



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 浙江工商大学

参赛队号 26103530218

1.许洪杰

队员姓名 2.张耀胜

3.张峻菲

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： **复杂场景下多模态情感预测的数学建模与算法设计**

摘 要：

多模态情感预测需同时利用文本、语音与视觉信号识别说话者的情感极性与强度，而复杂场景使该任务面临**异构时序对齐难、模态局部缺失、决策依据难追溯**的三重挑战。为此，本文基于 CMU-MOSEI 数据集建立 **“统一时序坐标—缺失感知预测—反事实解释”** 三层递进的建模体系，三个问题共用同一套坐标定义与合成缺失算子，使后一问题的建模与解释始终建立在前一问题的产出之上。

针对问题一，以转写文本的子词位置为主轴建立了**统一时序坐标系**：先形式化定义语义位置集、结构状态与观测状态三元组（自然观测、合成缺失、可用状态），再由 CTC 强制对齐获得词级半开时间区间，进而将语音与视觉特征按词区间池化映射至 **50 位网格**，截断、标点挂靠、无有效帧等边界情形均归入确定性规则并在映射表中留痕。该坐标系在 **100 条样本**上通过四类机器指标验收：样本覆盖完整，自生成特征与附件 2 总体行为一致，冻结后 **7 条**重叠样本文本特征逐位一致，管线责任对齐失败率约 **1.0%**，由此为问题二、问题三提供共用的位置语义与位置—物理时间对应关系。

针对问题二，在该坐标系之上**构建缺失感知可靠融合网络 MRFN**，以缺失状态编码、可用性约束注意力与可靠性门控三层机制使缺失成为显式输入变量。在 **31 个缺失场景**的固定网格上评测得到三条实验结论：其一，文本缺失是主导的脆弱性来源；其二，缺失增强训练使综合效用较干净训练**提高 0.030**，且干净性能不降反升；其三，三层机制的各自贡献由**模型阶梯与消融实验**逐级定位。MRFN 在测试集上取得 **66.71%** 的准确率，经预注册门槛筛选采纳的改进变体 MRFN+ 经三种子集成达到 **68.64%**，并完成附件 3 的 **30 条全量**预测与行为分析。

针对问题三，在冻结的 MRFN+ 之上建立**反事实解释框架**：模态作用程度由 **8 次**迭代精确 Shapley 值度量，位置级归因由 **64 步**中点积分梯度度量，关键证据沿问题一的坐标映射回溯至原词与物理时间。六项保真度检验按运行前冻结的判据执行，**A-E 通过；F 项未通过**，已完成结构性诊断。附件 4 的 **20 条全量**预测与解释均已完成，全局关键证据均为文本词证据并附物理时间区间。

综上，本文建立了统一的多模态时序坐标体系，构建了面向模态缺失的可靠融合网络，并进一步建立了基于 Shapley 值和积分梯度的情感预测解释方法，实现了从多模态数据对齐、缺失场景预测到结果解释与证据回溯的完整建模过程。实验结果表明，所建立模型能够有效提高缺失场景下的预测稳定性，并能够将预测结果追溯至具体的文本、语音和视觉信息，为多模态情感预测模型的实际应用提供了参考。

关键词： 多模态情感预测；时序对齐；模态局部缺失；鲁棒融合；可解释性；证据回溯

目录

1	问题背景与问题重述	5
1.1	问题背景	5
1.2	问题重述	5
1.3	附件与数据约束	6
2	问题分析	7
3	模型假设与符号说明	9
3.1	建模前提	9
3.2	待验证假设	9
3.3	符号说明	10
4	问题一：时序对齐模型的建立与求解	12
4.1	数据事实与分析	13
4.2	统一时序坐标系的建立	14
4.3	特征生成与边界延拓	15
4.4	CTC 对齐求解与合法性处置	17
4.5	验收检验与典型回放	20
5	问题二：鲁棒情感预测模型的建立与求解	23
5.1	缺失空间的数学描述	23
5.2	MRFN 模型的建立	24
5.3	训练方案与模型阶梯	26
5.4	鲁棒性评价与实验	28
5.5	模型改进与终评	30
5.6	预测与行为分析	32
6	问题三：可解释情感预测模型的建立与求解	35
6.1	解释任务的形式化	35
6.2	模态级 Shapley 模型	35
6.3	位置级积分梯度模型	36
6.4	解释可信性验证	40
6.5	解释结果与分析	42
7	模型评价	44
7.1	模型优点	44

7.2 三问联合验证	44
7.3 灵敏度与稳定性分析	45
7.4 局限与错误归因	45
参考文献	46
附录 A 环境与复现	48
附录 B 关键代码	49
附录 C 结果文件样例	52
附录 D 掩码库说明	54

1 问题背景与问题重述

1.1 问题背景

多模态情感预测通过综合文本、语音与视觉信号，判断说话者的情感极性与强度，在人机交互、辅助医疗和舆情分析等领域具有较好的应用价值。相比单一模态，多模态信息能够从不同角度反映情感状态，但不同模态在采样频率、时间尺度和信息表达方式上存在差异，实际数据中还可能出现局部信息缺失，使不同模态之间的信息融合更加困难。同时，模型给出预测结果后，仅提供情感极性和强度仍难以说明判断依据，如何将预测结果与原始输入中的具体信息对应起来，也是多模态情感预测需要进一步考虑的问题。多模态情感识别近年在融合架构、缺失处理与可解释性方面取得系统性进展，综述工作 [1] 对深度学习方法的现状与未来方向给出全面梳理，本文的统一坐标—缺失感知—反事实解释三层体系在该综述给出的分类框架下属于“联合优化 + 显式状态建模 + 后验归因”的代表性路线。

本文以 CMU-MOSEI (CMU Multimodal Opinion Sentiment and Emotion Intensity) [2, 3] 为唯一数据来源，主要研究多模态时序对齐、模态局部缺失条件下的情感预测以及预测结果的解释问题，并按照“统一时序坐标—缺失感知预测—结果解释与证据回溯”的思路逐步展开。

1.2 问题重述

本文以 CMU-MOSEI 数据集为基础，研究文本、语音和视觉三种模态信息在情感预测中的处理、融合与解释问题，具体需要完成以下三项任务。

问题一：文本、语音和视觉信号具有不同的采样频率和时间尺度，需要首先完成从原始素材到标准化时序特征的处理。研究中需要明确原始样本的处理流程、各模态情感特征的定义与提取方法，并确定跨模态时序对齐的规则与实现逻辑。允许使用开源工具或预训练模型完成基础处理，但相关规则需要落实到具体流程中，并保留相应参数和日志，以保证处理过程能够核验和复现。由于特征中的零值既可能来自合法的低能量观测，也可能来自采集失败，因此需要对不同情况进行区分。最终需要保证原始样本覆盖完整、时序组织清晰可验证，并为后续问题提供统一的时序基础。

问题二：在完成上述时序处理后，需要进一步研究文本、语音或视觉信息在部分连续时段不可用时的情感预测问题。模态局部缺失不同于整模态完全缺失，需要根据实际可用的输入信息完成预测，并分析缺失模态类型、缺失位置和缺失时长对预测性能的影响。模型需要同时完成情感极性三分类和情感强度回归两项预测，其中分类任务采用准确率与 F1 值评价，回归任务采用平均绝对误差与皮尔逊相关系数评价。训练与模型选择在附件 2 的训练集与验证集上进行，附件 3 中的全部无标签样本仅用于最终推理。

问题三：在得到情感预测结果后，还需要进一步分析模型作出判断时主要依据了哪些模态以及哪些时间位置的输入。由于文本、语音和视觉三类信息同时参与预测，模型的主要判断依据并不直观，因此需要以可量化、可复核的方式说明本次预测主要依赖的信息，并将关键证据对应到原始文本片段、语音时段或视觉关键帧，以便与原始素材进行核查。模型同样在附件 2 上完成训练与选择，并对附件 4 中的全部无标签样本输出预测与解释结

果。此处被解释样本的三模态信息保持完整；而为回答“若某模态信息不可用，预测将如何变化”等对比问题所构造的合成缺失，与问题二中的模态局部缺失含义不同，后续将分别进行处理。

1.3 附件与数据约束

本题提供四组数据与材料，各附件的规模、组织方式与本题用法汇总于表 1.1。

表 1.1 题面附件的规模、组织方式与用法

附件	内容与规模	关键组织方式	本题用法
附件 1	100 条原始英文视频（37 个 video_id 子文件夹，时长 2.648–34.567 s）及标注表	video_id 与 clip_id 共同确定样本；text 列为英文转写；连续强度标注取值 $[-3, 3]$ ，其中 $[-3, 0)$ 负向、0 中性、 $(0, 3]$ 正向，0 仅属中性	问题一特征提取与对齐的原始素材
附件 2	标准化多模态特征文件，对齐与非对齐两套、各 4850 条样本，按训练/验证/测试 = 3395/728/727 组织	文本/语音/视觉特征维度分别为 768/74/35；对齐版本三模态均按 50 个对应序列位置组织，非对齐版本语音与视觉保留独立时序（500 位置）；标签含三分类与连续强度	问题二、问题三建模的唯一训练与选型数据
附件 3	30 条无标签样本的特征文件，含随机模态局部缺失	缺失表现为一个或多个模态中特征值全部为零的随机连续区间	问题二专项测试，仅作最终推理
附件 4	20 条无标签真实场景视频及对应三模态特征文件，三模态信息完整	特征字段、张量维度与时序组织与附件 2 保持一致；配套原始视频用于将关键证据时间位置回看至文本、语音或视觉片段	问题三专项测试，仅作最终推理

表中“特征值全部为零的连续区间”是题面构造附件 3 时所采用的缺失判据；特征取零本身并不必然等同于信息缺失，二者的区分将在第四章观测状态建模中给出。

本文严格遵守题面规定的数据使用约束，以赛题提供的 CMU-MOSEI 系列数据作为唯一数据来源，不引入其他数据集参与训练、微调、参数优化、阈值选择或结果统计，同时保证训练、验证与专项测试采用相同的特征版本和输入接口。问题二与问题三模型均在附件 2 训练集上学习参数，并在验证集上完成模型结构与决策阈值的选择，附件 3 和附件 4 仅用于最终推理；对于极短、无效或异常片段，则保留原始样本并按照规定的处理规则进行处理，同时对相关规则予以说明。

2 问题分析

三问的内在联系、技术路线与公共实验纪律构成本章主体。本节先明确三问的输入输出关系与共同约定，再给出各问的技术路线与全篇公共实验纪律。

三问输入输出关系。三问面对同一批多模态数据，题面允许问题二、问题三直接采用附件 2 标准化特征建模。组织方式有两类：各问独立选择输入表示，或共用同一套时序坐标。本文采用后者，以问题一建立的时序坐标作为全篇共同使用的坐标定义，其位置体系、观测状态、位置—物理时间映射三类要素的形式化见 3.1 节与第四章。采用统一坐标主要基于两点考虑：第一，问题一的自生成表示须通过与附件 2 特征的行为一致性检验，以通过检验的坐标系为基准，后两问的特征语义有据可依；第二，问题二训练中的合成缺失与问题三解释中的反事实干预作用于同一位置体系，跨章结论可以相互支撑。需要说明的是，共用坐标系不等于共用特征文件，问题二、问题三输入模型的特征矩阵仍取自附件 2，“统一坐标”与“特征来源”属于两个层次。

三重挑战各对应一个数据层面的技术前提：异构时序对齐难转化为对齐问题，即 50 个序列位置须与物理时间建立可核验的对应；模态局部缺失转化为状态建模问题，即“是否观测到”与“观测值是多少”须分开形式化；决策依据难追溯转化为证据回溯问题，即关键证据依赖位置—时间映射。模态局部缺失的真实形态由附件 3 实测统计给出。如图 2.1 所示，附件 3 联合零行的连续缺失段长分布中，段长为 1 的单点散布占 74.7%，平均段长 1.379 个位置，缺失以单点散布为主、长段（ ≥ 4 位）合计仅 4.2%，各缺失段长度的精确统计见表 2.1；后文的实验设计即以这一真实分布为依据。




图 2.1 附件 3 联合零行连续缺失段长分布

对于各问技术路线，问题一建立统一时序坐标系并以四类机器指标验收 (§4.2–§4.5)。问题二在问题一的坐标系上构建 MRFN，将可用状态作为缺失状态编码、可用性约束注意力、可靠性门控融合三层机制的显式输入，以 31 场景网格评测 (§5.1–§5.6)。问题三在问题二冻结预测器之上叠加反事实解释框架，模态级贡献由精确 Shapley 值度量、位置级归因由积分梯度度量、解释可信性以运行前冻结的判据验证，关键证据沿位置—物理时间映


表 2.1 附件 3 联合零行连续缺失段长精确统计

段长（位）	段数	实测位数	段数占比	位数占比
1	71	71	74.7%	54.2%
2	16	32	16.8%	24.4%
3	4	12	4.2%	9.2%
4	4	16	4.2%	12.2%
≥ 5	0	0	0.0%	0.0%
全样本合计	95	131	100.0%	100.0%

射回溯 (§6.1–§6.5)。

对于总体技术框架，三条路线的整体组织与数据流向如图 2.2 所示。原始视频经文本转写、音频、视觉三路提取进入问题一，问题一在子词位置体系上完成特征生成与强制对齐并输出坐标定义。问题二以附件 2 特征为输入、以坐标定义为共同基准，训练缺失感知预测模型。问题三复用问题二确定的预测器完成反事实解释，关键证据沿位置—物理时间映射回溯至原始素材。映射链以旁路形式直接连通问题一与问题三，证据的时间定位不经过预测模型，可独立核验。数据自上而下单向流动、证据自下而上沿映射链回溯，本文不涉及反馈或再训练环节。

对于实验纪律，验收门槛在实验运行前确定，实验后不因结果调整，未通过项保留原始结果并给出诊断分析——与 1.2 节数据使用约束同源。



3 模型假设与符号说明

三条建模前提、九条待验证假设、四组核心符号构成全篇共同基础。本节登记前提与假设，统一全篇符号。前提经采用理由说明后直接成立；假设须在后续章节以实验检验，未达标项如实报告。

3.1 建模前提

本节登记建模采用的顶层前提；实现层面的具体规则随对应方法小节首次出现时给出。

- 任务定义：情感极性三分类与情感强度回归，值域 $[-3, 3]$ ，以多任务联合损失训练， $\lambda_r = 1$ （分类与回归等权）。
- 输入约束：附件 2 对齐版本；附件 3、附件 4 无标签，仅作最终推理。
- 评估口径：训练集学习参数、验证集选择模型结构与阈值、专项测试集只作最终推理；评测掩码库使用独立种子，与训练种子分离，评测场景对训练过程不可见。31 场景缺失率的实测分布由图 3.1、表 3.1 给出：训练 / 验证 / 测试三划分各 50 个场景级缺失率均集中在 0–80% 区间，三条密度曲线高度重叠（均值 0.43、标准差 0.23）。这表明 31 场景网格的覆盖率分布在三个划分上同源，评测场景对训练与选择决策不构成系统性偏差，因此 §5.4 的评测结果可在三划分间一致比较。




图 3.1 31 缺失场景缺失率分布

- 数据来源边界：以赛题提供的 CMU-MOSEI 系列数据为唯一来源，不引入其他数据集参与训练、微调、阈值选择或结果统计。

3.2 待验证假设

除上节前提外，另将九条预期命题登记为待验证假设，编号 H1–H9 全篇唯一。各条判定标准为实验运行前冻结的门槛，实验后不移动；未完全达标者如实记为部分成立，不回改假设。假设的最终状态以验证章节的报告为准，命题要点与验证落点列于表 3.2。

表 3.1 31 场景缺失率按类型汇总

场景类型	场景数	均值	标准差	最小	最大
MCAR 单模态 ($\{t, a, v\} \times \{10, 20, 40, 60, 80\}\%$)	15	0.4201	0.2643	0.1004	0.7985
MCAR 双模态 ($\{ta, tv, av\}@40\%$)	3	0.3999	0.0000	0.3999	0.3999
连续块 ($\{t, a, v\} \times \{\text{头/中/尾/随机}\}@40\%$)	12	0.3976	0.0037	0.3889	0.3999
联合缺失 ($av@40\%$)	1	0.3846	—	0.3846	0.3846
31 场景合计	31	0.4074	0.2179	0.1004	0.7985

表 3.2 待验证假设登记表

编号	名称	验证章节	命题要点
H1	音视表示规则一致	第四章	自生成音视特征的结构位处理与观测行为同附件 2 对齐版本一致
H2	文本接口同源	第四章	冻结编码器重编码的文本特征与附件 2 预计算特征同源（逐位余弦 ≥ 0.99 ）
H3	前提有效性	第四章	对齐粒度与观测语义前提可支撑 50 位网格的跨模态对齐与缺失识别
H4	缺失增强训练有效性	第五章	训练期混入合成缺失提升缺失场景效用，且干净性能代价有限
H5	门控可靠性响应	第五章	门控信任与对应模态的信息可用性存在同向响应
H6	组件增益可归因	第五章	架构各级增益可由阶梯设计与消融逐级定位
H7	解释分布基础	第六章	缺失感知训练使解释的反事实干预输入落在训练分布附近
H8	归因可回溯且忠实	第六章	位置归因可沿映射链回溯至物理时间，且与删除响应秩一致
H9	解释稳定	第六章	归因排序对输入轻微扰动保持稳定

3.3 符号说明

全篇核心符号列于表 3.3，高频符号的含义在首次使用公式处说明，本表仅列高频索引项；派生符号（ λ_r 、 α_j 、 c_m 、 T 、 τ 等）在对应公式括号内给出。

表 3.3 全篇核心符号

符号	含义
数据与坐标	
$m \in \{\text{text}, \text{audio}, \text{vision}\}$	模态（下标 $t/a/v$ ）
$j = 1, \dots, 50$	序列位置
$J = \{0, 1, \dots, 49\}$	语义位置集（定义 4.1，固定 50 步索引）
$w; n_w$	原词；词 w 所含子词数
$W = (w_1, \dots, w_K)$	对齐词序列（CTC 强制对齐输出）
$\kappa: J_{\text{内容}} \rightarrow W$	词归属函数（定义 4.3，内容位 $\mapsto$ 原词）
$\alpha_j = 1/n_{\kappa(j)}$	词内均匀权（语音/视觉特征在词内各子词位共享时按此计权）
x_j^m	模态 m 在位置 j 的特征向量
s_j	结构状态（内容/特殊/填充位）
o_j^m	自然观测指示
b_j^m	合成缺失指示
$a_j^m = o_j^m(1 - b_j^m)$	可用状态
$[t_s, t_e)$	词的物理时间半开区间
$I_w = [t_s(w), t_e(w))$	词 w 的物理时间区间（CTC 强制对齐求解）
预测模型	
F	情感预测器（极性 + 强度双输出）
g_m	融合层对模态 m 的门控信任
$\tilde{h}_m$	模态 m 经融合层得到的表示
$p; \hat{y}$	极性概率向量；强度预测值
缺失与评价	
$(M, P, r, \bar{l})$	缺失空间四元组（5.1 节，刻画单一缺失场景）
$\gamma_{M,P,r,\bar{l}}$	合成缺失算子（5.1 节，按四元组取样生成缺失位）
χ_j	内容窗指示（5.2 节， $m_j^e = \chi_j a_j^e$ ）
$r; \bar{l}$	缺失率；平均缺失段长
ℓ	连续缺失块长（附录 D 块长扫描 $\ell \in \{2, 5, 10\}$ ）
ρ	相关系数（Pearson/Spearman，文本—模态一致性）
$\mathcal{S}$	综合效用分
$D_U(r)$	缺失率 r 下的效用相对下降率
$\mathcal{S}_{\text{sel}}$	验证集选型分
ECE	期望校准误差（§5.6 校准前后对比）
训练细节	
T	温度校准系数（§5.6，验证集 NLL 拟合）
λ_r	多任务损失权重（ $\lambda_r = 1$ ，分类与回归等权）
解释框架	
$N; S \subseteq N$	模态全集；模态联盟
$v(S); v(\emptyset)$	联盟值；空联盟值（ $\emptyset$ 为空联盟， $v(\emptyset)$ 对应三模态全未观测）
φ_m	模态 m 的带符号 Shapley 贡献
$E; E'$	子词嵌入矩阵；IG 基线嵌入
$\tau \in [0, 1]$	IG 路径插值参数（公式 6.3， $E(\tau) = E' + \tau(E - E')$ ）
$\text{IG}_j; A_w$	位置归因；词级归因
AOPC	删除优越性指标（§6.4 判据 A，衡量删除/插入保真度）
CTC 算子（§4.4）	
π	CTC 字符级路径（允许重复发射，去重复/去空白）
$\mathcal{B}$	CTC 坍缩映射（去重并去除空白符）
ε	CTC 空白符（用于对齐词表外的空发射）

4 问题一：时序对齐模型的建立与求解

原始视频、音频与文本转写在采样粒度和坐标系上互不相同，直接联合建模会引入位置偏差。本章的核心任务是建立**统一的 50 步序列坐标系**，并保证网格位置可双向映射回原始素材的物理时间——前者支撑逐位置联合建模，后者支撑后续解释与回溯接口。本章先给出两组实测分布作为建模依据（图 4.2 与图 4.3），本章求解流程见图 4.1，全文整体技术路线流程见图 2.2。




图 4.1 问题一求解流程

在进入形式化定义之前，首先在实测事实上：CTC 词区间在 50 位序列上的分布并不均匀。图 4.2 按词所在位置分位给出词持续时间 $t_e - t_s$ 的核密度分布：**头段（位置 $\leq K/3$ ）词持续时间众数约 0.13 s、中段约 0.14 s、尾段约 0.16 s**，三段众数相近但分布尾部差异显著——尾段词持续时间在 0.3 s 以上的占比高于头段，对应说话过程中局部语速变化。该非均匀性是 §4.2 统一坐标系采用词区间映射（而非等间隔 50 帧）作为位置—时间接口的实测依据。

各模态对齐后的内容位填充情况由图 4.3 给出：文本空位数均值为 25.5，其中 48 个内容位中实际词片数较少导致空位占比大，与 §4.1 “位置语义不一致” 事实对应；语音空位数均值为 0、视觉空位数均值为 1.2（最大 17），说明对齐后语音内容位覆盖完整、视觉在 5% 的内容位上无人脸检出——这是 §3.1 前提中“零值不自动等于缺失”在自生成数据上的实测依据。




图 4.2 词持续时间按位置分位的核密度




图 4.3 对齐后内容位空位数分模态分布

4.1 数据事实与分析

问题一的建模对象为附件 1 的 100 条原始视频。本节将原始素材的实测事实转化为后续统一坐标建模所需的约束条件：只保留三类与建模直接相关的事实，具体统计数值留待 4.5 节在验收指标语境中报告。

其一，三模态的位置语义不一致。附件 2 对齐版本虽然将三模态组织在同一 50 位序列上，但实测结果表明：文本特征是逐子词的上下文向量——同一原词相邻子词的行向量互不相同、差异明显；语音、视觉特征则是词级池化后的复制——同一原词的全部子词行逐位相同，且二者在特殊位精确为零、SEP 位之后不出现非零行。同一“位置”对文本是子词级、对语音视觉是词级，统一坐标必须显式处理这一粒度差异。

其二，特征零值具有双重语义。按有效位置统计，语音特征近乎全为非零；视觉特征存在少量零行，其出现与无人脸或局部不可观测的情形相对应，另有极少量整条视觉全零的样本。零值既可能是合法的低能量观测，也可能是未观测到，“是否观测到”必须与“观

测值是多少”分离为两个独立变量——这一区分是第三章建模前提中“零值不自动等于缺失”的实测依据。

其三，素材物理参数不齐整。视频帧率不统一，且存在远超 50 位网格容量的长转写——截断必然发生，截断方向与特殊位摆放须显式定义；同时附件 1 与附件 2 存在重叠样本且转写逐条一致，可为自生成表示提供逐位核验的参照系。

上述三组事实共同决定了问题一的建模约束。在此约束下，问题一须同时满足三项建模要求：

- 统一的位置坐标：文本、语音、视觉必须组织到同一序列位置体系，使跨模态信息可逐位置联合建模；
- 区分真实零值与不可观测：必须把“是否观测到”与“观测值是多少”分离为两个独立变量，避免零值混叠合法低能量观测与采集失败；
- 证据可回溯至物理时间与原始输入：每个序列位置须能回溯到原始素材的物理时段，关键证据须能定位至原始文本、语音或视觉片段——这是后续解释与回溯的接口，与 §1.1 第三重挑战”决策依据难追溯”直接对应。

上述三项要求也分别对应 4.2 节的定义 4.1–4.3 与位置—物理时间双向映射接口声明，4.3 节的边界延拓规则以及 4.4 节的词区间求解。

4.2 统一时序坐标系的建立

坐标系采用双域设计——语义位置域承载逐位置联合建模，物理时间域承载与原始素材的对应——两域仅通过词区间连接，不假设各位置等间隔对应物理时间。这一设计回应 4.1 节”位置语义不一致、帧率不齐整”的约束；据此依次定义语义位置集、结构状态、观测状态、词序列与词归属四类要素，并声明位置—物理时间映射的求解接口。

定义 4.1：语义位置集 $J = \{0, 1, \dots, 49\}$ 是固定 50 步模型索引坐标： $j = 0$ 固定为 CLS 位；内容子词按转写顺序自 $j = 1$ 起排布；设内容子词数为 $k \leq 48$ ，则 $j = k + 1$ 为 SEP 位、 $j > k + 1$ 为填充位；内容子词超过 48 时保留前 48 个，SEP 固定于 $j = 49$ 。 J 不与物理时间等间隔对应。

在 J 上附以结构状态 $s_j \in \{\text{内容}, \text{特殊}, \text{填充}\}$ ：CLS 与 SEP 为特殊位，SEP 之后为填充位，其余非填充位为内容位；结构状态满足尾部单调性，且三类互斥、合计覆盖全部 50 位。结构状态与下述观测状态都是附着在”位置—模态”二元组上的逐位置标注变量，不构成第三个坐标域。

定义 4.2：观测状态三元组对位置 j 与模态 $m \in \{t, a, v\}$ ：自然观测 $o_j^m = 1$ 当且仅当模态 m 在该位置对应的原始素材片段被成功观测（文本：转写含该子词；语音/视觉：对应词区间内存在有效采集帧）；合成缺失 $b_j^m \in \{0, 1\}$ 为受控实验变量（问题二、问题三使用，本节一并定义以供全篇复用）；可用状态 $a_j^m = o_j^m(1 - b_j^m)$ 。观测状态由采集与对齐环节决定，与特征值 x_j^m 的数值在定义上分离——特征取零不改变观测状态。特殊位与填充位上 $a_j^m \equiv 0$ ；文本模态在内容位上 $o_j^m \equiv 1$ （转写存在即观测，与 4.1 节实测一致）。

定义 4.3：词序列、词归属与字符区间转写经规范化后，不发音的标点不入对齐词

序列、按继承规则挂靠邻词（继承规则随 4.3 节边界延拓规则给出）。对齐词序列 $W = (w_1, \dots, w_K)$ 中每个词 w 对应一个抽象的半开物理时间区间 $I_w = [t_s(w), t_e(w))$ —— I_w 的具体数值由 4.4 节对齐算法求解给出，本节仅约定其形式约定：两两不重叠、帧时间戳唯一归属一词、时长为正。词归属函数 $\kappa: J_{\text{内容}} \rightarrow W$ 将每个内容位映射到其所属原词，由分词器词编号与字符偏移联合构建；原词 w 经 κ 同时确定其在转写文本中的字符区间。词内均匀权 $\alpha_j = 1/n_{\kappa(j)}$ ， n_w 为词 w 所含子词片数（含继承标点位）；语音/视觉特征在词内各子词位共享词级信息（4.1 节事实），故涉及子词汇总的池化与归因均按 α_j 计权，避免子词数多的长词被重复加权。

位置—物理时间双向映射。坐标系的最后一维——位置 j 与物理时间 t 的对应——由词区间 I_w 决定，包含两个方向：其一，内容位置 j 经 $\kappa(j)$ 得原词 w ，再由 I_w 得该位置对应的物理时段；其二，任一帧时刻 t 若被某 I_w 覆盖，则 t 经该词的全部子词位置被唯一归属。

抽象 I_w 在本节仅作为接口声明出现，4.3 节特征池化与 4.4 节对齐求解均基于此接口。词区间的合法性约束（时长落在对齐量化粒度至 3 s、起于片段内）随 4.4 节 C2 检查一并给出，不在本节重复。

性质 4.1：双向可核验性由定义 4.1–4.3 与上述接口声明可得：任一内容位置 j 可经 $\kappa(j)$ 得原词、其字符区间，再经 I_w 得物理时间；反之，任一被词区间覆盖的物理时刻可经帧时间戳唯一归属到词与其全部子词位置。逐样本映射表随附录交付，两个方向均可分别复核、互不依赖对方的计算结果；本性质为构造性说明，不构成形式证明。

图 4.4 给出了坐标系的整体结构：上方为语义位置域，下方为物理时间域，中间梯形带为词区间映射。从图中可以得出，两域各自保持自身刻度、仅以词区间连接，不做任何线性拉伸——这正符合了 4.1 节“位置语义不一致、帧率不齐整”约束下统一坐标的实现方式。

4.3 特征生成与边界延拓

统一位置与抽象词区间 I_w 确定后，还需将三模态特征落实到 50 位网格上。文本不经时间池化，语音与视觉按词区间池化后复制到该词的子词位——三条路径对应 4.1 节第一组事实的三种粒度。截断、标点挂靠、无帧缺失等边界作为确定性映射使坐标系在非理想输入上得到延拓； I_w 的具体数值在本节仍为抽象符号，词区间的实际求解与合法性判定交由 4.4 节处理。

三个算子的语义差异直接来自 4.1 节第一组事实，分别定义如下。对于文本特征，本研究在语义位置域直接生成表征：先对文本转写结果执行子词切分，随后采用权重与版本固定的预训练 BERT 编码器（BERT[4]，bert-base-uncased，权重与版本冻结）完成逐子词编码，得到编码矩阵

$$H = \text{Encoder}(\text{input_ids}, \text{attn_mask}) \in \mathbb{R}^{50 \times 768}, \quad (4.1)$$

矩阵第 j 行即位置 j 的上下文相关子词表示，特殊标记与填充标记的向量由编码器依照标记语义自动生成，模型选取编码器最后一层隐状态作为输出，该层的选择依据与核验实验



图 4.4 统一时序坐标图

详见 4.5 节给出。并且文本特征不经过任何时间维度的池化操作。

对于音频特征，本研究基于扩展日内瓦极简声学参数集（eGeMAPS[5]；本文使用其 v02 工具实现，工具版本详情见 4.4 节工具清单）逐帧提取 25 项底层声学描述符，特征提取阶段帧移设置为 10 ms——该参数仅作用于特征提取环节，与 4.4 节对齐输出的时间量化粒度相互独立、互不约束。记帧时刻为 t_k 、帧特征为 x_k ，词 w 的池化算子为

$$P^a(w) = \frac{1}{|F(w)|} \sum_{k \in F(w)} x_k, \quad F(w) = \{k : t_k \in [t_s(w), t_e(w))\}, \quad (4.2)$$

将计算得到的单词级音频向量复制填充至该单词对应的全部子词位置，该处理方案与附件 2 对音视特征的官方组织规范保持一致（4.1 节事实）。

对于视觉特征，本研究先对图像完成人脸对齐，再提取面部动作单元与姿态描述特征，按照素材原生帧率抽取图像帧，以帧中心时刻是否落入单词时间区间 $[t_s(w), t_e(w))$ 判定帧归属，池化与向量复制填充规则与音频特征保持一致；若单词对应的时间区间内不存在有效图像帧，则按照规则 R3 填充全零行向量。

特征空间声明。问题一交付的是自提取原始空间特征，语音 25 维、视觉 23 维；问题二、问题三的模型输入取附件 2 官方维度，语音 74 维、视觉 35 维——两套特征数值空间不混用，全篇共用的是 4.2 节的坐标与状态定义，与第二章“统一坐标与特征来源分层”一致。

在边界延拓规则内以下规则进行形式化确定性映射，输入为 4.2 节坐标系，输出为特征矩阵与状态标注：

- **R1：头部截断**内容子词逾 48 时按定义 4.1 截断；被截除的整词不入网格、映射表标记截断；跨截断边界的词，其池化向量只复制到保留的子词位。
- **R2：标点挂靠**不发音的标点不产生独立词区间，但仍占据网格位置：其词归属 $\kappa(j)$ 取所挂靠的原词（收尾类挂前词、起始类挂后词、两可类默认挂前词并打标记），音视特征随挂靠词取值；文本特征不经时间池化，标点位置天然获得其自身的上下文表示。映射表对标点位置逐条记录挂靠类型， κ 在全部内容位上均有定义、无断点。
- **R3：无有效帧统一规则**：词区间内不存在任何有效帧时，该词语音/视觉特征为零行、 $o_j^m = 0$ 并记录缺失原因。有效帧的判定分模态定义——语音：区间内存在帧且描述符非全缺失；视觉：区间内存在帧且人脸检出成功。成功采集的低能量静音仍属观测 ($o_j^m = 1$)，对应 3.1 节“零值不自动等于缺失”的前提。
- **R4：部分帧缺失**区间内部分帧有效时仅对有效帧池化，全部无效方置零行。
- **R5：词间帧**词区间之外的帧不参与任何词的池化。

以一个发生截断的样本为例，图 4.5 展示了网格规则与状态标注的整体效果：图中呈现子词网格与结构状态、多子词的词内复制、标点挂靠、零行缺失标注与截断标记。从图中可以看出，边界延拓规则涉及的所有排除与变换均有明确规则并在映射表中留痕，不存在在未加声明的数据处置——被截断词、挂靠标点与缺失原因均可逐一追溯，这是性质 4.1 双向可核验性在边界情形下的延续。

4.4 CTC 对齐求解与合法性处置

词区间 I_w 的具体数值由 CTC 强制对齐得到；区间合法性通过 C1–C3 三条规则校验，校验失败的样本将按照管线责任与数据责任的分层策略执行异常处理。4.2 节定义 4.3 中作为接口的抽象 I_w 将在本节完成实例化：本节依次给出对齐问题的形式化（CTC 目标、维特比求解与词级聚合）、完整解码流程、合法性判定规则、异常分层处理与插值放行机制、置信度及失败原因的存储写入方式，同时附带本节用到的工具版本与核心参数清单。

CTC 强制对齐目标。记音频信号重采样至 16 kHz 后为 X ，声学编码器输出逐帧标记分布 $p(y_k | X)$ 。CTC [6] 引入空白符 ε 与逐帧取值的字符级路径 π （允许重复发射），坍塌映射 $\mathcal{B}$ 去重复、去空白符。词边界的编码：对齐词序列 $W = (w_1, \dots, w_K)$ 被编码为以词




图 4.5 50 位语义网格与状态标注

分隔符连接的字符目标 $\text{target} = w_1 | w_2 | \cdots | w_K$ (“|”为 CTC 词表中的分隔符标记)；强制对齐即求

$$\pi^* = \arg \max_{\pi} p(\pi | X) \quad \text{s.t.} \quad \mathcal{B}(\pi) = \text{target}, \quad (4.3)$$

由维特比算法精确求解。字符帧段与词级聚合：维特比回溯为 target 中每个字符 c 给出一个帧段 $[k_1(c), k_2(c))$ (该字符在路径中的发射帧段，可含多帧)；按分隔符将字符帧段切分归词后，词 w 的区间为

$$t_s(w) = \min_{c \in w} k_1(c) \cdot \Delta, \quad t_e(w) = \max_{c \in w} k_2(c) \cdot \Delta, \quad \Delta = 20 \text{ ms} \quad (4.4)$$

(帧移 320 采样 @ 16 kHz，即 C2 时长下界)。词置信度定义唯一：词内全部字符帧段的并集上、被指派标记的逐帧发射后验 $p(y_k=c | X)$ 的均值 (截断于 $[0, 1]$)。时刻约定：词区间端点取对齐帧边界 (量化格点)；4.3 节特征帧的归属判定则以帧中心时刻与该物理区间比较 (语音 $(k + 0.5) \times 10 \text{ ms}$ 、视觉帧时间戳) ——端点定义与帧归属是两个环节的约定，分别声明、不混用。

解码流程。①转写规范化（小写化与字符规整）；②构造对齐词序列并编码字符目标（标点不入序列，C1 失败词不入目标）；③音频重采样后经声学模型编码；④维特比求解 π^* ，按上述聚合得到词区间与置信度；⑤执行合法性判定 C1–C3；⑥通过者连同置信度写入映射表，失败者按下节分层处置。图 4.6 给出了一个五词样本的逐步对齐示例：维特比回溯得到字符帧段后，经分隔符切分归词，即得各词区间与词置信度。




图 4.6 CTC 逐步对齐示例

合法性判定 (C1–C3)。对每个词按固定顺序执行三条可机械复算的检查：

- **C1: 词表检查 (编码前)** 词的全部字符均在 CTC 词表内，否则判“接口失败”；
- **C2: 区间检查 (解码后)** 词区间为正时长、起于片段内，时长落在 $[20\text{ ms}, 3\text{ s}]$ ，且不出片段时长（允许一个量化帧的容差），否则判“区间非法”。词区间两两不重叠不设独立检查——由坍缩路径的时间单调性构造性保证（相邻词的字符帧段天然有序）。
- **C3: 置信度检查 (解码后)** 词置信度 ≥ 0.5 （冻结阈值），否则判“低置信”。

检查顺序固定，失败原因唯一且可独立复算。3 s 上界为契约冻结的验收参数（正常语速下单词时长的上界量级，用于隔离时长异常输出，非理论约束）。

失败分层。责任分类依据处置路径而非成因归责，判定规则均为机械规则：

- **管线责任 (C1/C2 失败)** —— 管线内确定性处置：调用下方“插值放行”规则给出词区间，再以 C2 复核切分结果；复核未通过者该词置为最终失败（无时间区间，其语音/视觉特征与观测状态按 4.3 节 R3 处理）。管线责任占比的通过门槛为 $\leq 2\%$ （实测值在 4.5 节报告）。
- **数据责任 (C3 失败)** —— 处置为按同一插值规则给出词区间，其原始解码区间与置信度保留于映射表供核查对照，并打质量标记进入人工核查；管线不重跑、不因失败修改已冻结的流程，回滚重跑仅保留于管线责任类缺陷。样本级阈值为嵌套两级：单样本低置信词占比超过 5% 者进入人工核查清单；超过 20% 者在同一清单中标记为数据异常样本、优先核查，并随管线放行。

插值放行。可信词定义为通过 C1–C3 全部检查的词；连续失败词作为一段处理，段的左右锚点取前一可信词的区间终点与后一可信词的区间起点，锚点缺失时以片段首帧、末帧为虚拟锚点；在两锚点之间按整帧等距切分出各失败词的区间，切分结果须通过 C2 的时长与界内检查。该规则对两类责任通用，但管线责任类执行后须 C2 复核，数据责任类保留原始解码区间与置信度。

置信度与失败原因写入映射表。通过者连同词置信度一并写入映射表；管线责任类失败者写入失败类型（C1/C2）与插值区间；数据责任类失败者写入原始解码区间、置信度、质量标记（review/rollback）与人工核查状态。所有写入均在映射表中留痕，与 4.3 节边界延拓规则共同保证性质 4.1 的可核验性在失败情形下依然成立。

工具清单。特征与对齐环节使用 BERT(bert-base-uncased, revision 86b5e09)[4]、wav2vec 2.0 声学模型 [7]（CTC 头，16 kHz，帧移 320 采样）、openSMILE 2.6.0（eGeMAPSv02，25 维、10 ms 帧移）与 Py-Feat 0.6.1[8]（人脸对齐与动作单元，交付 23 维）；运行环境与各工具完整参数、权重指纹清单随附录 A 交付。

4.5 验收检验与典型回放

题面对自生成特征的两项要求——覆盖完整性、可核验性——被转化为四类可计算的验收指标：覆盖完整性、行为一致性、接口同源性、对齐质量。按“指标定义 → 实测结果 → 图表读数 → 典型案例 → 本章产出”的顺序逐一报告实测结果，并回应题面要求；4.1 节后移的统计数值在此一并给出。

指标定义。四类指标分别对应题面的两项要求——覆盖完整性、可核验性与可复现性：

- 覆盖完整性——对应题面要求（1）：输出特征与附件 1 标注表一一对应——样本编号无缺失、无重复、无多余，且每条样本通过 p1.v2 契约的 schema 校验（形状、数据类型、结构位分区、SEP 位置、观测掩码取值域），违例计数为零。
- 行为一致性——对应题面要求（2）：自生成语音/视觉特征在内容位上的非零率，与附件 2 对应划分之差的绝对值不超过 2 个百分点。该指标是分布层面的检验：比较对象为自生成样本集与附件 2 对应划分两个样本总体，验证的是自产管线对“何为观测、何为零值”的处置规则与官方管线在总体行为上一致，而非逐样本复现官方特征。基准取附件 2 训练划分（18 条重叠样本中 11 条属训练划分，来源分布最接近），其值为语音 99.915%、视觉 94.473%（验证/测试划分依次为 99.732%/100.000%、94.293%/93.925%）。
- 接口同源性——对应题面要求（2）：重叠样本（共 18 条：训练划分 11 条、测试划分 7 条）上，自编码文本特征与附件 2 预计算文本特征的逐位一致性，按“11 条标定、7 条冻结后独立验证”协议执行——标定仅确定接口形态（最终层隐状态；接口唯一、无搜索过程，不构成调参），验证只在冻结后的 7 条测试重叠样本上报告，判定标准为逐位余弦 ≥ 0.99 。
- 对齐质量——对应题面要求（3）：三级质量标记 ok/review/rollback 分别对应“无低置信词、低置信词占比 $\in (5\%, 20\%]$ 、占比 $> 20\%$ ”（与 4.4 节两级阈值衔接；rollback 仅沿袭命名，处置为放行+优先核查）；管线责任占比门槛 $\leq 2\%$ 。

实测结果。四项指标全部通过——回应了题面”覆盖完整性、可核验性、可复现性”的要求。数值与逐位核验细节汇总于表 4.1；以下三项不在表内的数字补全：管线责任失败 19/1934 词（约 1.0%，门槛 $\leq 2\%$ ）、数据责任低置信 347 词（约 17.9%，按 4.4 节规则放行）、附件 2 自身亦含整条视觉全零样本（训练/验证/测试 110/15/28 条，自然缺失在官方特征中同样存在）。4.1 节后移的素材统计在此一并报告：帧率构成为 30/29.97/23.98/25 fps（83/10/5/2 条），转写词数中位数 18、最大 65、非特殊子词超 48 者 6 条，截断样本中头部截断占 234/253 且 SEP 恒在最后有效位（与 R1 及官方组织一致），文本同词相邻子词行向量余弦约 0.63、音视同词行逐位相同（4.1 节第一组事实的量化证据）。

图表读数。图 4.7 以三联图形式给出对齐质量、观测率与缺失原因的可视化，可读出两点观察：其一，质量标记中 review 居多、rollback 最少，且 rollback 样本均判定为数据异常后放行并优先核查——失败的责任构成可量化、可追溯；其二，观测率分布集中于高观测区间，视觉缺失原因以无人脸为主且逐样本记录成因——缺失由此成为带原因的显式标注。

典型案例。回放样本按边界类型分层选取，须覆盖多子词词、标点挂靠、头部截断、混合帧率、无人脸与对齐失败插值六类边界且至少含两条 rollback 样本，按此协议选取 9 条，由冻结规则自动渲染：每图并列文本子词轨、音频波形轨与按词区间定位的视觉关键帧轨，标注结构状态、挂靠类型、截断标记、缺失原因与插值区间（签核完成前一律称“自动回放”），9 张回放图随交付包一并交付。本节核验其中一条——rollback 样本 9yfZ3swSY_4，用以确认 R1 头部截断、R2 标点挂靠、R3 无有效帧、R5 词间帧四类边界与 4.4 节插值放行规则均真实落地：低置信词占比超过 20%，按数据责任规则判定为数据异常样本放行，图中可见插值区间与质量标记的落位。其余 8 张回放图随交付包一并交付。

本章产出。基于上述机器证据——映射表断言 0 违例、四类验收指标全部通过、回放覆盖全部六类边界（含 3 条 rollback 样本）——可对题面要求逐条回应：覆盖完整性由指标（1）保证，特征提取全量汇总表随附录 B 交付；时序可核验性由 4.2 节映射定义与逐样本映射表（性质 4.1）、指标（2）（3）的分布与逐位核验、本节回放核验三部分共同支撑；合理性与可复现性由 4.4 节工具清单、p1.v2 契约与 SHA-256 指纹（附录 A）及复现说明保证。假设验证状态：H2（文本接口同源）由指标（3）的逐位验证直接判定成立；H1（音视表示规则一致）与 H3（对齐可用性）在机器证据层面成立，最终判定由参赛队按 R1–R5 与 C1–C3 规则逐图核验全部 9 条（结论见交付包签核单）。

第四章向第五章、第六章交付统一时序坐标系，作为两者共用的输入定义。




图 4.7 问题一验收三联图：对齐质量、观测率与缺失原因

表 4.1 问题一验收结果汇总

验收项	实测值	参照基准	判定
覆盖完整性	100/100 一一对应，无缺失/重复/多余	附件 1 label-100	通过
Schema 一致性	违例 0 (shape/dtype/mask 分区/SEP 位)	p1.v2 契约	通过
BERT 留出一致性	bitwise 7/7, $\cos_{\min}=1.000$	附件 2 test 重叠 7 条	通过
audio 非零率	1.00000	0.99915	$ \Delta =0.085 \text{ pp} \leq 2 \text{ pp}$
vision 非零率	0.94704	0.94473	$ \Delta =0.231 \text{ pp} \leq 2 \text{ pp}$
对齐质量状态	ok/review/rollback = 43/33/24	—	质量标记，非管线失败

5 问题二：鲁棒情感预测模型的建立与求解

精准统一的序列位置粒度与观测状态标准，是实现多模态缺失数据建模的基础前提。依托前文 4.2 节构建的多模态序列坐标系，本文搭建了面向各类缺失场景的鲁棒预测模型 MRFN。本章整体研究流程如下：首先对缺失空间与合成缺失算子进行规范化形式化定义；其次构建 MRFN 模型的三层核心机制与分阶段训练方案，并基于 31 类缺失场景完成模型性能评测；最后通过八轮预注册实验筛选最优模型变体，实现附件 3 数据集的全量预测任务。本章完整求解流程如图 5.1。




图 5.1 问题二求解流程

5.1 缺失空间的数学描述

模态局部缺失可通过四个维度进行刻画：缺失模态、缺失位置、缺失时长与缺失机制。本节将缺失问题抽象为四元组 $(M, P, r, \bar{l})$ 以及合成缺失算子 γ ，使 1.3 节所梳理的三类缺失影响因素，即缺失模态类型、缺失位置与缺失时长，均可在该形式化体系中得到一一对应。

缺失空间四元组用于完整刻画单一缺失场景，任意缺失模式均可由 $(M, P, r, \bar{l})$ 四元组统一描述。其中： $M \subseteq \{\text{文本, 语音, 视觉}\}$ 代表发生缺失的模态集合，该集合非空且共计包含 7 种模态缺失组合； $P \in \{\text{头, 中, 尾, 随机}\}$ 用于限定缺失片段在序列中的位置分布模式； r 为缺失率，定义为当前模态被抹除的内容位数与总内容位数的比值； $\bar{l}$ 为平均段长，指代所有被抹除连续片段的平均长度。具体而言，模态缺失类型由 M 表征，缺失位置模式由 P 表征，而缺失的整体规模与连续形态则由 r 与 $\bar{l}$ 共同刻画： $\bar{l}$ 取值较小时对应零散的短缺失片段， $\bar{l}$ 取值较大时对应集中的连续缺失块。需要说明的是， $\bar{l}$ 仅为用于场景分类的统计特征量，缺失片段的具体数量与段长分布由后续定义的缺失机制采样规则确定，并非由 $\bar{l}$ 直接生成。

合成缺失算子。算子 $\gamma_{M, P, r, \bar{l}}$ 基于 4.2 节坐标系定义：对任意模态 $m \in M$ ，依据既定机制取样生成内容位子集 S_m ，使其满足缺失率 r 、位置模式 P 及对应段长分布。定义指示变

量 $b_j^m = \mathbf{1}[j \in S_m]$, 将模态观测状态更新为 $a_j^m = o_j^m(1 - b_j^m)$ 。在特征处理上, 语音与视觉模态对 S_m 位置直接置零, 文本模态则将缺失位置替换为 [MASK] 后重新编码。该方式遵循 3.1 节结论, 可避免编码后置零导致的掩码失效问题。本算子设置两项全局约束: CLS、SEP 与填充位不参与抹除; 原始真实零值保持不变, 以此区分自然缺失与合成缺失。同时算子限定至少一个模态可用率不低于 20%, 规避三模态大规模缺失的无效场景。5.4 节的 31 个评测场景均满足该条件, 三模态完全缺失因任务不可解, 不纳入评测范围。

四种缺失机制。位置与段长的取样规则即缺失机制, 共分为四类: ①随机散布 MCAR: 位置均匀随机抽取、与特征取值无关, 实现逐位散布缺失; ②Block 连续块: 生成单个连续缺失块, 块长在 $[5, 0.6 \times \text{内容位数}]$ 上均匀取样、位置由 P 指定, 对应连续时间段不可用的典型场景; ③联合缺失: 语音与视觉在同位置同步抹除, 段长按附件 3 实测联合零行的经验分布取样; ④整模态缺失: M 中模态的全部内容位被整体抹除。两点界定: 其一, 附件 3 的实测模式仅作为联合机制段长分布的经验参照, 本文不对真实数据的缺失机制作统计命名; 其二, 整模态缺失处于从属地位, 问题二的研究边界为模态局部缺失, 整模态缺失仅作为训练的边界覆盖分量与评测的极端对照场景引入, 用以检验缺失趋于极端时的行为下界并提供极端输入的训练覆盖, 不扩大本文核心研究边界。

训练与评测的统一生成。评测所需缺失场景基于独立种子预构建掩码库生成, 保证不同模型在相同场景集合下可公平对比; 训练阶段的缺失样本按类别在线生成并混合, 各类别在批次内占比为: 附件 3 模式的联合局部合成缺失 35

5.2 MRFN 模型的建立

MRFN 的设计动机与近期因子分解融合 [9] 与因果不变表示 [10] 思路一致: 在统一表征空间下显式建模模态间的互补与冗余, 并以门控机制稳定地适应输入分布漂移。本文的差异在于把“缺失状态”从隐变量提升为一等公民, 使训练与推理沿同一状态链路传播。

缺失感知机制分为三个环节: 输入端的缺失状态编码、交互端的可用性约束跨模态注意力、融合端的可靠性门控。MRFN 的三层机制按该顺序定义, 与第二章数据流保持一致。模型输入包含附件 2 对齐特征与 4.2 节的状态标注, 输出极性 logits 与强度预测: $F : (x, s, a) \mapsto (\text{logits} \in \mathbb{R}^3, \hat{y} = 3 \tanh(\cdot) \in [-3, 3])$, 多任务联合损失为 $\mathcal{L} = \text{CE}(\text{softmax}(\text{logits}), y_{cls}) + \lambda_r \cdot |\hat{y} - y_{reg}|_{\text{mean}}$, 其中 $\lambda_r = 1$, 分类与回归等权训练。

机制一: 缺失状态编码。结构状态 s_j 为类别量, 通过内容位指示量参与计算: 记 $\chi_j = \mathbf{1}[s_j = \text{内容位}]$ 。模态 m 在位置 j 的输入嵌入为 $z_j^m = p_j + \tilde{x}_j^m + (1 - a_j^m) e^m$, 其中 $\tilde{x}_j^m$ 采用选择运算: $a_j^m = 1$ 时取 x_j^m , 否则取 0。该运算数学上等价于门控乘积 $a_j^m x_j^m$, 但选择式实现可保证不可用位特征不进入计算图。 p_j 为可学习位置嵌入, e^m 为模态独立的缺失嵌入; 整模态缺失时输入退化为 $p_j + e^m$ 而非全零, 将缺失本身作为显式输入变量。

机制二: 可用性约束跨模态注意力。模型共包含六个交互方向 $q \leftarrow e$, 证据可用性定义为 $m_j^e = \chi_j a_j^e$ 。缩放点积注意力 [11] 以单头为基础, 多头为并行扩展, 实现设置工作维 64、2 头: $\omega_{jj'} = \text{softmax}_{j'} \left(\frac{(W_Q z_j^q)^\top (W_K z_{j'}^e)}{\sqrt{d_h}} + \log m_{j'}^e \right)$, $A_{q \leftarrow e}(j) = W_O \sum_{j'} \omega_{jj'} m_{j'}^e W_V z_{j'}^e$ 。 $m^e = 0$ 的位置经 $\log m = -\infty$ 使 softmax 权重归零, 再在值侧乘以 m^e , 构成双侧屏蔽, 不

可用位不作为证据参与聚合。另外增设显式置零分支：证据模态全部位置不可用时，注意力输出虽趋近于零，但输出投影 W_O 的偏置仍会引入非零值，因此直接将该方向输出置零。缺失位不提供证据，但可作为查询位接收其他模态的上下文补偿。

机制三：可靠性门控融合。各模态依次经过线性投影、内容窗双向 GRU、两个方向注意力增广、内容位掩码池化，得到模态表示 $\tilde{h}_m$ ；模态覆盖率定义为 $c_m = \frac{\sum_j \chi_j a_j^m}{\sum_j \chi_j} \in [0, 1]$ 门控与融合为 $g = \text{softmax}(\text{MLP}([\tilde{h}_{\text{text}}; \tilde{h}_{\text{audio}}; \tilde{h}_{\text{vision}}; c_{\text{text}}; c_{\text{audio}}; c_{\text{vision}}]))$ ， $h = \sum_m g_m \tilde{h}_m$ ，融合表示 h 送入双输出头完成预测。门控输出 g_m 代表融合层对各模态的信任分配，用于 5.4 节门控响应检验与第六章一致性分析。

模型整体数据流见图 5.2：左侧为缺失场景构造流程，包含缺失空间参数 $(M, P, r, \bar{l})$ 、可用状态计算 $a = o \cdot (1 - b)$ 、分模态掩码处理；右侧是四阶段前向数据流，依次为输入层、投影层、缺失鲁棒编码模块、双头输出。两条虚线连接左右栏的可用状态输入与掩码特征输入，和代码实现一一对应。三层机制分别对应输入端状态编码、交互端注意力约束、融合端门控响应，观测状态贯穿模型全程；输入维度采用附件 2 官方设定 74/35。




图 5.2 MRFN 缺失场景构造与数据流

5.3 训练方案与模型阶梯

训练方案为 MRFN 提供统一训练配置。本文设计 $B0 \rightarrow B1 \rightarrow B2 \rightarrow B3 \rightarrow MRFN$ 五级递进模型阶梯，用于逐级量化各机制的有效增益。前四级模型每级仅新增单一机制，用以独立验证对应模块效果。最终 MRFN 在 B3 基础上引入机制一与机制三两处缺失感知优化，模块的独立贡献将在 5.4 节通过消融实验完成归因分析。

训练方案。模型采用 AdamW 优化器，学习率 10^{-3} ，权重衰减 10^{-4} ，批大小设置为 32，最大训练轮次 40 轮，依据验证集损失执行早停，耐心值为 8 轮。实验采用三组随机种子重复训练，最终结果取均值保证稳定性。训练过程缺失样本按照 5.1 节的配比在线生成。配比设计遵循全覆盖原则，训练分布覆盖常规评测场景与极端缺失状态。联合缺失与整模态缺失样本用于覆盖边界输入状态，让模型具备重度缺失场景的训练经验。10

模型阶梯。为逐级验证各机制的独立增益，本文构建五级递进模型体系。B0 为基础基线模型，仅包含逐模态线性投影、内容位掩码池化、特征拼接与双头预测结构，不引入缺失状态建模。B1 增加独立模态编码，验证专属编码结构的增益效果。B2 替换为双向 GRU 时序建模，验证时序特征学习的有效性。B3 引入六方向可用性约束跨模态注意力，验证跨模态交互机制的增益。MRFN 在 B3 基础上完成两处优化，输入端采用缺失状态编码替代零填充策略，融合端增设可靠性门控结构，验证显式缺失感知机制的整体效果，两个模块的独立贡献由后续消融实验拆分。各级模型参数量与评测结果汇总于表 5.1，参数量范围为 81,284 至 416,839。

由表 5.1 可得到三点结论。第一，B1 相较 B0 的指标提升，印证独立模态编码能够有效优化特征表达。第二，B2、B3 的干净分类指标基本持平，但回归误差持续下降，说明时序建模与跨模态交互主要提升强度预测精度。第三，MRFN 相较 B3 取得最优的干净分类性能与最小的多场景退化幅度，同时参数量更低，综合性能更优。由于 B3 至 MRFN 同步更新两处模块，精细组件归因交由后续消融实验完成。本文所有阶梯结果与 31 类场景评测均采用测试集终评，模型早停、结构选型等全部决策均在验证集完成，严格规避数据泄露。模型阶梯的组织与三种子重复训练的性能分布分别见图 5.3 和图 5.4。

表 5.1 模型阶梯评估结果

模型	参数量	Acc	macro-F1	MAE	Pearson	$\mathcal{S}$	$\overline{D_S}$
B0	81,284	63.7%	60.0%	0.662	0.634	0.736	0.029
B1	93,764	65.7%	61.9%	0.644	0.653	0.749	0.035
B2	255,620	65.8%	61.0%	0.644	0.666	0.748	0.034
B3	429,380	65.0%	61.6%	0.631	0.665	0.748	0.035
MRFN	416,839	66.7%	62.5%	0.634	0.675	0.756	0.028

模型阶梯：五级机制递增 + 八轮预注册筛选




图 5.3 模型阶梯与预注册筛选示意

模型阶梯三种子性能分布 (valid; B0 为 test 单点对照)




图 5.4 模型阶梯三种子重复性能分布




图 5.5 缺失场景实验：(a) 退化曲线 (b) 热力图

表 5.2 缺失率-性能退化数值表

缺失模态 $\times$ 率	场景数	$\mathcal{S}$		$D_{\mathcal{S}}$ (相对 clean)	
		B3	MRFN	B3	MRFN
$t@10\%$	1	0.7280	0.7369	0.0272	0.0254
$t@20\%$	1	0.7158	0.7288	0.0434	0.0361
$t@40\%$	1	0.6820	0.7058	0.0885	0.0665
$t@60\%$	1	0.6233	0.6722	0.1671	0.1109
$t@80\%$	1	0.5565	0.6181	0.2563	0.1825
$a@10\%$	1	0.7476	0.7552	0.0009	0.0011
$a@20\%$	1	0.7487	0.7557	-0.0006	0.0005
$a@40\%$	1	0.7488	0.7547	-0.0007	0.0018
$a@60\%$	1	0.7497	0.7535	-0.0020	0.0034
$a@80\%$	1	0.7493	0.7512	-0.0014	0.0064
$v@10\%$	1	0.7480	0.7557	0.0003	0.0005
$v@20\%$	1	0.7489	0.7552	-0.0008	0.0012
$v@40\%$	1	0.7506	0.7544	-0.0031	0.0022
$v@60\%$	1	0.7497	0.7539	-0.0019	0.0029
$v@80\%$	1	0.7502	0.7538	-0.0026	0.0030
$ta@40\%$	1	0.6803	0.7071	0.0908	0.0648
$tv@40\%$	1	0.6808	0.7056	0.0902	0.0667
$av@40\%$	1	0.7505	0.7532	-0.0030	0.0038

5.4 鲁棒性评价与实验

鲁棒性评测聚焦于”模态局部缺失条件下模型能否稳定预测”这一题面核心要求。在缺失模态学习领域，相关方法从蒸馏 [12]、不确定性扩散 [13] 到代理驱动 [14] 形成了三条代表性技术路径；本文 MRFN 走的是”显式状态建模 + 门控信任”路径，与上述方法共享”用辅助信号增强缺失输入下预测”的核心思想，但在状态变量定义与训练目标上更为直接。

本次评测覆盖 31 个缺失场景、8 类缺失实例，共 248 次掩码测试，采用“效用——退化率——选型分”三级评价体系得到三条实验结论，完成 H4–H6 的检验。为统一不同量纲指标的对比与聚合，所有指标先映射至 $[0, 1]$ 区间的效用值。分类指标，包括准确率、macro-F1，直接作为效用；回归指标按 $U_{\text{MAE}} = \text{clip}(1 - \text{MAE}/6, 0, 1)$ 转换。常数 6 对应强度标注值域 $[-3, 3]$ 的完整区间，含义为平均误差等于值域全宽时效用归零；相关系数采用 $U_{\text{Pearson}} = (r_p + 1)/2$ ，将取值从 $[-1, 1]$ 映射到 $[0, 1]$ 。综合效用分 $\mathcal{S} = \frac{1}{2}U_{\text{cls}} + \frac{1}{2}U_{\text{reg}}$ ， U_{cls} 为两项分类指标均值， U_{reg} 为两项回归效用均值。缺失场景退化率定义为 $D_U = (U_{\text{clean}} - U_r) / \max(U_{\text{clean}}, \varepsilon)$ ； D_U 为负代表缺失输入下模型效用反而更高。

31 场景网格。评测基于固定掩码库下的 31 个场景开展：随机散布单模态 $\{t/a/v\} \times \{10, 20, 40, 60, 80\}\%$ ，共 15 个；随机散布双模态 $\{ta/tv/av\}@40\%$ ，共 3 个；连续块 $\{t/a/v\} \times \{\text{头}/\text{中}/\text{尾}/\text{随机}\}@40\%$ ，共 12 个；联合缺失 $av@40\%$ ，1 个。每个场景设置 8 个种子化掩码实例，总计 248 次掩码测试。汇总规则：先取单场景 8 个实例的均值作为场景指标，再对 31 个场景等权平均；31 场景均值 $\mathcal{S}$ 与平均退化 $\overline{D_{\mathcal{S}}}$ 均遵循该两步计算方式。全部场景满足 5.1 节的可用性下限，网格覆盖 1.3 节要求分析的三类影响因素。

选型分。模型选择的全部决策依据验证集上的选型分： $\mathcal{S}_{\text{sel}} = 0.50 \mathcal{S}_{\text{clean}} + 0.25 \mathcal{S}_{\text{text@40}} +$

$0.15 \mathcal{S}_{\text{text}@80} + 0.10 \mathcal{S}_{\text{jointAV}@40}$, 权重向文本缺失场景倾斜, 依据为开发阶段验证集同一掩码库观察得到的脆弱性结构, 即 §5.4 实验一。选型分仅用于 5.5 节的模型改进采纳, 不反向影响网格评测与结论。

结果与三条实验结论。缺失率—性能退化曲线与 31 场景热力图分别见图 5.5(a) 与 (b)。

实验一, 脆弱性结构: 性能退化几乎全部来自文本模态缺失。文本缺失率 40

缺失位置与缺失时长。题面需要独立考察两类因素: 缺失位置 $P \in \{\text{头, 中, 尾, 随机}\}$ 、缺失时长, 即连续块长度 ℓ 。位置维度包含 12 个 40

实验二, 架构组件的贡献, H6: MRFN 三个架构组件的消融结果见表 5.5。依次移除缺失状态编码、掩码注意力、门控模块, 31 场景均值 $\mathcal{S}$ 分别下降 0.012、0.015、0.017。结合 5.3 节的模型阶梯逐级增益, 逐级添加模块性能上升、移除模块性能下降, 两组证据共同支持 H6 成立。此前 5.3 节遗留的双组件归因在此完成拆分, 缺失状态编码与门控模块均带来正向收益。作为架构对照, 两种经典填充方案, B3 搭配零填充、B3 搭配前向填充, 31 场景均值均低于完整 MRFN, 降幅分别为 -0.019、-0.021。

实验三, 缺失增强训练的代价—收益, H4: 训练策略消融与 2×2 迁移实验见表 5.4, 二者是同一规律的两种分析角度。鲁棒性增益取缺失场景下两行差值, 缺失增强训练减去干净训练, 结果 $0.735 - 0.705 = +0.030$ 。干净代价取干净场景两行差值, 干净训练减去缺失增强训练, 结果 $0.736 - 0.756 = -0.020$ 。负值代表不存在干净性能损失, 缺失增强训练甚至小幅提升干净场景性能, 提升幅度 0.020。移除缺失增强训练后, 31 场景均值下降 0.030, 该消融结果和迁移表左上格数值保持一致。综上, H4 成立, 鲁棒性增益为正, 干净性能代价不为正。

图 5.5(b) 热力图可见, 退化集中在文本相关场景列。MRFN 整行颜色最浅, 平均退化 $\overline{D_S} = 0.028$, 在五级模型中最小; 相比 B3 的性能提升也集中于文本类场景。该结果与实验一的文本脆弱性结构、实验二消融结论保持一致。

门控响应, H5。门控曲线见图 5.6。 g_{text} 分箱均值随缺失率升高而降低, 从 10




图 5.6 门控信任随缺失率的响应

逐样本的门控—留一模态贡献秩相关在各模态上均为正 (文本 0.198、语音 0.033、视觉 0.077), 其中语音、视觉的关联较弱。按判据: 各模态响应方向一致且秩相关为正, H5

表 5.3 门控信任按缺失率分箱均值

缺失率档位	g_{text}	g_{audio}	g_{vision}	档内实例数
10%	0.6048	0.1570	0.2283	8
20%	0.6003	0.1561	0.2288	8
40%	0.5900	0.1541	0.2298	8
60%	0.5782	0.1521	0.2307	8
80%	0.5700	0.1498	0.2312	8
全档单调性	降 ($\Delta = 0.0348$)	降 ($\Delta = 0.0072$)	升 ($\Delta = 0.0029$)	—
Spearman (缺失率, g)	-1.00	-1.00	+1.00	—

判定成立，但样本级关联强度弱；该结果与第六章门控—贡献一致性的分析互补。

表 5.4 2×2 迁移表（同架构只变训练方式， $\mathcal{S}$ ）

训练方式 \ 测试	clean test	31 场景均值
clean 训练	0.736	0.705
缺失增强训练	0.756	0.735

表 5.5 组件消融与填充基线（ $\mathcal{S}$, Δ 相对完整 MRFN）

变体	参数量	clean $\mathcal{S}$	31 场景均值 $\mathcal{S}$	Δ
MRFN（完整）	416,839	0.756	0.735	—
去除缺失状态编码	413,447	0.739	0.723	-0.012
去除掩码注意力	416,839	0.741	0.719	-0.015
去除门控	432,772	0.733	0.718	-0.017
去除缺失增强训练	416,839	0.736	0.705	-0.030
B3 + zero 填充基线	429,380	0.737	0.716	-0.019
B3 + 前向填充基线	429,380	0.736	0.714	-0.021

5.5 模型改进与终评

八轮预注册筛选得到七轮负结果与一轮有效采纳结果。本节在预注册实验规范下明确正式模型 MRFN 与补充变体 MRFN+ 的主次定位，并在测试集上完成追加终评。

改进协议遵循预注册约束。测试集主表完成终评后立即冻结，所有迭代改进仅使用训练集与验证集数据。每轮改动提前登记全套验收门槛：选型分提升 $\geq +0.003$ 、干净准确率下降 ≤ 0.5 个百分点、干净 $\mathcal{S}$ 下降 ≤ 0.003 、文本 @80 退化改善 ≥ 0.015 、联合 @40 恶化 ≤ 0.005 、种子间波动不上升；任意条件不满足则本轮改动直接回滚。

本文 MRFN vs 三消融基线性能分布




图 5.7 四项消融变体的性能分布

改进轮次与负结果。本文共设置八轮迭代改进，前七轮均采用单点改动方案，具体主题见表 5.6，全部未能满足验收标准并按协议回滚， λ_r 保持 5.2 节设定的固定取值 1。从七轮负结果可归纳两条观察。第一，所有候选单点改动均体现出干净性能与文本鲁棒性之间稳定的权衡关系，不存在能够同步提升两项指标的方案。第二，共享缺失调度种子可将 S 的种子间标准差降至万分之一个百分点量级，说明训练阶段的缺失样本构造方式会显著影响不同种子的结果差异。这些负结果结合 5.4 节消融实验，共同刻画了模型可优化的性能边界。

表 5.6 前七轮改进候选与结果——验证集

轮次	改进主题	结果
1	鲁棒早停	回滚
2	逐样本缺失抽样	回滚
3	内容窗 GRU	回滚
4	层归一化门控	回滚
5	证据池化	回滚
6	回归损失权重减半 ($\lambda_r=0.5$)	回滚
7	BERT 解冻两层	回滚

基于上述七轮单点改进均未通过验收的结论，第八轮采用面向文本表征质量的组合式改进，同步调整三处设置：解冻编码器最后一层，设置微调学习率 5×10^{-5} ，可训练参数量为 7.09M；将训练混合 B 分量内文本样本的抽样权重加倍；把检查点筛选策略替换为选型分早停。微调阶段编码器实时重编码，不存在缓存污染问题。该组合方案在验证集上全部通过六项预设验收门槛：**选型分提升** +0.0225，高于 +0.003 的最低门槛；**干净准确率提升** 1.19 个百分点；**干净 S 提升** +0.0076；**文本 @80 场景退化** 由 0.175 降至 0.130，改善幅度 0.045，约为门槛的三倍；**联合 @40 场景退化指标** 为负，代表缺失场景下模型性能小幅

提升；种子间标准差减半。本轮性能增益来自三处改动的协同作用，本文不对各组件单独拆分归因；该组合方案依据预注册协议正式采纳为 **MRFN+**。

主次关系与追加终评。**MRFN 为测试集主表冻结正式模型**；MRFN+ 为验证集预注册筛选采纳的补充变体，仅用于附件 3 与附件 4 的最终推理。MRFN+ 在测试集上追加一次终评（表 5.7）：单模型三种子均值 **67.45%**、三种子集成 **68.64%**，同口径下相对主表 66.71% 分别**提升 0.74 与 1.93 个百分点**。MRFN+ 未做 31 场景评估、不构造鲁棒性曲线、不替换主表；其通过伴随鲁棒性条款约束，与前述权衡观察一致。

表 5.7 最终测试集结果

模型	评估批次	Acc	macro-F1	MAE	$\mathcal{S}$
MRFN	主表首次 test	66.71%	62.52%	0.634	0.756
MRFN+（单模型均值）	预注册追加 test	67.45%	62.80%	0.644	0.760
MRFN+（3-seed 集成）	预注册追加 test	68.64%	63.86%	0.614	0.769




图 5.8 MRFN+ 双输出性能与误差结构

5.6 预测与行为分析

附件 3 包含 30 条无标签样本，共计 131 个联合零行，单样本最高联合缺失率为 50

预测结果。全部 30 条样本均完成预测，推理采用 **MRFN + 三种子概率与回归集成**。输出文件记录每条样本的极性、强度以及校准置信度，相关结果随同附录 C 一并提供。置信度基于验证集 NLL 做温度校准 [15]，温度系数 $T = 1.2142$ 。经过校准，期望校准误差由 0.0424 下降至 0.0347，且 argmax 预测结果保持不变。样本预测分布为负 / 中 / 正 7/10/13。

输入侧缺失统计。30 条样本合计 605 个内容位，语音与视觉联合零行共 131 个，占比 21.7

行为分析，见图 5.9。分析围绕两项实验前预先登记的行为预期展开。第一，门控响应预期：当音视模态发生缺失时，模型应当将信任权重向文本模态转移，即 g_{text} 随音视缺

失率上升而增大。将样本划分为高、低缺失两组后，两组 g_{text} 均值分别为 0.616 和 0.638，Spearman 相关系数 = -0.195 ，并未观测到预期的单调权重重分配。该现象和 5.4 节实验一“音视缺失场景性能退化接近零”的结论可以相互印证。第二，仅文本趋同预期：若音视信息可舍弃，完整输入下的模型预测应当趋近仅文本输入的预测。实测整体预测一致率为 0.733，高缺失组一致率 0.600 低于低缺失组 0.867，该预期同样不成立。两项结果共同说明，模型对音视信息的利用程度虽然偏低，但并非完全弃用；权重分配也不会随音视缺失率平滑切换。此外，单种子与集成预测的极性一致比例在三个种子上依次为 0.767、0.767、0.800。困难样本清单按照音视平均缺失率降序、同缺失率下按校准置信度升序排序，选取前 5 条随同附录 C 交付。




图 5.9 附件 3 行为分析

图 5.9 将联合缺失率、 g_{text} 、text-only 一致率与预测极性分布并置；行为分析与 31 场景网格相互对照——网格给出受控合成场景下的规律，附件 3 给出真实缺失输入上的行为样例。

错误归因。两条结构性观察如下：其一，**Z0/Z1 两带的错误份额合计约 64% (MRFN) 与 68% (MRFN+)**——错误主体集中在弱带与中性带，强极性带 (Z2) 相对易判；MRFN+ 在 Z2 提升 3.2 个百分点的同时，Z0 略降 2.2 个百分点，呈现同一架构下”强带更准、弱带持平”的可重复观察——按 $|\hat{y}|$ 分区的准确率排序未变，错误归因结构未被推翻。其二，**标签的符号 oracle 准确率为 100%** (按 $\hat{y}$ 符号反推 cls 全中)，上限由特征侧弱情感分辨力决定，决策侧四种调整——阈值、类别权重、阈值兼权重、回归口径——对 Z0/Z1 准确率的

表 5.8 附件 3 行为分析关键指标

指标	全样本	高缺失半区	低缺失半区
样本数 n	30	15	15
平均联合缺失率	20.67%	—	—
单样本最高联合缺失率	50.0%	—	—
存在局部联合缺失样本数	27	—	—
音视平均缺失率 (g_{text} 均值)	—	0.6158	0.6384
g_{text} -音视缺失率 Spearman		-0.1955	
整体 text-only 一致率	0.7333	—	—
text-only 一致率 (按音视平均缺失率分半区)	—	0.6000	0.8667
预测极性分布 (负/中/正)		7 / 10 / 13	
校准温度 T		1.2142	
校准后期望校准误差 ECE		0.0347 (自 0.0424)	
argmax 不变 (校准前后)		30/30	
单种子间极性一致比例 (seed 1/2/3)		0.767 / 0.767 / 0.800	

改动均不超过 1 个百分点 (弱带主体未改变), 属系统性而非工程性瓶颈。诊断详情见 7.4 节错误归因层。数据按 $|\hat{y}|$ 分区列于表 5.9 (验证集 728 条, MRFN / MRFN+ 各三种子均值):

表 5.9 按 $|\hat{y}|$ 分区的准确率

带	定义	n	MRFN 准确率	MRFN+ 准确率
Z0: 中性	$ \hat{y} = 0$	184	0.480	0.458
Z1: 弱极性	$0 < \hat{y} \leq 0.5$	147	0.435	0.447
Z2: 强极性	$ \hat{y} > 0.5$	397	0.751	0.783

6 问题三：可解释情感预测模型的建立与求解

仅给出极性与强度的预测值无法独立复核判断依据。本章在冻结的 **MRFN+** 之上叠加反事实解释框架：模态级贡献由精确 **Shapley** 值度量，位置级归因由积分梯度给出，两套反事实参照使证据可回溯至原词与物理时间；解释可信性按运行前冻结的 **A-F** 六项判据验证。

6.1 解释任务的形式化

问题三要求在预测结果之外给出判断依据——以可量化、可复核的方式说明本次判断主要依据了哪些模态、哪些时间位置的输入。每条样本的解释输出包含五要素：极性/强度、模态贡献 φ_m 、主要参考模态、关键证据与物理时间区间，对应完备性、保真性、一致性与可回溯性四项性质；本节同时明确两套反事实参照的分工：**Shapley** 使用联盟级 $v(\emptyset)$ ($\text{avail} \equiv 0$)，**IG** 使用条件特征基线 ($\text{avail} \equiv 0$ ；缺失架构在全部模态未观测时梯度归零)。

网络结构与输出规格。解释框架在冻结 **MRFN+** 之上叠加归因层，**不引入新预测网络、不重新训练、也不新增可训练参数**。归因层对 **MRFN+** 输出执行两次解释计算，即 **8 联盟全枚举 (Shapley)** 与 **50 位网格上中点 64 步积分 (IG)**，二者共享同一预测器与同一输入接口。解释对象为冻结 **MRFN+** 集成（三种子概率与回归平均），每条样本输出**五要素**：极性、强度、各模态带符号贡献 φ_m 、主要参考模态、关键证据及其物理时间区间 $[t_s, t_e)$ 。

模态级贡献由精确 **Shapley** 值度量 [16, pp. 307–317]，其联盟级 $v(\emptyset)$ 对应三模态全部未观测的状态；位置级归因由积分梯度度量 [17]，其条件特征基线保持自然观测、特征取缺失参照值。**IG** 不取联盟级参照的原因是结构性的：缺失感知架构在全部模态未观测时阻断一切特征梯度，位置归因恒为零。两套参照的构造规则与 5.4 节合成缺失算子保持一致，使干预输入的状态与训练所见状态可对应。

H7 验证状态。**H7 判据**要求归因保真度优于无缺失训练对照，但所需对照实验未执行，故如实报告：**H7** 的预注册判据未完成验证；现有证据仅支持分布覆盖性，即除空联盟外，**Shapley** 的 7 个联盟输入与 **IG** 的基线输入均落在问题二训练缺失生成机制的组合空间之内。

四项性质目标。**完备性** ($\sum_m \varphi_m = v(N) - v(\emptyset)$ 精确成立，6.2 节)、**保真性** (按归因序删除的预测偏移显著大于随机序，6.4 节)、**一致性** (门控信任与实际贡献趋势一致，6.4 节)、**可回溯性** (每个归因位可映射到证据与物理时间，6.3、6.5 节)。

6.2 模态级 Shapley 模型

模态作用程度以合作博弈的精确 **Shapley** 值度量——**8 联盟全枚举**，权重按精确分数 $\frac{|S|!(3-|S|-1)!}{3!}$ 计算。本节依次给出 **Shapley** 公式、联盟输入构造与三项公理校验：哑玩家公理由样本 #13 视觉整模态自然缺失的真实数据实证 ($\varphi_v^{\text{cls}} \equiv [0, 0, 0]$ 、 $\varphi_v^r = 0$)；附件 4 与附件 2 测试集 5 条重合样本的锚点自检 5/5 预测一致。

联盟值的构造。记模态全集 $N = \{\text{文本, 语音, 视觉}\}$ ，共 8 个联盟。对联盟 $S \subseteq N$ ，联盟值 $v(S)$ 通过对补集模态执行合成缺失得到： S 内模态保持自然观测， S 外模态的内容

位全部抹除——文本在编码前将相应子词替换为 [MASK] (3.1 节规则)，语音/视觉置零； $v(\emptyset)$ 为三模态全部未观测的状态，此时输入非全零——由 5.2 节机制一，位置嵌入与缺失嵌入仍构成输入。构造规则与 5.4 节合成缺失算子一致。分类与强度双输出分别取联盟值 $v^{cls}(S) \in \Delta^3$ ，预测概率向量与 $v^r(S) \in [-3, 3]$ ，均为三种子均值口径。

精确 Shapley 值。三模态的全部联盟仅 8 个，可精确枚举：

$$\varphi_m = \sum_{S \subseteq N \setminus \{m\}} \frac{|S|!(3 - |S| - 1)!}{3!} [v(S \cup \{m\}) - v(S)], \quad (6.1)$$

权重以精确分数 (1/3, 1/6, 1/3) 参与计算，避免浮点权重误差；分类输出逐类计算带符号 $\varphi_m^{cls} \in \mathbb{R}^3$ ，强度输出为标量 φ_m^r 。主要参考模态取

$$m^* = \arg \max_m |[\varphi_m^{cls}]_{\hat{y}}|, \quad (6.2)$$

其中 $[\cdot]_{\hat{y}}$ 为预测类 $\hat{y}$ 对应的分量。

公理校验（表 6.3）。**效率公理精确成立**（残差见 §6.1）；**哑玩家公理由样本 #13 视觉整模态自然缺失给出真实数据实证**： $\phi_v \equiv 0$ 时该模态输入嵌入、证据可用性、覆盖率均逐位相同， $\varphi_v \equiv 0$ 严格成立。附件 4 与附件 2 测试集 5 条重合样本的锚点自检 5/5 一致（仅作内部自检、不参与选择决策）。

贡献分布（表 6.2、图 6.1）。**20 条样本的主导模态分布为文本 18、视觉 2、语音 0**，与问题二“文本主导”的实验结论一致；高置信样本（校准置信度 > 0.97 ）呈大 φ_{text} （预测类 0.55–0.68）配微小的 φ_a, φ_v 。方向性信息同样可读：如样本 #04（预测负类）的 $\varphi_{\text{text}} = (+0.36, -0.08, -0.28)$ ，文本同时支持负类并抑制正类——带符号贡献在解释卡中直呈。图中左侧的带符号贡献堆叠显示文本占绝对主体、#13 的视觉贡献恒零（哑玩家实证）；右侧 TOP-8 原词证据对应高贡献样本，词级证据回溯经问题一网格完成（20 条样本全部建立位置——原词映射）。三模态贡献的整体分布密度见图 6.2。

表 6.1 三模态 Shapley 贡献分位数

模态	度量	min	Q25	median	Q75	max	跨度
文本	$ \varphi_{\text{text}} $	0.050	0.185	0.401	0.531	0.682	0.632
语音	$ \varphi_{\text{audio}} $	0.008	0.020	0.029	0.045	0.157	0.149
视觉	$ \varphi_{\text{vision}} $	0.000	0.021	0.034	0.076	0.199	0.199
文本	$\varphi_{\text{text}}^{[\hat{y}]}$ （预测类）	-0.097	0.185	0.401	0.531	0.682	0.779
语音	$\varphi_{\text{audio}}^{[\hat{y}]}$	-0.157	-0.023	0.006	0.034	0.119	0.276
视觉	$\varphi_{\text{vision}}^{[\hat{y}]}$	-0.123	-0.001	0.023	0.036	0.199	0.322

6.3 位置级积分梯度模型

位置级重要性以积分梯度 (IG) 度量。本节将 IG 形式化为四个要点：可微层级、三基线对照 (missing/zero/mean)、词级质量守恒聚合与架构级零归因阻断。验证结论为：全 40




图 6.1 模态贡献与词级证据回溯

三模态 Shapley 贡献分布 (附件4, 20 条样本, 预测类带符号)




图 6.2 三模态 Shapley 贡献密度

表 6.2 模态 Shapley 方向统计

模态	$\varphi > 0$	$\varphi < 0$	主导
text	19	1	18
audio	10	10	0
vision	13	7	2

表 6.3 Shapley 完备性检验

输出头	最大残差	门槛	通过
分类	3.0×10^{-8}	1×10^{-5}	20/20
强度	4.4×10^{-16}	1×10^{-5}	20/20

项 IG 检验通过、最大相对误差 0.62%；零泄漏性质在 3 基线 $\times$ 2 输出 $\times$ 3 模态 $\times$ 逐种子的全部组合下成立（结构位与不可用位归因逐位精确为零）。

可微层级与基线。文本的积分梯度路径定义在编码器输出嵌入层 $E \in \mathbb{R}^{50 \times 768}$ 上（各种子使用其微调编码器、冻结求值），插值路径为

$$E(\tau) = E' + \tau(E - E'), \quad \tau \in [0, 1], \quad (6.3)$$

绝不对离散子词编号做数值插值；语音/视觉路径定义在标准化连续特征上。统一公式中的 x, x' 按模态取不同对象：文本取 $x = E, x' = E'$ （输出嵌入及其基线），语音/视觉取 x 为标准化特征、 x' 为对应基线值。可用掩码固定为自然观测（可用性判定含阈值切分、不可微，故不做掩码插值）。基线取 6.1 节分名的条件特征基线：文本为全部子词 [MASK] 重编码所得嵌入，语音/视觉取缺失参照值；敏感性检验另设零向量与训练均值两种基线。

积分梯度与数值求积。积分梯度作用于三种子集成的预测函数 F ：分类目标取集成预测类的 logit，集成为三种子模型输出的均值函数，故其梯度等于各种子梯度之均值——与逐种子计算后平均在数学上等价；完备性检验的对象即该集成函数。与 6.1 节的“两套参照分名”相应，此处区分两套目标函数：模态级贡献与删除/插入检验作用于概率函数（三种子 softmax 概率的均值），位置级积分梯度作用于集成 logit 分数函数（积分梯度的 Score 约定，完备性对分数成立）；二者解释同一冻结预测器的不同侧面，口径分列、不混用。位置 j 的归因定义为

$$\text{IG}_j = (x_j - x'_j) \int_0^1 \frac{\partial F}{\partial x_j} (x' + \tau(x - x')) d\tau, \quad (6.4)$$

数值上采用 64 步中点 Riemann 求积（ $\tau_k = (k - 0.5)/64$ ）；强度目标取强度输出。

精度检验（表 6.4）。完备性残差按逐样本、逐输出检验： $|\sum_j \text{IG}_j - \Delta F|$ 不超过 $\max(0.05|\Delta F|, 10^{-3})$ ，在 20 条样本 $\times$ 2 类输出共 **40 项检验上全部通过，最大相对误差 0.62%**。求积规则经消融确定：32 步右端点在 6 个样本上超出阈值（最差 11.1%），64 步中点将其压至 0.62%。

基线敏感性。该项检验以三对基线在内容位上逐样本计算排序 Spearman：**各对、各模态的均值均 ≥ 0.96** ，单样本最低 0.76（缺失参照与零向量的视觉通道）。语音/视觉的缺失参照与训练均值在标准化空间数值重合，不构成有效对照；实质性对比为文本通道三基线之间、以及缺失参照与零向量之间的对比，均值亦在 0.96 以上。

词级聚合。位置归因经问题一的映射聚合到原词：位置—原词映射在全部 20 条样本（含 2 条截断样本）上建立，词内均匀权 $\alpha_j = 1/n_w$ 提供归属与权重；词级归因取质量守恒

求和

$$A_w = \sum_{j \in w} \text{IG}_j, \tag{6.5}$$

保证词级完备性 $\sum_w A_w = \sum_j \text{IG}_j$ ；被 50 位网格截断的整词标记为未覆盖（共 22 词），不生成证据。

零泄漏性质。结构位（CLS/SEP/填充位）与不可用位的归因，在全部”3 基线 × 2 输出 × 3 模态 × 逐种子”组合下恒为零（逐位精确为 0）。这由 5.2 节机制保证：选择运算使不可用位不进入计算图、值侧屏蔽使其不作为证据，梯度不经由这些位置。因此，**零归因是架构级性质而非数值巧合**：在本章的 IG 归因路径与 5.2 节架构下，缺失证据不进入位置归因。

图 6.3 中，三种基线下的归因排序高度一致（与敏感性数值相符），积分完备性残差集中于远低于阈值的区间；其中关于 IG-LOO 一致性的对比——音视局部干预强一致、文本未达门槛——属于保真度检验范畴，在 6.4 节展开。TOP-20 关键词的词级 IG 贡献见

表 6.4 IG 验证结果

验证项	实测	门槛/口径	判定
积分误差（64 步中点）	40/40	max rel 0.62%	通过
阻断位泄漏	max IG =0（逐位精确）	3 基线 × 2 输出 × 3 模态	通过
#13 哑玩家	max IG _v =0（逐位精确）	$\varphi_v \equiv 0$	通过
问题一网格映射	20/20	截断词 22 个未覆盖	通过
基线排序敏感性	$\bar{\rho}_{min}=0.961$	≥ 0.96	通过
稳定性 t/a/v	0.997/0.995/0.984	text ≥ 0.6	通过




图 6.3 IG 验证与 F 项诊断

图 6.4。




图 6.4 TOP-20 关键词 IG 贡献

6.4 解释可信性验证

本节以运行前冻结的六项保真度检验核验解释可信性：**A** 删除优越性、**B** 插入优越性、**C** Comprehensiveness/Sufficiency、**D** 随机化坍塌、**E** 扰动稳定性、**F** IG-LOO 一致性。综合结果为前五项通过、F 项未通过并给出结构性诊断——**A 19/20 胜 (mean AOPC 0.166)**、**B 20/20 胜 (mean Δ AUC 0.129)**、**C compr = 0.306 > |suff| = 0.098**、**D 各模态中位 Spearman ≤ 0.267** 、**E text 0.997/audio 0.995/vision 0.984**；F 项 text 单点 LOO 未达门槛 (**0.170 < 0.3**)，三步结构性诊断给出机制解释 (BERT [MASK] 重编码属非局部干预，与 a/v 局部干预 $\rho_{\text{abs}} = 0.74/0.73$ 形成对照)，H8 由此落定为**部分成立**。本节末段以 $g\text{-}\varphi$ 一致性分析 (验证集全量 728 条，text Spearman **0.716**，argmax 一致率 **90.7%**) 作为补充证据。

判据定义。删除/插入证据序为三模态可用位按 $|IG|$ 跨模态合并降序 (零泄漏性质保证不可用位不进入)；删除自自然观测起逐位执行问题二的抹除算子，插入自条件特征基线态起逐位恢复，对照为 5 组种子化随机序。**A**——删除优越性 (AOPC)；**B**——插入优越性 (Δ AUC)；**C**——compr/suff@0.2 (评价思想参考 ERASER[18])；**D**——权重随机化坍塌 (重置预测头后排序相关显著降低)；**E**——5% 噪声下 IG 排序 Spearman；**F**——IG-LOO 全秩 Spearman 及 TOP-20% 重合率。

检验结果 (表 6.5、图 6.5)。**A-E 通过**：**A**——AOPC 均值 0.166、19/20 胜 (唯一例外 #19, -0.08)；**B**—— Δ AUC 均值 0.129、20/20 胜；**C**——compr@0.2 均值 **0.306 对 |suff| 0.098**；**D**——各模态中位 ≤ 0.267 ；**E**——文本 mean ρ **0.997** (音/视 0.995/0.984)。

F 项未通过。文本通道全秩 Spearman **0.170**，低于专项门槛 0.3，如实报告、不移动门槛。诊断三步：其一，同输入重复计算差为零，排除计算误差；其二，音/视删除是局部干预，IG-LOO 一致性 $\rho = 0.739/0.732$ 、TOP-20% 重合 76%/71%——IG 在局部干预语义下

忠实；其三，文本删除需 [MASK] 重编码、属非局部干预（掩码推断即 BERT 预训练目标），故 LOO 在文本通道近似度量”上下文可推断性”而非”嵌入敏感度”（与 IG 属不同反事实， $|\Delta p|$ 秩相关 0.213、TOP-20% 重合仅 29%）。

方法边界。IG 的参照（条件特征基线）与删除/插入的干预（抹除算子）分属两条路径：A/B/C 证明的是操作性保真度——按 IG 排序选出的证据在实际缺失干预下确为关键证据——而非同路径的积分验证；单点文本 LOO 则受非局部干预限制。二者在文中分开表述，不相互替代。

H8 部分成立。位置归因沿映射链回溯成立；局部干预下归因排序与删除响应秩一致成立（音/视 $\rho \approx 0.73$ ）；文本 IG-LOO 未达专项门槛（0.170 对 0.3），语义边界已由上述诊断界定，未达标部分已给出机制解释。




图 6.5 删除/插入保真度曲线

表 6.5 解释保真度六项检验结果

门槛	实测	预注册规则	判定
A 删除	0.166（胜 19/20）	均值 >0 且 $\geq 15/20$	通过
B 插入	0.129（胜 20/20）	均值 >0 且 $\geq 15/20$	通过
C 全面/充分	compr=0.306， suff =0.098	compr>0， suff <compr	通过
D 随机化坍塌	median ρ max 0.267	≤ 0.3	通过
E 稳定性	0.997	≥ 0.6	通过
(text)			
F text IG- LOO	0.170	≥ 0.3	未通过

门控—贡献一致性。门控 g_m 是融合层的信任权重， φ_m 是对预测输出的反事实贡献，二者含义不同，此处验证的是趋势一致性而非等同性。在附件 2 验证集全量 728 条样本上，对每条样本同时计算三种子均值口径的 g_m 与 φ_m （取预测类分量的绝对值）：**文本通道 Pearson/Spearman 为 0.711/0.716，语音 0.186/0.106、视觉 0.228/0.213 呈弱正相关，argmax**

一致率 **90.7%**，逐样本散点见图 6.6。音/视通道相关较弱（0.11–0.23）且贡献量级微小（6.2 节分布），本文不对二者建立解释性关联；该结果与 5.4 节门控响应检验互证——前者看”信任—贡献”的对应，后者看”信任—缺失”的响应。从图中可以看出，文本通道的点云随贡献增大整体上移，音视通道集中于低信任、低贡献区域——散点形态与分模态数值（0.72 对 0.11–0.21）一致。




图 6.6 门控—贡献一致性散点

门控—贡献一致性的逐模态 Pearson 与 Spearman 数值见表 6.6。

表 6.6 门控-贡献一致性

模态	cls Pearson	cls Spearman	reg Pearson	reg Spearman
文本	0.711	0.716	0.644	0.596
语音	0.186	0.106	0.166	0.134
视觉	0.228	0.213	0.253	0.246

6.5 解释结果与分析

附件 4 从预测分布、主导模态、证据覆盖与解释卡片四个维度呈现模型解释结果，不做任何精度评价。统计结果显示：**样本预测分布为正向 10 条、负向 7 条、中性 3 条；主导模态以文本为主共 18 条、视觉 2 条、语音 0 条。**所有解释证据依托问题一建立的映射体系，回溯至原始素材的物理时间区间。

证据回溯链。本文构建完整证据回溯链路：模型位置 j $\xrightarrow{\text{问题一网格}}$ 原始词项（词归属 κ ） $\xrightarrow{\text{CTC 强制对齐}}$ 物理时间区间 $[t_s, t_e)$ 。由于附件 4 样本与问题一的 100 条源样本无重叠，本文针对 20 条视频样本重新生成对齐资源，全部通过词—子词映射与 50 位网格构造校验。其中 9 条样本对齐完全无误差；存在少量对齐瑕疵的样本，其词级时间区间按照 4.4 节插值规则补全，对齐状态逐行记录于证据明细表。最终 60 条定位证据中，57 条来自精确对齐、3 条来自插值补全，不存在无法核验的无效证据。

置信度校准。所有样本统一采用问题二验证集拟合的温度系数 $T = 1.2142$ 执行概率校准，校准前后样本预测类别完全一致，实现 20/20 不变性。

全量证据结果。在全部 20 条样本中，按跨模态 $|IG|$ 排序的全局 TOP-3 核心证据均来自文本模态，该规律与 §6.2 模态贡献分布、问题二实验结论相互印证。逐模态 TOP-1 证据明细表完整输出文本原词及对应时间区间、语音与视觉证据的有效时间区间，并对时间中点渲染关键帧（共 19 帧）；其中样本 #13 存在视觉模态全程自然缺失，无视觉证据输出。由于语音、视觉特征无明确语义词典，音、视证据仅保留可核验的时间区间信息，不做主观语义描述。带符号的全量模态贡献分布结果见图 C.1。

解释卡片示例（图 6.7）。本文选取三类典型样本展示可视化解释结果：#09 为文本主导的强负向样本、#14 为少数视觉主导样本（20 条中仅 2 例）、#13 为视觉模态完全缺失样本（ $\varphi_v \equiv 0$ ），仅依托文本与语音模态完成预测与解释。解释卡片左右分区对应：左侧展示预测结果与各模态量化贡献，右侧展示 TOP-5 词级核心证据与对应物理时间区间，实现预测依据的完整可回溯。



图 6.7 解释卡三例

7 模型评价

各问指标均引用前文结果，已在前文验证的结论不再重复证明。本章从模型优点、三问联合验证、灵敏度与稳定性以及局限与改进四个方面对本文模型进行总结。

7.1 模型优点

综合三部分实验，本文方法的主要特点体现在表示基础、训练评测同源、解释公理化和过程可溯源四个方面。

1. 三个问题共用问题一建立的统一时序坐标系，其中包括序列位置体系、观测状态定义和位置—物理时间映射，并将“特征零值不自动等于缺失”作为贯穿全文的基本前提（3.1 节）。该体系经过四类验收指标检验（4.5 节），使训练、评测与解释均建立在统一的位置语义基础上。
2. 缺失感知训练与评测采用统一的缺失构造规则，并为问题三的反事实干预提供状态可对应的构造（5.4、6.1 节）。缺失状态作为显式输入参与编码、注意力和门控三个环节，其代价与收益通过迁移对照和消融实验进行验证，H4、H6 成立。四项消融变体的性能分布如图 5.7 所示。
3. 解释方法同时考虑模态级和位置级贡献，其中模态级贡献采用 8 组模态子集精确 Shapley 值进行度量，位置级归因采用积分梯度进行度量，并对效率公理、完备性和零泄漏等性质进行了检验（6.2、6.3 节）。解释可信性采用运行前冻结的判据进行检验，对于未通过的项目如实保留结果（6.4 节）。
4. 实验过程遵循统一的可溯源纪律，验收门槛在实验运行前冻结，未通过的项目如实呈现，包括 F 项、七轮改进回滚以及 H7 判据缺位等情况。关键产物均通过清单与指纹进行登记（见第二章），全部实测结果均可追溯至冻结产物，具备可复现性。

7.2 三问联合验证

本节将三个问题得到的证据链放在同一坐标下进行联合分析，考察融合层的信任分配（门控 g_m ）、输入的判别信息（删除干预下的性能变化与错误分区结构）以及解释层的实际贡献（ φ_m ）是否指向一致的结构。由于三者的度量对象不同，本文仅进行关系分析，不以其中任一结果证明另一结果。

三条证据链均指向文本模态具有较高的作用：一是文本缺失造成的性能退化显著高于语音和视觉缺失，判别信息集中于文本（5.4 节实验一）；二是模态贡献分布中有 18/20 的样本由文本主导（6.2 节）；三是主通道的门控—贡献 Spearman 相关系数为 0.716，argmax 一致率为 90.7%（6.4 节），且门控对文本缺失率的响应方向符合 H5。与此同时，本文也保留了相应边界：音频和视觉通道的门控—贡献相关性较弱，为 0.11–0.23；文本单点删除与 IG 属于不同的反事实语义（6.4 节 F 项诊断），“贡献”的两种度量在文本模态上并不完全重合；此外，文本主导并不等同于文本充分，弱极性带仍承载错误主体（7.4 节），信息量一侧限制了三条证据链能够共同达到的上限。

7.3 灵敏度与稳定性分析

本节仅汇总已有实测结果，不新增实验。结果表明，解释结果对基线选择具有较高稳定性，三组基线下的归因排序 Spearman 相关系数均不低于 0.96；在加入 5% 噪声后，归因排序 Spearman 相关系数仍达到 0.997。模型输出本身的种子间标准差低至万分之一个百分点量级，阶梯与终评结果均采用三种子均值口径。

需要指出的是，本文尚未对冻结超参数 λ_r 和 T 开展扫描式敏感性分析。

7.4 局限与错误归因

本文从表示、预测、解释和实验覆盖四个层面对模型局限进行总结，并对错误归因进行结构性分析，相关结论均回指正文，不新增断言。

在表示方面，H1、H3 已在机器证据层面成立，但仍待人工签核落定（4.5 节）；当前特征缺少维名字典，语义解释只能达到时间区间级；同时，对齐输出质量依赖素材，对于低置信失败只能采用插值放行（4.4 节）。

在预测与错误归因方面，干净性能与文本鲁棒性之间存在稳定权衡，MRFN+ 是八轮候选中唯一通过全部门槛的组合，但尚未突破这一权衡，且未完成 31 场景评估（5.5 节）。关于错误归因，包括按 $|q|$ 分区的准确率、MRFN+ 重演一致性以及决策侧四种手段的上限，其完整分析见 §5.6 节末段。MRFN+ 双输出性能与误差结构如图 5.8 所示。此外，本节补充两点延伸观察：弱极性样本中 37% 被判为中性；MRFN+ 集成存在双输出误差结构，其中真中性样本仅有 84/184 判对，强度预测向零收缩，集成口径 MAE 为 0.575、Pearson 为 0.680。上述两项观察共同表明，误差主要来源于极性边界与弱情感区段，而非缺失处理。

在解释方面，主要存在五条边界：附件 4 无标签，因此相关结果不作精度声明；文本单点 LOO 与 IG 属于不同的反事实语义，H8 仅部分成立；H7 判据尚未完成验证，目前仅有分布覆盖性论证；音频和视觉证据的语义解释止于时间区间级；证据时间定位与原始素材的对应已在 §4.5 节给出逐样本核验（详见交付包 9 张回放图与签核单）。其中，前两条对全文结论的约束最强。

在实验覆盖方面，本文尚未开展超参数扫描式敏感性分析（7.3 节），H7 对照实验尚未完成（6.1 节），同时三模态同时全缺失的情况被排除在评测网格之外（5.4 节）。

针对上述局限，后续工作可以从三个方面进一步开展：首先，完成人工签核与 H7 对照实验；其次，针对弱极性带进一步增强文本表示的判别信息；最后，发展适用于局部干预语义的文本归因方法。在推广方面，与本文结构对应性较强的应用场景是医学时序监测，其中多通道异构采样可对应统一坐标与双域设计，传感器脱落与伪影可对应“零值不等于缺失”的观测状态分离，临床决策可追溯则可对应证据回溯链。迁移到该场景后，标签结构与判定门槛需要依据临床规范重新建立，解释方法的临床可用性也需要另行验证。

参考文献

- [1] Shengyin Zhang, Yanci Yang, Chen Chen, Xinyu Liu, Tianyi Zhang, and Peng Lv. Deep learning-based multimodal emotion recognition from audio, visual, and text modalities: A systematic review of recent advancements and future prospects. Expert Systems with Applications, 237:121692, 2024.
- [2] Amir Zadeh, Paul Pu Liang, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, pages 2207–2214, 2018.
- [3] Amir Zadeh, Minghai Chen, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. Tensor fusion network for multimodal sentiment analysis. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 1103–1114, 2017.
- [4] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of NAACL-HLT, pages 4171–4186, 2019.
- [5] Florian Eyben, Klaus R. Scherer, Björn W. Schuller, Johan Sundberg, Elisabeth André, Carlos Busso, Mark W. Moore, and Shrikanth Narayanan. The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for voice research and affective computing. IEEE Transactions on Affective Computing, 7(2):190–202, 2016.
- [6] Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. In Proceedings of the 23rd International Conference on Machine Learning, pages 369–376, 2006.
- [7] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations. In Advances in Neural Information Processing Systems, pages 12449–12460, 2020.
- [8] Jin Hyun Cheong, Eshin Jolly, Tianmin Xie, et al. Py-Feat: Python facial expression analysis toolbox. Affective Science, 4:771–781, 2023.
- [9] Zitai Yang and Muzhi Li. Factorize, reconstruct, enhance: A unified framework for multimodal sentiment analysis. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2026.
- [10] Sijie Mai and Song Han. Learning invariant modality representation for robust multimodal learning from a causal inference perspective. In Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (ACL), 2026.
- [11] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Advances in Neural Information Processing Systems, pages 5998–6008, 2017.

- [12] Yuan Zhuang, Ming Liu, Wei Bai, and Hongxia Chen. CMAD: Correlation-aware and modalities-aware distillation for multimodal sentiment analysis with missing modalities. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2025.
- [13] Xiangyu Qiu, Yuhong Fang, Qianyi Zhou, and Qiang Hu. Beyond missing modalities: Hypergraph conditioned diffusion for uncertainty-aware multimodal emotion recognition. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2026.
- [14] Anqi Zhu, Ming Hu, Xinyu Wang, and Feng Liu. Proxy-driven robust multimodal sentiment analysis with incomplete data. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL), 2025.
- [15] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In Proceedings of the 34th International Conference on Machine Learning, pages 1321–1330, 2017.
- [16] Lloyd S. Shapley. A value for n-person games. In Contributions to the Theory of Games II, pages 307–317. Princeton University Press, Princeton, 1953.
- [17] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. Axiomatic attribution for deep networks. In Proceedings of the 34th International Conference on Machine Learning, pages 3319–3328, 2017.
- [18] Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher, and Byron C. Wallace. ERASER: A benchmark to evaluate rationalized NLP models. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 4443–4458, 2020.
- [19] OpenAI. GPT-5.6: 大型语言模型. <https://openai.com/>, 2026.
- [20] 智谱 AI. GLM-5.3: 双语对话大模型. <https://www.zhipuai.cn/>, 2026.
- [21] 上海稀宇科技有限公司. MiniMax3: 大语言模型. <https://api.minimax.chat/>, 2026.

附录 A 环境与复现

A.1 运行环境

全部版本号取自问题一数据契约 (p1.v2) 的冻结记录，为本文环境描述的唯一口径：

组件	版本：冻结值
Python	3.10
PyTorch / torchaudio	2.11.0 / 2.11.0
transformers	5.17.0
openSMILE	2.6.0
Py-Feat	0.6.1
imageio-ffmpeg / ffmpeg	0.6.0 / 7.0.2 (static)

A.2 模型与权重指纹

BERT: bert-base-uncased, revision 86b5e09 (权重 SHA-256 前缀 68d45e234eb4); 对齐声学模型: torchaudio WAV2VEC2_ASR_BASE_960H; MRFN+ 三种子检查点 SHA-256 前 12 位: 54c56d1fd45d / 7553aa96090f / b491d4f1e5fd (第六章归因与附件 3、附件 4 推理使用同一权重族); 测试集终评冻结于 commit 03eece9 (唯一一次评估, 此后冻结)。

A.3 数据契约

问题一特征契约为 p1.v2: 100 条样本、schema 违例 0, 含结构掩码、逐样本映射表与三个核心 artifact 的 SHA-256; 评测掩码库使用独立种子 (2026), 每场景 8 个实例, 与训练种子分离; 改进轮次的缺失调度种子独立登记, 掩码库全量重生成经逐位一致性校验。

A.4 复现步骤

按下列入口脚本顺序即可复现全部结果 (参数与运行说明随交付包):

```
run_p1.py, check_p1_acceptance.py, generate_p1_replay.py #
    问题一
generate_p2_mask_library.py, train_p2_ladder.py,
    train_p2_mrfn.py,
train_p2_bft.py, eval_p2_test.py, eval_p2_test_second.py,
    predict_fj3.py # 问题二
check_p3_m1.py..check_p3_m5.py, gen_p3_m6_alignment.py,
    predict_fj4.py # 问题三
```

附录 B 关键代码

```
# 参考文献[19--21]
# ---- 关键参数 (与正文 S5.1 一致) ----
# MASK_LIBRARY_SEED=2026 掩码库种子; 与训练种子分离
# K_INSTANCES=8          每场景 8 个种子化实例 (31×8=248 次)
# MIN_AVAIL_RATE=0.20    任一模式可用率下限, 规避三模式全缺失
# JOINT_RATE=0.40        联合缺失场景固定 40% 缺失率
# ---- 契约 ----
# b_m 只允许落在 o_m=1 的位置; special/padding 永不抹除; a = o*(1-b)
# 机制: mcar=均匀随机位; block=单连续块(位置 head/mid/tail/random);
#      joint=a+v 同位联合(段长~附件3实测分布); full=整模式
# 附件3 实测段长分布: {1: 0.7474, 2: 0.1684, 3: 0.0421, 4: 0.0421}
# 可复现: rng = default_rng([mask_library_seed, combo_idx,
#                             k]), 逐位复现
MASK_LIBRARY_SEED = 2026; K_INSTANCES = 8
MIN_AVAIL_RATE = 0.20
JOINT_RATE = 0.40
```

```
# 参考文献[19--21]
# ---- 关键超参数 (与正文 S5.2 一致) ----
# D_MODEL=128          模式表示维度
# N_HEADS=2, HEAD_DIM=64 注意力头数 / 工作维 (多头=并行扩展)
# WINDOW_RADIUS=3       内容窗半径, 仅跨位置 ±3 交换
# GATE_HIDDEN=64        门控 MLP 隐层维
# ---- 机制一: 缺失状态编码 ----
def forward(self, x, a, mod_idx): # 缺失状态编码: 选择运算
    x_eff = torch.where(a_b[..., None], x, zeros) # a=0
    位不进计算图
    return self.pos + x_eff + (~a_b).to(x.dtype)[..., None] *
        self.miss[mod_idx]
# ---- 机制二: 可用性约束跨模式注意力 ----
scores = scores.masked_fill(~avail[:, None, None, :],
    float("-inf")) # K 侧屏蔽
v = torch.where(avail[:, None, :, None], v, zeros) # V 侧置零
# ---- 机制三: 可靠性门控融合 ----
empty = ~avail.any(dim=1) # 证据全不可用 -> 显式置零分支
g = softmax(self.gate(cat(list(h_tilde.values()) + [cov],
    dim=-1))) # 门控 (cov=覆盖率协变量)
```

```
# 参考文献[19--21]
```

```

# ---- 关键参数 (与正文 §6.2/§6.3 一致) ----
# N_COALITIONS=8      模态全集大小=3, 2^3-空=8 联盟
# SHAPLEY_WEIGHTS={0:1/3, 1:1/6, 2:1/3} 精确分数权重
# N_IG_STEPS=64      积分梯度路径步数 (中点 Riemann)
# BASELINE=cond_feature 条件特征基线 (avail == o)
# ---- 模态级 Shapley ----
def exact_shapley(values):  # 8 联盟精确枚举, 精确分数权重
    w = shapley_weights()  # (1/3, 1/6, 1/3)
    for r in range(len(others) + 1):
        for c in combinations(others, r):
            term = (values[S | {m}] - values[S]) * float(w[r])
# ---- 位置级 IG (代码中路径变量名 alpha 对应正文 \tau) ----
for k in range(1, n_steps + 1):
    alpha = k / n_steps if rule == "right" else (k - 0.5) /
        n_steps

```

```

# 参考文献[19--21]
# ---- 关键参数 (与正文 §4.4 一致) ----
# SAMPLE_RATE=16000  音频重采样率 (Hz)
# FRAME_SHIFT=320    帧移 (采样点), 对应 20ms
# CTC_BLANK=0        空白符 id (用于路径扩展)
# MIN_DUR_MS=20      词区间时长下界 (与 C2 检查一致)
# MAX_DUR_MS=3000    词区间时长上界
# CONF_FLOOR=0.0     词置信度截断下界 ([0, 1] 区间)
# ---- 阶段 1: 构造目标 + 维特比回溯 ----
def ctc_forced_align(logits, target, blank=CTC_BLANK):
    # logits: [T, V] 帧级字符分布; target: [U] 目标字符 id (已加 '|'
    # 分隔符)
    T, V = logits.shape; U = len(target)
    # 扩展路径: 每个字符可重复发射 + 字符间允许 blank
    ext = [blank] + [c for c in target for _ in (0, 1)] +
        [blank] # 长度 2U+1
    S = len(ext)
    # 前向概率矩阵 alpha, log 域避免下溢
    alpha = full((T + 1, S), -inf); alpha[0, 0] = 0.0
    for t in range(1, T + 1):
        for s in range(S):
            a = alpha[t-1, s]
            if s > 0 and ext[s] != blank and ext[s] != ext[s-2]:
                a = log_add(a, alpha[t-1, s-1])
            if s > 1 and ext[s] == ext[s-2]:
                a = log_add(a, alpha[t-1, s-2])

```

```

        alpha[t, s] = a + logits[t-1, ext[s]]
# ---- 阶段 2: 回溯得字符帧段 ----
char_frames = [[] for _ in target]
t, s = T, S - 1
while t > 0:
    c = ext[s]
    if c != blank:
        char_frames[c].append(t - 1) # 0-indexed 帧下标
    # 决定 s 转移方向
    if s > 0 and alpha[t-1, s-1] + logits[t-1, ext[s-1]] ==
        alpha[t, s]:
        s -= 1
    elif s > 1 and ext[s] == ext[s-2] and alpha[t-1, s-2] +
        logits[t-1, ext[s-2]] == alpha[t, s]:
        s -= 2
    t -= 1
# ---- 阶段 3: 字符帧段聚合为词区间 ----
word_intervals = []
word_confs = []
for w_idx, frames in enumerate(char_frames):
    if not frames: continue
    k1, k2 = min(frames), max(frames)
    t_s = k1 * (FRAME_SHIFT / SAMPLE_RATE) * 1000 # ms
    t_e = (k2 + 1) * (FRAME_SHIFT / SAMPLE_RATE) * 1000
    word_intervals.append((t_s, t_e))
    word_confs.append(round(mean_prob_at_frames(logits,
        frames, target[w_idx]), 4))
return word_intervals, word_confs

```

附录 C 结果文件样例

C.1 附件 3 (问题二)

附件 3 预测结果 CSV 含 30 行全量 (完整表头随交付包)。样例行:

```
附件3_02, 1, -0.1721, 0.4488, 28, 0.0, 0.178571, 0.178571,
0.178571, 1.25, ...
```

行为分析摘要与困难样本清单 (前 5 条: 附件 3_30/29/27/17/21) 随交付包提供。推理模型为 MRFN+ 三种子集成。

C.2 附件 4 (问题三)

预测与模态贡献 CSV 列: sample_id, pred_polarity, confidence (校准), main_modality, $\varphi_{t/a/v}$, $\varphi_{t/a/v}^r$, $g_{t/a/v}$, vision_natural_missing (20 行全量); 证据定位长表列: sample_id, rank, modality, attribution, model_position, evidence_type, content, t_start, t_end, word_align_status (60 行)。样例行:

```
01, 1, text, 0.0552, 9, word, belt, 1, 3.04, 3.22, 8, aligned
```

解释卡交付 4 例 (样本 #04/#09/#13/#17, 覆盖双向词证、强负文本主导、视觉整模态缺失哑玩家、高置信正类四类), 全文随交付包; 正文图 6.7 为另行选取的代表性三例 (含视觉主导样本 #14), 两处样本集不同。样例 (样本 #09):

```
极性 Negative (校准置信度 0.97) | 强度 -2.29 | 主要参考模态 text
转写: "(uhh) I did not like this movie at all, I would not
      recommend it"
text:  $\varphi=+0.682$  (预测类) /  $-2.454$  (强度) /  $g=0.765$ 
证据 TOP3 (|IG| 序): "recommend" t=[3.20, 3.62]s; "i"
      t=[2.80, 2.82]s; "it" t=[3.62, 4.96]s
对齐: 14 词 CTC 强制对齐 (失败 2, 插值放行), 视频时长 5.0s
```

20 条样本的带符号模态贡献全量总览见图 C.1, 与正文 6.5 节的解释卡互为整体与细节。

20 条样本的逐样本数值 (极性/置信度/强度/主模态/带符号 $\varphi_t/\varphi_a/\varphi_v$) 见表 C.1。

表 C.1 附件 4 全量解释汇总

样本	极性	置信度	强度	主模态	φ_t	φ_a	φ_v
#01	Neutral	0.47	+0.24	text	+0.106	-0.012	+0.024
#02	Positive	0.40	+0.25	text	+0.219	-0.085	-0.045
#03	Negative	0.46	-0.15	text	+0.185	-0.018	+0.011
#04	Negative	0.42	+0.50	text	+0.360	-0.157	-0.076
#05	Positive	0.75	+0.97	text	+0.314	+0.021	+0.140
#06	Positive	0.61	+0.49	text	+0.414	+0.034	-0.123
#07	Positive	0.79	+1.02	text	+0.468	+0.020	+0.026
#08	Positive	0.61	+0.49	text	+0.445	-0.027	-0.091
#09	Negative	0.97	-2.29	text	+0.682	-0.017	+0.021
#10	Negative	0.91	-1.81	text	+0.664	-0.027	+0.005
#11	Negative	0.92	-1.72	text	+0.548	+0.039	+0.068
#12	Negative	0.78	-0.93	text	+0.531	-0.031	+0.032
#13	Neutral	0.53	+0.20	text	+0.182	+0.020	+0.000
#14	Positive	0.48	+0.63	vision	-0.097	+0.059	+0.199
#15	Positive	0.77	+1.12	text	+0.389	+0.119	-0.001
#16	Negative	0.98	-2.40	text	+0.662	-0.008	+0.036
#17	Positive	0.96	+1.77	text	+0.609	+0.045	-0.001
#18	Neutral	0.45	-0.12	text	+0.107	-0.023	+0.030
#19	Positive	0.52	+0.77	vision	+0.050	+0.069	+0.101
#20	Positive	0.82	+1.17	text	+0.422	+0.032	+0.076




图 C.1 附件 4 全量解释总览：各样本带符号模态贡献

附录 D 掩码库说明

31 个评测场景的固定键序（与 5.4 节网格一一对应）：

```
mcar/t/rate{10,20,40,60,80}/random # 单模态 × 5 率 (15 条)
mcar/{ta,tv,av}/rate40/random # 双模态 @40% (3 条)
block/{t,a,v}/rate40/{head,mid,tail,random} # 连续块 × 位置 (12 条)
joint/av/rate40/random # 联合缺失 (1 条)
```

每场景 8 个种子化实例 (`default_rng([2026, combo_idx, k])`)，场景值为 8 实例均值；掩码库种子与训练种子分离，训练期不可见；全库重生成经逐位一致性校验。

表 D.1 为固定覆盖率 40% 下不同连续缺失块长 ($\ell \in \{2, 5, 10\}$ 、独立种子 2027) 的性能扫描结果，与 §5.4 节“文本主导脆弱性”结论互为补充——退化由覆盖率与模态身份驱动，而非缺失的连续形态。




图 D.1 31 缺失场景类型占比

此外，31 场景按缺失类型分组的占比见图 D.1：MCAR 单模态 48.4%（15 条）、Block 38.7%（12 条）、双模态 9.7%（3 条）、联合缺失 3.2%（1 条）；按类型聚合，与图 5.5(b) 按场景键序呈现退化分布的视角互为补充。

表 D.1 固定覆盖率 40% 下连续缺失长度扫描 (D_S)

缺失形态	平均段长	文本	语音	视觉
散布 (mcar@40)	1.6	+0.048	-0.001	+0.004
短块 ($\ell \leq 2$)	2.4	+0.054	-0.000	+0.004
中块 ($\ell \leq 5$)	4.5	+0.050	-0.000	+0.004
长块 ($\ell \leq 10$)	7.2	+0.051	-0.002	+0.004
单块 ($\ell \approx 0.4w$)	9.3	+0.050	-0.002	+0.004