



文本轨：BERT 逐位置输出，词分组着色（多子词同色相连）



映射：词 → [t_s, t_e) （音频 / 视觉在词区间池化后复制到词内全部 WordPiece）



音频轨：eGeMAPS LLD 在词区间 [t_s, t_e) 内池化（time 域）



视觉轨：关键帧按帧时间戳 pts_time 落位（底部短刻度 = 全部 163 帧的 pts）

