



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

浙江工商大学

参赛队号

2026XXXXX

队员姓名 1. 许洪杰

2. 张耀胜

3. 张峻菲

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 复杂场景下多模态情感预测的数学建模与算法设计

摘 要：

多模态情感预测需同时利用文本、语音与视觉信号识别说话者的情感极性与强度，而复杂场景使该任务面临异构时序对齐难、模态局部缺失、决策依据难追溯的三重挑战。为此，本文基于 CMU-MOSEI 数据集建立“统一时序坐标—缺失感知预测—反事实解释”三层递进的建模体系，三个问题共用同一套坐标定义与合成缺失算子，使后一问题的建模与解释始终建立在前一问题的产出之上。

针对问题一，以转写文本的子词位置为主轴建立了统一时序坐标系：先形式化定义语义位置集、结构状态与观测状态三元组（自然观测、合成缺失、可用状态），再由 CTC 强制对齐获得词级半开时间区间，进而将语音与视觉特征按词区间池化映射至 50 位网格，截断、标点挂靠、无有效帧等边界情形均归入确定性规则并在映射表中留痕。该坐标系在 100 条样本上通过四类机器指标验收：样本覆盖完整（schema 违例 0），自生成特征与附件 2 总体行为一致（非零率差不超过 0.231 个百分点），冻结后 7 条重叠样本文本特征逐位一致（余弦为 1.0），管线责任对齐失败率约 1.0%（门槛 2%），由此为问题二、问题三提供共用的位置语义与位置—物理时间对应关系。

针对问题二，在该坐标系之上构建缺失感知可靠融合网络 MRFN，以缺失状态编码、可用性约束注意力与可靠性门控三层机制使缺失成为显式输入变量。在 31 个缺失场景的固定网格上评测得到三条实验结论：其一，文本缺失是主导的脆弱性来源；其二，缺失增强训练使综合效用较干净训练提高 0.030，且干净性能不降反升；其三，三层机制的各自贡献由模型阶梯与消融实验逐级定位。MRFN 在测试集上取得 66.71% 的准确率，经预注册门槛筛选采纳的改进变体 MRFN+ 经三种子集成达到 68.64%，并完成附件 3 的 30 条全量预测与行为分析。

针对问题三，在冻结的 MRFN+ 之上建立反事实解释框架：模态作用程度由 8 联盟精确 Shapley 值度量（效率公理残差不超过 3×10^{-8} ，哑玩家公理由整模态自然缺失的真实样本实证），位置级归因由 64 步中点积分梯度度量（完备性检验 40/40 通过，结构位与不可用位的归因恒为零），关键证据沿问题一的坐标映射回溯至原词与物理时间。六项保真

度检验按运行前冻结的判据执行，A-E 通过；F 项（文本 IG-LOO 一致性）未通过，已完成结构性诊断。附件 4 的 20 条全量预测与解释均已完成，全局关键证据均为文本词证据并附物理时间区间。

综上，本文建立了统一的多模态时序坐标体系，构建了面向模态缺失的可靠融合网络，并进一步建立了基于 Shapley 值和积分梯度的情感预测解释方法，实现了从多模态数据对齐、缺失场景预测到结果解释与证据回溯的完整建模过程。实验结果表明，所建立模型能够有效提高缺失场景下的预测稳定性，并能够将预测结果追溯至具体的文本、语音和视觉信息，为多模态情感预测模型的实际应用提供了参考。

关键词： 多模态情感预测；时序对齐；模态局部缺失；鲁棒融合；可解释性；证据回溯

目录

1	问题重述	5
1.1	问题背景	5
1.2	附件与数据约束	5
2	问题分析	7
3	模型假设与符号说明	10
3.1	建模前提	10
3.2	待验证假设	10
3.3	符号说明	11
4	问题一：时序对齐模型的建立与求解	13
4.1	数据事实与分析	14
4.2	统一时序坐标系的建立	15
4.3	特征生成与边界延拓	16
4.4	CTC 对齐求解与合法性处置	19
4.5	验收检验与典型回放	20
5	问题二：鲁棒情感预测模型的建立与求解	23
5.1	缺失空间的数学描述	23
5.2	MRFN 模型的建立	24
5.3	训练方案与模型阶梯	25
5.4	鲁棒性评价与实验	27
5.5	模型改进与终评	30
5.6	预测与行为分析	32
6	问题三：可解释情感预测模型的建立与求解	36
6.1	解释任务的形式化	36
6.2	模态级 Shapley 模型	36
6.3	位置级积分梯度模型	37
6.4	解释可信性验证	41
6.5	解释结果与分析	43
7	模型评价	46
7.1	模型优点	46
7.2	三问联合验证	46

7.3 灵敏度与稳定性分析	46
7.4 局限与错误归因	47
参考文献	49
附录 A 环境与复现	50
附录 B 关键代码	51
附录 C 结果文件样例	52
附录 D 掩码库说明	55
附录 E 自动回放图与签核单	57

1 问题重述

1.1 问题背景

多模态情感预测要求同时利用文本、语音与视觉信号判断说话者的情感极性与强度。本文以 CMU-MOSEI (CMU Multimodal Opinion Sentiment and Emotion Intensity) [1] 为唯一数据来源, 聚焦三个落地缺口: 异构时序对齐、模态局部缺失下的鲁棒融合、决策依据可回溯。三重挑战的具体形式化与三问的对应关系见 2 节, 下文先重述任务与附件约束。

问题一: 多模态特征提取与时序对齐。建模对象是从原始素材到标准化时序特征的处理全过程, 须明确原始样本的处理流程、各模态情感特征的定义与提取方法、跨模态时序对齐的规则与实现逻辑。允许使用开源工具或预训练模型完成基础处理, 但规则须经流程落实方可核验, 流程须附参数与日志方可复现。难点集中在两点: 一是三模态采样频率与时间尺度不一致, 二是特征零值既可能来自合法低能量观测、也可能来自采集失败。题面对自生成特征提出三项要求: 原始样本覆盖完整、时序组织可核验、方法合理可复现。

问题二: 缺失场景下的鲁棒情感预测。问题二在问题一的时序基础上展开, 要求在模态局部缺失条件下仍能稳定预测, 并对附件 3 的无标签测试样本给出预测。模态局部缺失指文本、语音或视觉中部分连续时段不可用, 有别于整模态完全缺失。这一定义划定了研究边界: 既然常规固定权重融合在局部缺失下失效, 本文就须先定义可用的输入条件, 再据此设计预测模型。模型须完成情感极性三分类与情感强度回归两项预测, 并分析缺失模态类型、缺失位置、缺失时长对性能的影响规律。训练与选择在附件 2 的训练集与验证集上进行, 附件 3 的全部无标签样本仅用于最终推理。分类任务采用准确率与 F1 值评价, 回归任务采用平均绝对误差与皮尔逊相关系数评价。

问题三: 可解释性情感预测与证据回溯。问题三在预测之上要求模型附带判断依据: 除极性与强度预测外, 还须以可量化、可复核的方式说明本次判断主要依据了哪些模态、哪些时间位置的输入。难点在于三模态信息同时在场时信息来源增多, “主要依据” 不再显然, 关键证据须可对应至原始文本片段、语音时段或视觉关键帧, 以便对照原始素材核查。模型同样在附件 2 上完成训练与选择, 对附件 4 的全部无标签样本输出预测与解释结果。此处三模态信息完整是被解释样本的输入设定; 而为回答“若某模态信息不可用, 预测将如何变化”一类对比问题构造的合成缺失与问题二的模态局部缺失含义不同, 后文将分别处理。

1.2 附件与数据约束

本题提供四组数据与材料, 各附件的规模、组织方式与本题用法汇总于表 1.1。

表中“特征值全部为零的连续区间”是题面构造附件 3 时所采用的缺失判据; 特征取零本身并不必然等同于信息缺失, 二者的区分将在第四章观测状态建模中给出。

数据使用须遵守题面统一约束: 以赛题提供的 CMU-MOSEI 系列数据为唯一数据来源, 不得引入其他数据集参与训练、微调、参数优化、阈值选择或结果统计; 训练、验证与专项测试保持同一特征版本与同一输入接口; 问题二与问题三模型均在附件 2 训练集上学习参数、在验证集上选择模型结构与决策阈值, 附件 3、附件 4 仅作最终推理; 对极

表 1.1 题面附件的规模、组织方式与用法

附件	内容与规模	关键组织方式	本题用法
附件 1	100 条原始英文视频 (37 个 video_id 子文件夹, 时长 2.648–34.567 s) 及标注表	video_id 与 clip_id 共同确定样本; text 列为英文转写; 连续强度标注取值 $[-3, 3]$, 其中 $[-3, 0)$ 负向、0 中性、 $(0, 3]$ 正向, 0 仅属中性	问题一特征提取与对齐的原始素材
附件 2	标准化多模态特征文件, 对齐与非对齐两套、各 4850 条样本, 按训练/验证/测试 = 3395/728/727 组织	文本/语音/视觉特征维度分别为 768/74/35; 对齐版本三模态均按 50 个对应序列位置组织, 非对齐版本语音与视觉保留独立时序 (500 位置); 标签含三分类与连续强度	问题二、问题三建模的唯一训练与选型数据
附件 3	30 条无标签样本的特征文件, 含随机模态局部缺失	缺失表现为一个或多个模态中特征值全部为零的随机连续区间	问题二专项测试, 仅作最终推理
附件 4	20 条无标签真实场景视频及对应三模态特征文件, 三模态信息完整	特征字段、张量维度与时序组织与附件 2 保持一致; 配套原始视频用于将关键证据时间位置回看至文本、语音或视觉片段	问题三专项测试, 仅作最终推理

短、无效或异常片段的处理保留原始样本并说明规则。

2 问题分析

三问的内在联系、路线图与公共实验纪律构成本章主体。本节先确定三问的输入输出关系与共同约定，再给出各问技术路线与全篇公共实验纪律。

三问输入输出关系。三问面对同一批多模态数据，题面允许问题二、问题三直接采用附件 2 标准化特征建模。组织方式有两类：各问独立选择输入表示，或共用同一套时序坐标。本文采用后者——以问题一建立的时序坐标作为全篇共同使用的坐标定义，其位置体系、观测状态、位置—物理时间映射三类要素的形式化见 4.2 节。两点理由：第一，问题一的自生成表示须通过与附件 2 特征的行为一致性检验，以通过检验的坐标系为基准，后两问的特征语义有据可依；第二，问题二训练中的合成缺失与问题三解释中的反事实干预作用于同一位置体系，跨章结论可以相互支撑。共用坐标系不等于共用特征文件：问题二、问题三输入模型的特征矩阵仍取自附件 2，“统一坐标”与“特征来源”是两个层次。

三重挑战各对应一个数据层面的技术前提：**异构时序对齐难**转化为对齐问题（**50 个序列位置**须与物理时间建立可核验的对应）；**模态局部缺失**转化为状态建模问题（“是否观测到”与“观测值是多少”须分开形式化）；**决策依据难追溯**转化为证据回溯问题（关键证据依赖位置—时间映射）。模态局部缺失的真实形态由附件 3 实测统计给出，图 2.1 展示了附件 3 联合零行的连续缺失段长分布——段长为 1 的单点散布占 74.7




图 2.1 附件 3 联合零行连续缺失段长分布 ($n = 30$, 131 段)


各问技术路线。问题一建立统一时序坐标系并以四类机器指标验收 (§4.2–§4.5)。问题二在问题一的坐标系上构建 **MRFN**，将可用状态作为缺失状态编码、可用性约束注意力、可靠性门控融合三层机制的显式输入，以 **31 场景网格**评测 (§5.1–§5.6)。问题三在问题二冻结预测器之上叠加反事实解释框架，**模态级贡献由精确 Shapley 值度量、位置级归因由积分梯度度量**、解释可信性以运行前冻结的判据验证，关键证据沿位置—物理时间映射回溯 (§6.1–§6.5)。

总体技术框架。三条路线的整体组织与数据流向见图 2.2。原始视频经文本转写、音频、视觉三路提取进入问题一，问题一在子词位置体系上完成特征生成与强制对齐并输出

表 2.1 附件 3 联合零行连续缺失段长精确统计

段长（位）	段数	实测位数	段数占比	位数占比
1	71	71	74.7%	54.2%
2	16	32	16.8%	24.4%
3	4	12	4.2%	9.2%
4	4	16	4.2%	12.2%
≥ 5	0	0	0.0%	0.0%
全样本合计	95	131	100.0%	100.0%

注：与图 2.1 共同给出缺失形态——段长 1 占段数主体（74.7%），平均段长 1.379 位（=131/95），≥ 4 位合计仅 8 段（8.4%，对应 12.2% 位数）。缺失以单点散布为主、连续块为辅。实测位数 = 段数 × 段长；分母 95 与 131 分别来自 pmf 与 joint_zero_rows。



坐标定义。问题二以附件 2 特征为输入、以坐标定义为共同基准，训练缺失感知预测模型。问题三复用问题二确定的预测器完成反事实解释，关键证据沿位置—物理时间映射回溯至原始素材。映射链以旁路形式直接连通问题一与问题三，证据的时间定位不经过预测模型、可独立核验。数据自上而下单向流动、证据自下而上沿映射链回溯，本文不涉及反馈或再训练环节。

实验纪律。验收门槛在实验运行前确定，实验后不因结果调整；未通过项保留原始结果并给出诊断分析。该纪律与 1.2 节的数据使用约束同源。

3 模型假设与符号说明

三条建模前提、九条待验证假设、四组核心符号构成全篇共同基础。本节登记前提与假设，统一全篇符号。前提经采用理由说明后直接成立；假设须在后续章节以实验检验，未达标项如实报告。

3.1 建模前提

本节登记建模采用的顶层前提；实现层面的具体规则随对应方法小节首次出现时给出。

- 任务定义：情感极性三分类与情感强度回归，值域 $[-3, 3]$ ，以多任务联合损失训练， $\lambda_r = 1$ （分类与回归等权）。
- 输入约束：附件 2 对齐版本（文本 768 / 语音 74 / 视觉 35 维，三模态统一于 50 位序列）；附件 3、附件 4 无标签，仅作最终推理。
- 评估口径：训练集学习参数、验证集选择模型结构与阈值、专项测试集只作最终推理；评测掩码库使用独立种子，与训练种子分离，评测场景对训练过程不可见。31 场景缺失率的实测分布由图 3.1 给出：训练 / 验证 / 测试三划分各 50 个场景级缺失率均集中在 0–80% 区间，三条密度曲线高度重叠（均值 0.43、标准差 0.23）。这表明 31 场景网格的覆盖率分布在三个划分上同源，评测场景对训练与选择决策不构成系统性偏差，因此 §5.4 的评测结果可在三划分间一致比较。




图 3.1 31 缺失场景缺失率分布（训练/验证/测试，8 实例均值）

- 数据来源边界：以赛题提供的 CMU-MOSEI 系列数据为唯一来源，不引入其他数据集参与训练、微调、阈值选择或结果统计。

3.2 待验证假设

除上节前提外，另将九条预期命题登记为待验证假设，编号 H1–H9 全篇唯一。各条判定标准为实验运行前冻结的门槛，实验后不移动；未完全达标者如实记为部分成立，不回

表 3.1 31 场景缺失率按类型汇总（附件 2 test）

场景类型	场景数	均值	标准差	最小	最大
MCAR 单模态 ($\{t, a, v\} \times \{10, 20, 40, 60, 80\}\%$)	15	0.4201	0.2643	0.1004	0.7985
MCAR 双模态 ($\{ta, tv, av\}@40\%$)	3	0.3999	0.0000	0.3999	0.3999
连续块 ($\{t, a, v\} \times \{ \text{头/中/尾/随机} \}@40\%$)	12	0.3976	0.0037	0.3889	0.3999
联合缺失 ($av@40\%$)	1	0.3846	—	0.3846	0.3846
31 场景合计	31	0.4074	0.2179	0.1004	0.7985

注：与图 3.1 共同支撑——三划分密度曲线高度重叠，证明网格覆盖率分布在训练/验证/测试同源；连续块场景实际缺失率略低于名义 40%（最差 v 系列 38.9%），源于连续块在头/中/尾受限的可铺区域。
联合缺失组 n=1 无标准差。

改假设。假设的最终状态以验证章节的报告为准，命题要点与验证落点列于表 3.2。

表 3.2 待验证假设登记表

编号	名称	验证章节	命题要点
H1	音视表示规则一致	第四章	自生成音视特征的结构位处理与观测行为同附件 2 对齐版本一致
H2	文本接口同源	第四章	冻结编码器重编码的文本特征与附件 2 预计算特征同源（逐位余弦 ≥ 0.99 ）
H3	前提有效性	第四章	对齐粒度与观测语义前提可支撑 50 位网格的跨模态对齐与缺失识别
H4	缺失增强训练有效性	第五章	训练期混入合成缺失提升缺失场景效用，且干净性能代价有限
H5	门控可靠性响应	第五章	门控信任与对应模态的信息可用性存在同向响应
H6	组件增益可归因	第五章	架构各级增益可由阶梯设计与消融逐级定位
H7	解释分布基础	第六章	缺失感知训练使解释的反事实干预输入落在训练分布附近
H8	归因可回溯且忠实	第六章	位置归因可沿映射链回溯至物理时间，且与删除响应秩一致
H9	解释稳定	第六章	归因排序对输入轻微扰动保持稳定

3.3 符号说明

全篇核心符号列于表 3.3，高频符号的含义在首次使用公式处说明，本表仅列高频索引项；派生符号（ λ_r 、 α_j 、 c_m 、 T 、 τ 等）在对应公式括号内给出。

表 3.3 全篇核心符号

符号	含义
数据与坐标	
$m \in \{\text{text}, \text{audio}, \text{vision}\}$	模态（下标 $t/a/v$ ）
$j = 1, \dots, 50$	序列位置
$w; n_w$	原词；词 w 所含子词数
x_j^m	模态 m 在位置 j 的特征向量
s_j	结构状态（内容/特殊/填充位）
o_j^m	自然观测指示
b_j^m	合成缺失指示
$a_j^m = o_j^m(1 - b_j^m)$	可用状态
$[t_s, t_e)$	词的物理时间半开区间
预测模型	
F	情感预测器（极性 + 强度双输出）
g_m	融合层对模态 m 的门控信任
$p; \hat{g}$	极性概率向量；强度预测值
缺失与评价	
$r; \bar{l}$	缺失率；平均缺失段长
S	综合效用分
$D_U(r)$	缺失率 r 下的效用相对下降率
$\mathcal{S}_{\text{sel}}$	验证集选型分
解释框架	
$N; S \subseteq N$	模态全集；模态联盟
$v(S); v(\emptyset)$	联盟值；空联盟值
φ_m	模态 m 的带符号 Shapley 贡献
$E; E'$	子词嵌入矩阵；IG 基线嵌入
$\text{IG}_j; A_w$	位置归因；词级归因

4 问题一：时序对齐模型的建立与求解

原始视频、音频与文本转写在采样粒度和坐标系上互不相同，直接联合建模会引入位置偏差。本章的核心任务是建立**统一的 50 步序列坐标系**，并保证网格位置可双向映射回原始素材的物理时间——前者支撑逐位置联合建模，后者支撑后续解释与回溯接口。本章先给出两组实测分布作为建模依据（图 4.1 与图 4.2），整体技术路线见图 2.2。

在进入形式化定义之前，先补充一项实测事实：**CTC 词区间在 50 位序列上的分布并不均匀**。图 4.1 按词所在位置分位给出词持续时间 $t_e - t_s$ 的核密度分布：**头段（位置 $\leq K/3$ ）词持续时间众数约 0.13 s、中段约 0.14 s、尾段约 0.16 s**，三段众数相近但分布尾部差异显著——尾段词持续时间在 0.3 s 以上的占比高于头段，对应说话过程中局部语速变化。该非均匀性是 §4.2 统一坐标系采用词区间映射（而非等间隔 50 帧）作为位置—时间接口的实测依据。




图 4.1 词持续时间按位置分位的核密度（CTC 对齐区间）




图 4.2 对齐后内容位空位数分模态分布（附件 1， $n = 100$ ）

各模态对齐后的内容位填充情况由图 4.2 给出：文本空位数均值为 25.5（48 个内容位中实际词片数较少导致空位占比大，对应 §4.1 “位置语义不一致”事实）；语音空位数均值为 0、视觉空位数均值为 1.2（最大 17），说明对齐后语音内容位覆盖完整、视觉在 5% 的内容位上无人脸检出——这是 §3.1 前提中“零值不自动等于缺失”在自生成数据上的实测依据。

4.1 数据事实与分析

问题一的建模对象是附件 1 的 100 条原始视频。本节将原始素材的实测事实转化为后续统一坐标建模所需的约束条件：只保留三类与建模直接相关的事实，具体统计数值留待 4.5 节在验收指标语境中报告。

其一，三模态的位置语义不一致。附件 2 对齐版本虽将三模态组织在同一 50 位序列上，但实测表明：文本特征是逐子词的上下文向量——同一原词相邻子词的行向量互不相同、差异明显；语音、视觉特征则是词级池化后的复制——同一原词的全部子词行逐位相同，且二者在特殊位精确为零、SEP 位之后不出现非零行。同一“位置”对文本是子词级、对语音视觉是词级，统一坐标必须显式处理这一粒度差异。

其二，特征零值具有双重语义。按有效位置统计，语音特征近乎全为非零；视觉特征存在少量零行，其出现与无人脸或局部不可观测的情形相对应，另有极少量整条视觉全零的样本。零值既可能是合法的低能量观测，也可能是未观测到，“是否观测到”必须与“观测值是多少”分离为两个独立变量——这一区分是第三章建模前提中“零值不自动等于缺失”的实测依据。

其三，素材物理参数不齐整。视频帧率不统一，且存在远超 50 位网格容量的长转写——截断必然发生，截断方向与特殊位摆放须显式定义；同时附件 1 与附件 2 存在重叠样本且转写逐条一致，可为自生成表示提供逐位核验的参照系。

上述三组事实共同决定了问题一的建模约束。在此约束下，问题一须同时满足三项建模要求：

- 统一的位置坐标：文本、语音、视觉必须组织到同一序列位置体系，使跨模态信息可逐位置联合建模；
- 区分真实零值与不可观测：必须把“是否观测到”与“观测值是多少”分离为两个独立变量，避免零值混叠合法低能量观测与采集失败；
- 证据可回溯至物理时间与原始输入：每个序列位置须能回溯到原始素材的物理时段，关键证据须能定位至原始文本、语音或视觉片段——这是后续解释与回溯的接口，与 §1.1 第三重挑战”决策依据难追溯”直接对应。

上述三项要求分别对应 4.2 节的定义 4.1–4.3 与位置—物理时间双向映射接口声明，4.3 节的边界延拓规则以及 4.4 节的词区间求解。

4.2 统一时序坐标系的建立

坐标系采用双域设计——语义位置域承载逐位置联合建模，物理时间域承载与原始素材的对应——两域仅通过词区间连接，不假设各位置等间隔对应物理时间。这一设计回应 4.1 节“位置语义不一致、帧率不齐整”的约束；据此依次定义语义位置集、结构状态、观测状态、词序列与词归属四类要素，并声明位置—物理时间映射的求解接口。

定义 4.1: 语义位置集 $J = \{0, 1, \dots, 49\}$ 是固定 50 步模型索引坐标: $j = 0$ 固定为 CLS 位; 内容子词按转写顺序自 $j = 1$ 起排布; 设内容子词数为 $k \leq 48$, 则 $j = k + 1$ 为 SEP 位、 $j > k + 1$ 为填充位; 内容子词超过 48 时保留前 48 个, SEP 固定于 $j = 49$ 。J 不与物理时间等间隔对应。

在 J 上附以结构状态 $s_j \in \{\text{内容, 特殊, 填充}\}$: CLS 与 SEP 为特殊位, SEP 之后为填充位, 其余非填充位为内容位; 结构状态满足尾部单调性, 且三类互斥、合计覆盖全部 50 位。结构状态与下述观测状态都是附着在“位置—模态”二元组上的逐位置标注变量, 不构成第三个坐标域。

定义 4.2: 观测状态三元组对位置 j 与模态 $m \in \{t, a, v\}$: 自然观测 $o_j^m = 1$ 当且仅当模态 m 在该位置对应的原始素材片段被成功观测 (文本: 转写含该子词; 语音/视觉: 对应词区间内存在有效采集帧); 合成缺失 $b_j^m \in \{0, 1\}$ 为受控实验变量 (问题二、问题三使用, 本节一并定义以供全篇复用); 可用状态 $a_j^m = o_j^m(1 - b_j^m)$ 。观测状态由采集与对齐环节决定, 与特征值 x_j^m 的数值在定义上分离——特征取零不改变观测状态。特殊位与填充位上 $a_j^m \equiv 0$; 文本模态在内容位上 $o_j^m \equiv 1$ (转写存在即观测, 与 4.1 节实测一致)。

定义 4.3: 词序列、词归属与字符区间转写经规范化后, 不发音的标点不入对齐词序列、按继承规则挂靠邻词 (继承规则随 4.3 节边界延拓规则给出)。对齐词序列 $W = (w_1, \dots, w_K)$ 中每个词 w 对应一个抽象的半开物理时间区间 $I_w = [t_s(w), t_e(w))$ —— I_w 的具体数值由 4.4 节对齐算法求解给出, 本节仅约定其形式约定: 两两不重叠、帧时间戳唯一归属一词、时长为正。词归属函数 $\kappa: J_{\text{内容}} \rightarrow W$ 将每个内容位映射到其所属原词, 由分词器词编号与字符偏移联合构建; 原词 w 经 κ 同时确定其在转写文本中的字符区间。词内均匀权 $\alpha_j = 1/n_{\kappa(j)}$, n_w 为词 w 所含子词片数 (含继承标点位); 语音/视觉特征在词内各子词位共享词级信息 (4.1 节事实), 故涉及子词汇总的池化与归因均按 α_j 计权, 避免子词数多的长词被重复加权。

位置—物理时间双向映射 (接口声明)。坐标系的最后一维——位置 j 与物理时间 t 的对应——由词区间 I_w 决定, 包含两个方向: 其一, 内容位置 j 经 $\kappa(j)$ 得原词 w , 再由 I_w 得该位置对应的物理时段; 其二, 任一帧时刻 t 若被某 I_w 覆盖, 则 t 经该词的全部子词位置被唯一归属。

抽象 I_w 在本节仅作为接口声明出现, 4.3 节特征池化与 4.4 节对齐求解均基于此接口。词区间的合法性约束 (时长落在对齐量化粒度至 3 s、起于片段内) 随 4.4 节 C2 检查一并给出, 不在本节重复。

性质 4.1: 双向可核验性由定义 4.1–4.3 与上述接口声明可得: 任一内容位置 j 可经 $\kappa(j)$ 得原词、其字符区间, 再经 I_w 得物理时间; 反之, 任一被词区间覆盖的物理时刻可经

帧时间戳唯一归属到词与其全部子词位置。逐样本映射表随附录交付，两个方向均可分别复核、互不依赖对方的计算结果；本性质为构造性说明，不构成形式证明。

图 4.3 给出了坐标系的整体结构：上方为语义位置域，下方为物理时间域，中间梯形带为词区间映射。从图中可以看出，两域各自保持自身刻度、仅以词区间连接，不做任何线性拉伸——这正对应 4.1 节“位置语义不一致、帧率不齐整”约束下统一坐标的实现方式。




图 4.3 统一时序坐标图（文本位置域与物理时间域经词区间映射）

4.3 特征生成与边界延拓

统一位置与抽象词区间 I_w 确定后，还需将三模态特征落实到 50 位网格上。文本不经时间池化，语音与视觉按词区间池化后复制到该词的子词位——三条路径对应 4.1 节第一

组事实的三种粒度。截断、标点挂靠、无帧缺失等边界作为确定性映射使坐标系在非理想输入上得到延拓； I_w 的具体数值在本节仍为抽象符号，词区间的实际求解与合法性判定交由 4.4 节处理。

三个算子的语义差异直接来自 4.1 节第一组事实，分别定义如下。

文本特征算子。文本特征在语义位置域上直接生成：转写子词化后，经冻结的预训练编码器（BERT[2]，bert-base-uncased，权重与版本冻结）逐子词编码，

$$H = \text{Encoder}(\text{input_ids}, \text{attn_mask}) \in \mathbb{R}^{50 \times 768},$$

第 j 行即位置 j 的上下文相关子词表示，特殊位与填充位由编码器按特殊标记语义自然生成；输出层级取最终层隐状态，其选择依据与核验在 4.5 节给出。文本特征不经过任何时间池化。

音频特征算子。语音特征以扩展日内瓦极简声学参数集（eGeMAPS[3]；本文使用其 v02 工具实现，版本见 4.4 节工具清单）的 25 个低层描述符逐帧提取，特征提取的帧移为 10 ms——此为特征提取环节的参数，与 4.4 节对齐输出的时间量化粒度属不同环节、互不约束。记帧时刻为 t_k 、帧特征为 x_k ，词 w 的池化算子为

$$P^a(w) = \frac{1}{|F(w)|} \sum_{k \in F(w)} x_k, \quad F(w) = \{k : t_k \in [t_s(w), t_e(w))\},$$

所得词向量按位复制到该词的全部子词位置——与附件 2 对音视特征的官方组织方式一致（4.1 节事实）。

视觉特征算子。视觉特征经人脸对齐后提取动作单元与姿态描述，按素材原生帧率取帧、以帧中心时刻落入 $[t_s(w), t_e(w))$ 判定归属，池化与复制规则同音频；词区间内无有效帧时按规则 R3 置零行。

特征空间声明。问题一交付的是自提取原始空间特征，语音 25 维、视觉 23 维；问题二、问题三的模式输入取附件 2 官方维度，语音 74 维、视觉 35 维——两套特征数值空间不混用，全篇共用的是 4.2 节的坐标与状态定义，与第二章“统一坐标与特征来源分层”一致。

边界延拓规则。以下规则形式化为确定性映射，输入为 4.2 节坐标系，输出为特征矩阵与状态标注：

- **R1：头部截断**内容子词逾 48 时按定义 4.1 截断；被截除的整词不入网格、映射表标记截断；跨截断边界的词，其池化向量只复制到保留的子词位。
- **R2：标点挂靠**不发音的标点不产生独立词区间，但仍占据网格位置：其词归属 $\kappa(j)$ 取所挂靠的原词（收尾类挂前词、起始类挂后词、两可类默认挂前词并打标记），音视特征随挂靠词取值；文本特征不经时间池化，标点位置天然获得其自身的上下文表示。映射表对标点位置逐条记录挂靠类型， κ 在全部内容位上均有定义、无断点。
- **R3：无有效帧统一规则**：词区间内不存在任何有效帧时，该词语音/视觉特征为零行、 $o_j^m = 0$ 并记录缺失原因。有效帧的判定分模态定义——语音：区间内存在帧且描述

符非全缺失；视觉：区间内存在帧且人脸检出成功。成功采集的低能量静音仍属观测 ($o_j^m = 1$)，对应 3.1 节”零值不自动等于缺失”的前提。

- **R4：部分帧缺失**区间内部分帧有效时仅对有效帧池化（语音逐描述符在有效帧上求均值，视觉取人脸检出帧），全部无效方置零行。
- **R5：词间帧**词区间之外的帧不参与任何词的池化。

以一个发生截断的样本为例，图 4.4 展示了网格规则与状态标注的整体效果：图中呈现子词网格与结构状态、多子词的词内复制、标点挂靠、零行缺失标注与截断标记。从图中可以看出，边界延拓规则涉及的所有排除与变换均有明确规则并在映射表中留痕，不存在在未加声明的数据处置——被截断词、挂靠标点与缺失原因均可逐一追溯，这是性质 4.1 双向可核验性在边界情形下的延续。




图 4.4 50 位语义网格与状态标注（截断样本示例）

4.4 CTC 对齐求解与合法性处置

词区间 I_w 的具体数值由 CTC 强制对齐给出；合法性由 C1–C3 检查判定，失败处置按管线责任与数据责任分层执行。4.2 节定义 4.3 中作为接口的抽象 I_w 在此落地：本节依次给出对齐问题的形式化（CTC 目标、维特比求解与词级聚合）、解码流程、合法性判定规则（C1 词表 / C2 区间 / C3 置信度）、失败分层与插值放行机制、置信度与失败原因的写入路径，并附本节所用工具的版本与核心参数清单。

CTC 强制对齐目标。记音频信号重采样至 16 kHz 后为 X ，声学编码器输出逐帧标记分布 $p(y_k | X)$ 。CTC 引入空白符 ε 与逐帧取值的字符级路径 π （允许重复发射），坍塌映射 $\mathcal{B}$ 去重复、去空白符。词边界的编码：对齐词序列 $W = (w_1, \dots, w_K)$ 被编码为以词分隔符连接的字符目标 $\text{target} = w_1 | w_2 | \dots | w_K$ （“|”为 CTC 词表中的分隔符标记）；强制对齐即求

$$\pi^* = \arg \max_{\pi} p(\pi | X) \quad \text{s.t. } \mathcal{B}(\pi) = \text{target},$$

由维特比算法精确求解。字符帧段与词级聚合：维特比回溯为 target 中每个字符 c 给出一个帧段 $[k_1(c), k_2(c))$ （该字符在路径中的发射帧段，可含多帧）；按分隔符将字符帧段切分归词后，词 w 的区间为

$$t_s(w) = \min_{c \in w} k_1(c) \cdot \Delta, \quad t_e(w) = \max_{c \in w} k_2(c) \cdot \Delta, \quad \Delta = 20 \text{ ms}$$

（帧移 320 采样 @ 16 kHz，即 C2 时长下界）。词置信度定义唯一：词内全部字符帧段的并集上、被指派标记的逐帧发射后验 $p(y_k=c | X)$ 的均值（截断于 $[0, 1]$ ）。时刻约定：词区间端点取对齐帧边界（量化格点）；4.3 节特征帧的归属判定则以帧中心时刻与该物理区间比较（语音 $(k + 0.5) \times 10 \text{ ms}$ 、视觉帧时间戳）——端点定义与帧归属是两个环节的约定，分别声明、不混用。

解码流程。转写规范化（小写化与字符规整）；构造对齐词序列并编码字符目标（标点不入序列，C1 失败词不入目标）；音频重采样后经声学模型编码；维特比求解 π^* ，按上述聚合得到词区间与置信度；执行合法性判定 C1–C3；通过者连同置信度写入映射表，失败者按下节分层处置。

合法性判定（C1–C3）。对每个词按固定顺序执行三条可机械复算的检查：

- **C1：词表检查（编码前）** 词的全部字符均在 CTC 词表内，否则判“接口失败”；
- **C2：区间检查（解码后）** 词区间为正时长、起于片段内，时长落在 $[20 \text{ ms}, 3 \text{ s}]$ ，且不超出片段时长（允许一个量化帧的容差），否则判“区间非法”。词区间两两不重叠不设独立检查——由坍塌路径的时间单调性构造性保证（相邻词的字符帧段天然有序）。
- **C3：置信度检查（解码后）** 词置信度 ≥ 0.5 （冻结阈值），否则判“低置信”。

检查顺序固定，失败原因唯一且可独立复算。3 s 上界为契约冻结的验收参数（正常语速下单词时长的上界量级，用于隔离时长异常输出，非理论约束）。

失败分层。责任分类依据处置路径而非成因归责，判定规则均为机械规则：

- **管线责任（C1/C2 失败）**——管线内确定性处置：调用下方“插值放行”规则给出词区间，再以 C2 复核切分结果；复核未通过者该词置为最终失败（无时间区间，其语音/视

觉特征与观测状态按 4.3 节 R3 处理)。管线责任占比的通过门槛为 $\leq 2\%$ (实测值在 4.5 节报告)。

- 数据责任 (C3 失败) ——处置为按同一插值规则给出词区间, 其原始解码区间与置信度保留于映射表供核查对照, 并打质量标记进入人工核查; 管线不重跑、不因失败修改已冻结的流程, 回滚重跑仅保留于管线责任类缺陷。样本级阈值为嵌套两级: 单样本低置信词占比超过 5% 者进入人工核查清单; 超过 20% 者在同一清单中标记为数据异常样本、优先核查, 并随管线放行。

插值放行。可信词定义为通过 C1–C3 全部检查的词; 连续失败词作为一段处理, 段的左右锚点取前一可信词的区间终点与后一可信词的区间起点, 锚点缺失时以片段首帧、末帧为虚拟锚点; 在两锚点之间按整帧等距切分出各失败词的区间, 切分结果须通过 C2 的时长与界内检查。该规则对两类责任通用, 但管线责任类执行后须 C2 复核, 数据责任类保留原始解码区间与置信度。

置信度与失败原因写入映射表。通过者连同词置信度一并写入映射表; 管线责任类失败者写入失败类型 (C1/C2) 与插值区间; 数据责任类失败者写入原始解码区间、置信度、质量标记 (review/rollback) 与人工核查状态。所有写入均在映射表中留痕, 与 4.3 节边界延拓规则共同保证性质 4.1 的可核验性在失败情形下依然成立。

工具清单。特征与对齐环节使用 BERT(bert-base-uncased, revision 86b5e09)[2]、wav2vec 2.0 声学模型 [4] (CTC 头, 16 kHz, 帧移 320 采样)、openSMILE 2.6.0 (eGeMAPSv02, 25 维、10 ms 帧移) 与 Py-Feat 0.6.1[5] (人脸对齐与动作单元, 交付 23 维); 运行环境与各工具完整参数、权重指纹清单随附录 A 交付。

4.5 验收检验与典型回放

题面对自生成特征的各项要求——覆盖完整性、可核验性、可复现性——被转化为四类可计算的验收指标: 覆盖完整性、行为一致性、接口同源性、对齐质量。按”指标定义 → 实测结果 → 图表读数 → 典型案例 → 本章产出”的顺序逐一报告实测结果, 并回应题面要求; 4.1 节后移的统计数值在此一并给出。

指标定义。四类指标分别对应题面的三项要求——覆盖完整性、可核验性与可复现性:

- 覆盖完整性——对应题面要求 (1): 输出特征与附件 1 标注表一一对应——样本编号无缺失、无重复、无多余, 且每条样本通过 p1.v2 契约的 schema 校验 (形状、数据类型、结构位分区、SEP 位置、观测掩码取值域), 违例计数为零。
- 行为一致性——对应题面要求 (2): 自生成语音/视觉特征在内容位上的非零率, 与附件 2 对应划分之差的绝对值不超过 2 个百分点。该指标是分布层面的检验: 比较对象为自生成样本集与附件 2 对应划分两个样本总体, 验证的是自产管线对“何为观测、何为零值”的处置规则与官方管线在总体行为上一致, 而非逐样本复现官方特征。基准取附件 2 训练划分 (18 条重叠样本中 11 条属训练划分, 来源分布最接近), 其值为语音 99.915%、视觉 94.473% (验证/测试划分依次为 99.732%/100.000%、94.293%/93.925%)。
- 接口同源性——对应题面要求 (2): 重叠样本 (共 18 条: 训练划分 11 条、测试划分 7

条)上,自编码文本特征与附件2预计算文本特征的逐位一致性,按“11条标定、7条冻结后独立验证”协议执行——标定仅确定接口形态(最终层隐状态;接口唯一、无搜索过程,不构成调参),验证只在冻结后的7条测试重叠样本上报告,判定标准为逐位余弦 ≥ 0.99 。

- 对齐质量——对应题面要求(3):三级质量标记 ok/review/rollback 分别对应“无低置信词、低置信词占比 $\in (5\%, 20\%]$ 、占比 $> 20\%$ ”(与4.4节两级阈值衔接;rollback仅沿袭命名,处置为放行+优先核查);管线责任占比门槛 $\leq 2\%$ 。

实测结果。四项指标全部通过——回应了题面“覆盖完整性、可核验性、可复现性”的要求。数值与逐位核验细节汇总于表4.1;以下三项不在表内的数字补全:管线责任失败19/1934词(约1.0%,门槛 $\leq 2\%$)、数据责任低置信347词(约17.9%,按4.4节规则放行)、附件2自身亦含整条视觉全零样本(训练/验证/测试110/15/28条,自然缺失在官方特征中同样存在)。4.1节后移的素材统计在此一并报告:帧率构成为30/29.97/23.98/25 fps(83/10/5/2条),转写词数中位数18、最大65、非特殊子词超48者6条,截断样本中头部截断占234/253且SEP恒在最后有效位(与R1及官方组织一致),文本同词相邻子词行向量余弦约0.63、音视同词行逐位相同(4.1节第一组事实的量化证据)。

图表读数。图4.5以三联图形式给出对齐质量、观测率与缺失原因的可视化,可读出两点观察:其一,质量标记中review居多、rollback最少,且rollback样本均判定为数据异常后放行并优先核查——失败的责任构成可量化、可追溯;其二,观测率分布集中于高观测区间,视觉缺失原因以无人脸为主且逐样本记录成因——缺失由此成为带原因的显式标注。

典型案例。回放样本按边界类型分层选取,须覆盖多子词词、标点挂靠、头部截断、混合帧率、无人脸与对齐失败插值六类边界且至少含两条rollback样本,按此协议选取9条,由冻结规则自动渲染:每图并列文本子词轨、音频波形轨与按词区间定位的视觉关键帧轨,标注结构状态、挂靠类型、截断标记、缺失原因与插值区间(签核完成前一律称“自动回放”),9张回放图随附录E交付。本节核验其中一条——rollback样本9yfZ3swSY_4,用以确认R1头部截断、R2标点挂靠、R3无有效帧、R5词间帧四类边界与4.4节插值放行规则均真实落地:低置信词占比超过20%,按数据责任规则判定为数据异常样本放行,图中可见插值区间与质量标记的落位。其余8张回放图随附录E一并交付。

本章产出。基于上述机器证据——映射表断言0违例、四类验收指标全部通过、回放覆盖全部六类边界(含3条rollback样本)——可对题面要求逐条回应:覆盖完整性由指标(1)保证,特征提取全量汇总表随附录B交付;时序可核验性由4.2节映射定义与逐样本映射表(性质4.1)、指标(2)(3)的分布与逐位核验、本节回放核验三部分共同支撑;合理性与可复现性由4.4节工具清单、p1.v2契约与SHA-256指纹(附录A)及复现说明保证。假设验证状态:H2(文本接口同源)由指标(3)的逐位验证直接判定成立;H1(音视表示规则一致)与H3(对齐可用性)在机器证据层面成立,最终判定以人工签核为准(签核单9条已生成,签核结果将补录于附录E)。

第四章向第五章、第六章交付统一时序坐标系,作为两者共用的输入定义。




图 4.5 问题一验收三联图：对齐质量、观测率与缺失原因

表 4.1 问题一验收结果汇总

验收项	实测值	参照基准	判定
覆盖完整性	100/100 一一对应, 无缺失/重复/多余	附件 1 label-100	通过
Schema 一致性	违例 0 (shape/dtype/mask 分区/SEP 位)	p1.v2 契约	通过
BERT 留出一致性	bitwise 7/7, $\cos_{\min}=1.000$	附件 2 test 重叠 7 条	通过
audio 非零率	1.00000	0.99915	$ \Delta =0.085 \text{ pp} \leq 2 \text{ pp}$
vision 非零率	0.94704	0.94473	$ \Delta =0.231 \text{ pp} \leq 2 \text{ pp}$
对齐质量状态	ok/review/rollback = 43/33/24	—	质量标记，非管线失败

注：非零率保留 5 位小数以逐位核对基准；bitwise 表示逐位相等；ok/review/rollback 为质量标记（非管线失败）。

5 问题二：鲁棒情感预测模型的建立与求解

统一的位置粒度与观测状态是缺失建模的前提。本章在该坐标系之上构建面向缺失场景的鲁棒预测模型 MRFN：先形式化缺失空间与合成算子，再搭建 MRFN 三层机制与训练阶梯并开展 31 场景评测，最后通过八轮预注册筛选改进变体并完成附件 3 的全量预测。本章求解流程见图 5.1。




图 5.1 问题二求解流程：缺失空间定义 → MRFN 三层机制 → 训练与阶梯 → 31 场景鲁棒性评测 → 改进采纳与附件 3 预测

5.1 缺失空间的数学描述

模态局部缺失可由四类维度描述：缺失模态、缺失位置、缺失时长、缺失机制。本节将缺失形式化为四元组 $(M, P, r, \bar{l})$ 与合成缺失算子 γ ，使 1.1 节要求分析的三类影响因素（缺失模态类型、缺失位置、缺失时长）逐一获得形式化对应。

缺失空间的四元组。一个缺失场景由 $(M, P, r, \bar{l})$ 描述： $M \subseteq \{\text{文本, 语音, 视觉}\}$ 为被抹除的模态集合（非空，共 7 种组合）； $P \in \{\text{头, 中, 尾, 随机}\}$ 为缺失段在序列中的位置模式； r 为缺失率，即该模态被抹除的内容位数与内容位总数之比； $\bar{l}$ 为平均段长，即各被抹连续段的平均长度。缺失模态类型对应 M 、缺失位置对应 P ，缺失的规模与连续性形态由 r 与 $\bar{l}$ 共同描述， $\bar{l}$ 小为短散段、 $\bar{l}$ 大为连续块。 $\bar{l}$ 是缺失场景的统计特征量，用于归类场景；缺失段的段数与段长分布由所选缺失机制的取样规则显式给出（见下文），而非由 $\bar{l}$ 直接生成。

合成缺失算子。算子 $\gamma_{M, P, r, \bar{l}}$ 在 4.2 节坐标系上定义：对每个 $m \in M$ ，按所选机制的取样规则生成内容位子集 S_m ——其基数满足率 r 、段位置满足 P 、段数与段长按机制分布取样，置 $b_j^m = \mathbf{1}[j \in S_m]$ ，可用状态更新为 $a_j^m = o_j^m(1 - b_j^m)$ 。特征的实现分模态：语音/视觉在 S_m 上置零；文本在被抹位置将子词替换为 [MASK] 后整体重新编码——对应 3.1 节实现规则：若在编码后置零，邻近子词已吸收被抹内容的信息，掩码将形同虚设。两条全局约束：结构位（CLS/SEP/填充位）不参与抹除；真实零值不改变 o ——自然缺失与合成

缺失在记录中始终分离。此外，算子默认保证至少一个模态的可用率不低于 20%，以避免任务退化为三模态同时高缺失；5.4 节的全部 31 个评测场景均满足该约束，三模态同时全缺失不作为评测场景（此时全部输入信息被抹除，任务不可解）。

四种缺失机制。位置与段长的取样规则即缺失机制，分四类：随机散布（合成机制名 MCAR）——位置均匀随机抽取、与特征取值无关，段为逐位散布；Block（连续块）——单个连续块，块长在 $[5, 0.6 \times \text{内容位数}]$ 上均匀取样、位置由 P 指定，对应题面“连续时间段不可用”的典型场景；联合缺失——语音与视觉同位置同步抹除，段长按附件 3 实测联合零行的经验分布取样；整模态缺失—— M 中模态的全部内容位被抹除。两点界定：其一，附件 3 的实测模式（30 条中 27 条存在局部联合缺失）仅作为联合机制段长分布的经验参照，本文不对真实数据的缺失机制作统计命名；其二，整模态缺失处于从属地位——问题二的研究边界为模态局部缺失，整模态缺失仅作为训练的边界覆盖分量与评测的极端对照场景引入，用以检验缺失趋于极端时的行为下界并提供极端输入的训练覆盖，而不扩大研究边界。

训练与评测的统一生成。评测用缺失场景由独立种子的掩码库预生成，保证不同模型在同一场景集合上严格可比；训练期的缺失按分量在线生成并混合，各分量占该批训练样本的比例为：附件 3 模式的联合局部合成缺失 35%（以附件 3 实测模式为模板生成，与附件 3 数据本身的缺失比例无关）、MCAR 与 Block 合计 40%、整模态 15%、干净样本 10%——配比的消融见 5.4 节。掩码库种子与训练种子分离，评测场景对训练过程不可见。

5.2 MRFN 模型的建立

缺失感知机制分布于三个环节：输入端的缺失状态编码、交互端的可用性约束跨模态注意力、融合端的可靠性门控。MRFN 的三层机制按此顺序定义，与第二章的数据流一致。模型输入为附件 2 对齐特征与 4.2 节的状态标注（结构状态 s 、自然观测 o 、合成缺失 b 、可用性 $a = o \cdot (1 - b)$ ），输出极性 logits 与强度预测：

$$F : (x, s, a) \mapsto (\text{logits} \in \mathbb{R}^3, \hat{y} = 3 \tanh(\cdot) \in [-3, 3]),$$

多任务联合损失为

$$\mathcal{L} = \text{CE}(\text{softmax}(\text{logits}), y_{cls}) + \lambda_r \cdot |\hat{y} - y_{reg}|_{\text{mean}},$$

其中 $\lambda_r = 1$ ，分类与回归等权冻结。

机制一：缺失状态编码（输入端）。结构状态 s_j 为类别量，在数值公式中以内容位指示量出现：记 $\chi_j = \mathbf{1}[s_j = \text{内容位}]$ 。模态 m 在位置 j 的输入嵌入为

$$z_j^m = p_j + \tilde{x}_j^m + (1 - a_j^m) e^m,$$

其中 $\tilde{x}_j^m$ 由选择运算定义： $a_j^m = 1$ 时取 x_j^m 、否则取 0——数学上等价于门控乘积 $a_j^m x_j^m$ ，但实现采用选择而非乘法，保证不可用位的特征值（包括数值异常占位）物理上不进入计算图（“缺失位不得读取”）。 p_j 为可学习位置嵌入、 e^m 为按模态独立的缺失嵌入；整模态缺失时输入退化为 $p_j + e^m$ 而非全零——缺失本身成为显式输入变量。

机制二：可用性约束跨模态注意力。对每个方向 $q \leftarrow e$ （共六个方向），证据可用性定义为 $m_j^e = \chi_j a_j^e$ 。缩放点积注意力 [6] 的单头形式（多头为其并行推广；实现为工作维 64、2 头）：

$$\omega_{jj'} = \text{softmax}_{j'} \left(\frac{(W_Q z_j^q)^\top (W_K z_{j'}^e)}{\sqrt{d_h}} + \log m_{j'}^e \right), \quad A_{q \leftarrow e}(j) = W_O \sum_{j'} \omega_{jj'} m_{j'}^e W_V z_{j'}^e.$$

$m^e = 0$ 的位置经 $\log m = -\infty$ 在 softmax 中获得零权重，值侧再乘 m^e ，构成双侧屏蔽——不可用位不作为证据。实现中另含显式置零分支：当证据模态全部位置不可用 ($\sum_j m_j^e = 0$) 时，注意力输出虽为零、输出投影 W_O 的偏置仍会引入非零值，故该方向输出被直接置零（该分支为代码的确定性处置，非掩码 softmax 的自然结果）。缺失位不作证据，但可作为查询位接受其他模态的上下文补偿。

机制三：可靠性门控融合。每个模态经“线性投影 $\rightarrow$ 内容窗双向 GRU $\rightarrow$ 两个方向注意力增广 $\rightarrow$ 内容位掩码池化”得到模态表示 $\tilde{h}_m$ ；模态覆盖率定义为

$$c_m = \frac{\sum_j \chi_j a_j^m}{\sum_j \chi_j} \in [0, 1]$$

（内容位上的可用比例）。门控与融合为

$$g = \text{softmax} \left(\text{MLP}([\tilde{h}_{\text{text}}; \tilde{h}_{\text{audio}}; \tilde{h}_{\text{vision}}; c_{\text{text}}; c_{\text{audio}}; c_{\text{vision}}]) \right), \quad h = \sum_m g_m \tilde{h}_m,$$

双输出头作用于融合表示 h ；门控输出 g_m 记录为融合层的信任分配，供 5.4 节门控响应检验与第六章一致性分析使用。

模型的整体数据流见图 5.2：左列为缺失场景构造流程（缺失空间参数 $(M, P, r, \bar{l})$ 、可用状态计算 $a = o \cdot (1 - b)$ 、分模态掩码处理），右列为四阶段前向数据流（输入层 $\rightarrow$ 投影层 $\rightarrow$ 缺失鲁棒编码模块 $\rightarrow$ 双头输出），两条虚线：可用状态输入与掩码后特征输入显式连接左右两栏，与代码实现逐条对应。从图中可以看出，三个机制恰好对应数据流的三个环节——输入端（状态编码）、交互端（注意力约束）与融合端（门控响应），观测状态自下而上贯穿全程；输入维度为附件 2 官方 74/35。

5.3 训练方案与模型阶梯

训练方案给出 MRFN 的统一训练配方；模型阶梯通过 $B0 \rightarrow B1 \rightarrow B2 \rightarrow B3 \rightarrow \text{MRFN}$ 五级递增值定位各机制增益——前四级每级只增加一个机制、回答一个机制问题；末级 MRFN 在 B3 之上并引入两处缺失感知修改（机制一与机制三），内部归因由 5.4 节消融拆分 (H6)。

训练方案。优化器 AdamW（学习率 10^{-3} 、权重衰减 10^{-4} ），批大小 32，最多 40 轮、以验证集损失早停（耐心 8 轮），随机种子 1/2/3 各训练一次、报告三者均值。训练期缺失按 5.1 节配比在线生成；配比的设定依据是覆盖原则：训练分布应覆盖评测网格与极端输入状态涉及的观测状态组合——联合与整模态分量提供边界状态覆盖（使模型在模态近乎完全缺失的输入上有训练经验），干净分量（10%）约束干净性能代价；混合训练在鲁棒性




图 5.2 MRFN 缺失场景构造与数据流（左：三级构造；右：四阶段）

增益与干净代价之间的权衡由 5.4 节的迁移对照量化检验 (H4)。文本输入以冻结编码器从附件 2 子词编号重编码（与问题一文本算子同接口，H2 已验证）；语音/视觉使用附件 2 官方维度特征，标准化统计量由训练集拟合、冻结后全程复用。

模型阶梯。为回答“各级机制是否各自带来增益”，构造五级阶梯：**B0**（地板基线）逐模态线性投影 → 内容位掩码池化 → 拼接 → 双头，不使用任何缺失状态；**B1** 各模态独立编码（问题：增益是否来自独立模态编码）；**B2** 模态内换双向 GRU（问题：增益是否来自时序建模）；**B3** 增加六方向跨模态注意力，证据侧带可用性屏蔽（问题：增益是否来自跨模态交互）；**MRFN** 在 **B3** 之上作两处受控修改——输入端以缺失状态编码取代零填充约定、融合端增加可靠性门控（问题：显式缺失感知整体是否带来增益；两个组件的分别贡献见 5.4 节消融）。各级参数量与阶梯评估结果汇总于表 5.1 (**81,284**→**416,839**)。

从表 5.1 可以得出三点观察：其一，**B1** 相对 **B0** 的 S 提升 (**0.736**→**0.749**) 与独立模态编码的引入相对应；其二，**B2**、**B3** 的干净 S 持平 (**0.748**) 而回归误差持续下降 (**MAE 0.644**→**0.631**) ——从结果看，时序与跨模态交互的收益主要体现在回归侧；其三，**MRFN** 相比 **B3** 在干净 S (**0.756**, 五级最高) 与 31 场景平均退化 (**0.028**, 五级最小) 两项指标

上均有改善，且参数量少于 B3（416.8k 对 429.4k）——由于 B3→MRFN 同时改变两个组件，组件级归因留待 5.4 节消融完成。需要说明该表的评测口径：阶梯各级与 31 场景均为测试集上的一次性终评，而模型间的一切选择决策——早停、选型、采纳——均先于测试、在验证集完成（选型分定义见 5.4 节）。

表 5.1 模型阶梯评估结果（附件 2 test；3 种子均值）

模型	参数量	Acc	macro-F1	MAE	Pearson	$\mathcal{S}$	$\overline{D_S}$
B0	81,284	63.7%	60.0%	0.662	0.634	0.736	0.029
B1	93,764	65.7%	61.9%	0.644	0.653	0.749	0.035
B2	255,620	65.8%	61.0%	0.644	0.666	0.748	0.034
B3	429,380	65.0%	61.6%	0.631	0.665	0.748	0.035
MRFN	416,839	66.7%	62.5%	0.634	0.675	0.756	0.028

注：Acc 与 macro-F1 为百分数； $\mathcal{S}$ 为综合效用分， $\overline{D_S}$ 为 31 场景等权平均退化（先场景内 8 实例均值、后 31 场景等权）。




图 5.3 模型阶梯三种子重复性能分布（验证集，B0 为测试集对照）

5.4 鲁棒性评价与实验

本次评测覆盖 31 个缺失场景、8 类缺失实例，共 248 次掩码测试，按”效用——退化率——选型分”三级评价体系给出三条实验结论，完成 H4–H6 的检验。为使不同量纲的指标可比较、可聚合，先将各指标转化为 $[0, 1]$ 上的效用：分类指标（准确率、macro-F1）直接作为效用；回归指标按 $U_{MAE} = \text{clip}(1 - MAE/6, 0, 1)$ 转化——常数 6 为强度标注值域 $[-3, 3]$ 的全宽，即”平均误差达到值域全宽时效用归零”的归一化基准； $U_{Pearson} = (r_p + 1)/2$




图 5.4 缺失场景实验：(a) 退化曲线 (b) 热力图

表 5.2 缺失率-性能退化数值表（附件 2 test，B3/MRFN 并列）

缺失模式 × 率	场景数	S		D_S (相对 clean)	
		B3	MRFN	B3	MRFN
$t@10\%$	1	0.7280	0.7369	0.0272	0.0254
$t@20\%$	1	0.7158	0.7288	0.0434	0.0361
$t@40\%$	1	0.6820	0.7058	0.0885	0.0665
$t@60\%$	1	0.6233	0.6722	0.1671	0.1109
$t@80\%$	1	0.5565	0.6181	0.2563	0.1825
$a@10\%$	1	0.7476	0.7552	0.0009	0.0011
$a@20\%$	1	0.7487	0.7557	-0.0006	0.0005
$a@40\%$	1	0.7488	0.7547	-0.0007	0.0018
$a@60\%$	1	0.7497	0.7535	-0.0020	0.0034
$a@80\%$	1	0.7493	0.7512	-0.0014	0.0064
$v@10\%$	1	0.7480	0.7557	0.0003	0.0005
$v@20\%$	1	0.7489	0.7552	-0.0008	0.0012
$v@40\%$	1	0.7506	0.7544	-0.0031	0.0022
$v@60\%$	1	0.7497	0.7539	-0.0019	0.0029
$v@80\%$	1	0.7502	0.7538	-0.0026	0.0030
$ta@40\%$	1	0.6803	0.7071	0.0908	0.0648
$tv@40\%$	1	0.6808	0.7056	0.0902	0.0667
$av@40\%$	1	0.7505	0.7532	-0.0030	0.0038

注：与图 5.4 共同支撑实验一脆弱性结构——文本缺失率 40% 时 MRFN $D_S = 0.067$ (B3 0.089)、80% 时 0.183 (B3 0.256)，音/视缺失各档 D_S 绝对值 ≤ 0.0064 (MRFN $a@80$ 上界)；双模态联合中含文本档 (ta/tv) 退化近单文本 40% 水平，纯音视联合 (av) 退化 ~ 0 。表给出每档精确 S 与 D_S ，是热力图与文字论述的精确数据底座。

将相关系数自 $[-1, 1]$ 映射到 $[0, 1]$ 。综合效用分 $\mathcal{S} = \frac{1}{2}U_{cls} + \frac{1}{2}U_{reg}$ ，其中 U_{cls} 为两分类指标均值、 U_{reg} 为两回归效用均值。缺失场景的退化率定义为 $D_U = (U_{\text{clean}} - U_r) / \max(U_{\text{clean}}, \varepsilon)$ ；若 D_U 为负，则表示缺失下的效用反而更高。

31 场景网格。评测在固定掩码库的 **31 个场景** 上进行：随机散布单模态 $\{t/a/v\} \times \{10, 20, 40, 60, 80\}\%$ (15 个)、随机散布双模态 $\{ta/tv/av\}@40\%$ (3 个)、连续块 $\{t/a/v\} \times \{\text{头/中/尾/随机}\}@40\%$ (12 个)、联合缺失 $av@40\%$ (1 个)；每场景 **8 个种子化掩码实例**，

合计 **248 次掩码测试**。汇总规则：先对每场景的 8 个实例取均值得到场景值，再对 31 个场景等权平均——”31 场景均值 $\mathcal{S}$ ” 与平均退化 $\overline{D_S}$ 均按此两步计算。全部场景满足 5.1 节的可用性下限；该网格覆盖了 1.1 节要求分析的三类影响因素。

选型分。模型间的一切选择决策使用验证集上的选型分

$$\mathcal{S}_{\text{sel}} = 0.50 \mathcal{S}_{\text{clean}} + 0.25 \mathcal{S}_{\text{text@40}} + 0.15 \mathcal{S}_{\text{text@80}} + 0.10 \mathcal{S}_{\text{jointAV@40}},$$

权重向文本缺失场景倾斜，依据是开发期（验证集、同一掩码库）观察到的脆弱性结构，即 §5.4 实验一；选型分仅用于 5.5 节的改进采纳，不反作用于网格与结论。

结果与三条实验结论。缺失率—性能退化曲线与 31 场景热力图分别见图 5.4(a) 与 (b)。

实验一（脆弱性结构）：**性能退化几乎全部来自文本模态缺失**。文本缺失率 40% 时 D_S 约 **0.07–0.09**、80% 时约 **0.18–0.26**（MRFN 0.067/0.183，B3 0.089/0.256）；语音与视觉缺失在各缺失率下 D_S 均在 0 附近（绝对值 0.005 量级），联合缺失（ $av@40\%$ ）的退化亦接近零。从图 5.4(a) 可直接读出该结构：文本轨随缺失率陡降，语音、视觉轨基本水平。固定覆盖率 40% 下改变连续块长度（散布至单块）对退化无显著影响（附录 D 表 D.1），表明退化由覆盖率与模态身份驱动、而非缺失的连续形态。

缺失位置与缺失时长。两类影响因素——缺失位置 $P \in \{\text{头, 中, 尾, 随机}\}$ 与缺失时长（连续块长 ℓ ）——在题面要求中独立列出。缺失位置： P 维度的 12 个 40% 块场景（ $\{t/a/v\} \times \{\text{头/中/尾/随机}\}$ ）在 31 场景网格中分属 eval_position/eval_mech 两类标签，跨位置 D_S 极差均小于 0.01，可见位置不是退化的主控因素。缺失时长：附录 D 的块长扫描（ $\ell \in \{2, 5, 10\}$ ）、固定 40% 覆盖率、不重叠连续块铺至目标长度）显示文本 D_S 介于 0.048–0.054（极差 0.005，与种子间标准差同量级），语音与视觉保持在 0 附近，可见时长亦不构成主控因素。综合两项，题面”缺失模态类型、缺失位置、缺失时长对预测性能的影响规律”可分别给出结论：**模态身份**（文本 vs 音/视）为主控因素，**覆盖率**（缺失率 r ）次之，**位置与时长**对退化的贡献在当前 31 场景评测精度内不显著。

实验二（架构组件的贡献，H6）：对 MRFN 三个架构组件的消融见表 5.5——移除缺失状态编码、掩码注意力、门控，分别使 31 场景均值 $\mathcal{S}$ 下降 **0.012/0.015/0.017**。结合 5.3 节的阶梯逐级增益，“逐级增、移除则降”的两端证据共同支持 **H6 成立**；5.3 节遗留的两组件归因由此拆分——缺失状态编码与门控的贡献均为正。作为架构外对照，两种经典填充方案（B3+ 零填充、B3+ 前向填充）的 31 场景均值亦低于完整 MRFN（−0.019/ −0.021）。

实验三（缺失增强训练的代价—收益，H4）：训练策略消融与迁移 2×2 （表 5.4，同一架构、只变训练方式）是同一事实的两种视角。定义鲁棒性增益为缺失场景列中两行之差（缺失增强 − 干净训练）= 0.735 − 0.705 = +0.030；干净代价为干净列中两行之差（干净训练 − 缺失增强）= 0.736 − 0.756 = −0.020，负值表示**无干净代价**（缺失增强训练的干净性能反而略高 0.020）。训练策略消融行（移除缺失增强训练，31 场景均值 −0.030）与迁移表左上格相互一致。由此，**H4 在“增益为正、代价不为正”两端成立**。

从图 5.4(b) 可以看出：退化集中于文本系场景所在列，MRFN 行整体颜色最浅（ $\overline{D_S} = 0.028$ ，五级最小），对 B3 的改善也集中在文本系场景——与实验一的文本脆弱性结构相一致，并与实验二的总体消融结果相符。

门控响应 (H5)。门控曲线 (图 5.5) 显示: g_{text} 的分箱均值随缺失率上升而下降 (10%→80% 档自 0.609 降至 0.575), g_{audio} 同向小幅下降 (0.156→0.148), g_{vision} 基本持平 (0.225→0.228) ——响应方向与假设一致。




图 5.5 门控信任随缺失率的响应 (验证集, 三种子均值)

表 5.3 门控信任按缺失率分箱均值 (MRFN 三种子)

缺失率档位	g_{text}	g_{audio}	g_{vision}	档内实例数
10%	0.6048	0.1570	0.2283	8
20%	0.6003	0.1561	0.2288	8
40%	0.5900	0.1541	0.2298	8
60%	0.5782	0.1521	0.2307	8
80%	0.5700	0.1498	0.2312	8
全档单调性	降 ($\Delta = 0.0348$)	降 ($\Delta = 0.0072$)	升 ($\Delta = 0.0029$)	—
Spearman (缺失率, g)	-1.00	-1.00	+1.00	—

注: 与图 5.5 共同支撑 H5—— g_{text} 自 0.605 降至 0.570, g_{audio} 自 0.157 降至 0.150, g_{vision} 自 0.228 微升至 0.231 (基本持平); 响应方向与缺失率同向。 Δ 为 10% 至 80% 极差; 逐档样本 = 档内 8 实例 $\times$ 728 valid 样本。

逐样本的门控一留一模态贡献秩相关在各模态上均为正 (文本 0.198、语音 0.033、视觉 0.077), 其中语音、视觉的关联较弱。按判据: 各模态响应方向一致且秩相关为正, **H5 判定成立**, 但样本级关联强度弱; 该结果与第六章门控一贡献一致性的分析互补。

5.5 模型改进与终评

八轮预注册筛选, 七轮负结果、一轮采纳。本节在预注册纪律下确定正式模型 MRFN 与补充变体 MRFN+ 的主次关系, 并在测试集上完成追加终评。

表 5.4 2×2 迁移表（同架构只变训练方式， $\mathcal{S}$ ）

训练方式 \ 测试	clean test	31 场景均值
clean 训练	0.736	0.705
缺失增强训练	0.756	0.735

注： $\mathcal{S}$ 为综合效用分；clean test 为附件 2 测试集 clean 子集；31 场景均值为评测网格的等权平均（先场景内 8 实例、后 31 场景）。

表 5.5 组件消融与填充基线（ $\mathcal{S}$, Δ 相对完整 MRFN）

变体	参数量	clean $\mathcal{S}$	31 场景均值 $\mathcal{S}$	Δ
MRFN（完整）	416,839	0.756	0.735	—
去除缺失状态编码	413,447	0.739	0.723	-0.012
去除掩码注意力	416,839	0.741	0.719	-0.015
去除门控	432,772	0.733	0.718	-0.017
去除缺失增强训练	416,839	0.736	0.705	-0.030
B3 + zero 填充基线	429,380	0.737	0.716	-0.019
B3 + 前向填充基线	429,380	0.736	0.714	-0.021

注：clean $\mathcal{S}$ 与 31 场景均值 $\mathcal{S}$ 为综合效用分（0-1）； Δ 相对完整 MRFN。

改进协议：预注册。测试集主表一经终评即冻结；改进轮次全程只消费训练集与验证集；每轮改进预先登记验收门槛——选型分提升 $\geq +0.003$ 、干净准确率下降 ≤ 0.5 个百分点、干净 $\mathcal{S}$ 下降 ≤ 0.003 、文本 @80 退化改善 ≥ 0.015 、联合 @40 恶化 ≤ 0.005 、种子间波动不增——未全过即回滚。

改进轮次与负结果。共八轮改进：前七轮各围绕单一改进主题（表 5.6），均未通过验收门槛、按规则回滚（ λ_r 维持 5.2 节的冻结值 1）。七轮负结果沉淀出两条观察：其一，在已测试的候选改动中，干净性能与文本鲁棒性表现出稳定的权衡，没有任何一轮同时改善两者；其二，共享缺失调度种子后 $\mathcal{S}$ 的种子间标准差降至万分之一个百分点量级，训练期缺失安排对种子间差异有显著影响。负结果与 5.4 节消融共同显示了改进的边界。

采纳：第八轮组合改进。第八轮为围绕文本表示质量的组合改进，同时修改三处：解冻编码器最后 1 层（学习率 5×10^{-5} 、可训练参数 7.09M）、训练混合 B 分量中文本条目的抽样权重加倍、检查点选择改为选型分早停（微调中的编码器现场重编码，无缓存污染）。该组合在验证集上六项门槛全部通过：**选型分** +0.0225（门槛 +0.003）、**干净准确率** +1.19

表 5.6 前七轮改进候选与结果——验证集

轮次	改进主题	结果
1	鲁棒早停	回滚
2	逐样本缺失抽样	回滚
3	内容窗 GRU	回滚
4	层归一化门控	回滚
5	证据池化	回滚
6	回归损失权重减半 ($\lambda_r=0.5$)	回滚
7	BERT 解冻两层	回滚

个百分点、干净 $S + 0.0076$ 、文本 @80 退化自 0.175 降至 0.130（改善 0.045，约为门槛的三倍）、联合 @40 退化为负，缺失下反而略升、种子间标准差减半。组合的增益为三处修改的联合效果，本文不拆分归因；该组合按协议采纳为 **MRFN+**。

主次关系与追加终评。**MRFN 为测试集主表冻结正式模型**；MRFN+ 为验证集预注册筛选采纳的补充变体，仅用于附件 3 与附件 4 的最终推理。MRFN+ 在测试集上追加一次终评（表 5.7）：单模型三种子均值 **67.45%**、三种子集成 **68.64%**，同口径下相对主表 66.71% 分别**提升 0.74 与 1.93 个百分点**。MRFN+ 未做 31 场景评估、不构造鲁棒性曲线、不替换主表；其通过伴随鲁棒性条款约束，与前述权衡观察一致。

表 5.7 最终测试集结果（附件 2 test，clean 口径）

模型	评估批次	Acc	macro-F1	MAE	S
MRFN	主表首次 test	66.71%	62.52%	0.634	0.756
MRFN+（单模型均值）	预注册追加 test	67.45%	62.80%	0.644	0.760
MRFN+（3-seed 集成）	预注册追加 test	68.64%	63.86%	0.614	0.769

注：MRFN 为主表冻结正式模型；MRFN+ 为预注册追加评估的补充变体，未做 31 场景评估、不构造鲁棒性曲线；单模型均值与三种子集成为不同口径，不可直接比较。

5.6 预测与行为分析

附件 3 共 30 条无标签样本，含 131 个联合零行，单样本最高联合缺失率 50%——其在真实缺失下给模型提出了与评测网格不完全相同的输入。本节完成附件 3 的全量预测与两项未预期行为分析；全部产出仅为预测结果与过程证据，不做任何精度声明（1.2 节约束）。

预测结果。**30 条样本全部完成预测**，推理模型为 MRFN+ 三种子概率/回归集成；结果文件包含每条样本的极性、强度与校准置信度（随附录 C 给出）。置信度按验证集 NLL 拟合的温度校准 [7] ($T = 1.2142$)，校准后期望校准误差自 0.0424 降至 0.0347，且校准保持 argmax 不变；**预测分布为负/中/正 = 7/10/13**。

输入侧缺失统计。**30 条样本共 605 个内容位**，其中语音/视觉联合零行 **131 个 (21.7%)**；27 条样本存在局部联合缺失，单样本联合缺失率最高 50%（均值 20.7%）。这与 5.4 节联合缺失机制所参照的实测模式一致——附件 3 的真实缺失集中表现为音视同位置联合缺失，文本无缺失。

行为分析（图 5.6）。分析围绕两项运行前登记的行为预期展开：其一，门控响应预期——若模型在音视缺失时向文本转移信任， g_{text} 应随音视缺失率上升；实测高、低缺失半区为 0.616 对 0.638（Spearman = -0.195），未观察到预期的单调重分配，与 5.4 节实验一中”音视缺失下退化接近零”的观察一致。其二，text-only 趋同预期——若音视信息可弃，全模型预测应向仅文本输入趋同；实测整体一致率 0.733，且高缺失组（0.600）低于低缺失组（0.867），预期未成立。两项结果共同表明：模型对音视信息的利用虽小但并非零，且不随其缺失率平滑切换。此外，单种子与集成预测的极性一致比例在三个种子上分别为 0.767/0.767/0.800；困难样本清单（音视平均缺失率降序、同率按校准置信度升序，取前 5 条）随附录 C 交付。




图 5.6 附件 3 行为分析（MRFN+ 集成，30 条，无标签）

图 5.6 将联合缺失率、 g_{text} 、text-only 一致率与预测极性分布并置；行为分析与 31 场

表 5.8 附件 3 行为分析关键指标 (MRFN+ 集成)

指标	全样本	高缺失半区	低缺失半区
样本数 n	30	15	15
平均联合缺失率	20.67%	—	—
单样本最高联合缺失率	50.0%	—	—
存在局部联合缺失样本数	27	—	—
音视平均缺失率 (g_{text} 均值)	—	0.6158	0.6384
g_{text} -音视缺失率 Spearman		-0.1955	
整体 text-only 一致率	0.7333	—	—
text-only 一致率 (按音视平均缺失率分半区)	—	0.6000	0.8667
预测极性分布 (负/中/正)		7 / 10 / 13	
校准温度 T		1.2142	
校准后期望校准误差 ECE		0.0347 (自 0.0424)	
argmax 不变 (校准前后)		30/30	
单种子间极性一致比例 (seed 1/2/3)		0.767 / 0.767 / 0.800	

注：与图 5.6 共同支撑两项行为预期报告——门控响应预期未观察到 (hi/lo g_{text} 0.616 对 0.638、Spearman -0.195)、text-only 趋同预期未成立 (高/低缺失组 0.600 对 0.867)。结论与 §5.4 实验一“音/视缺失下退化接近零”互为补充。困难样本清单 (前 5 条按音视平均缺失率降序、同率按校准置信度升序)：附件 3_30/29/27/17/28，随附录 C 交付。

景网格相互对照——网格给出受控合成场景下的规律，附件 3 给出真实缺失输入上的行为样例。

错误归因。两条结构性观察如下：其一，**Z0/Z1 两带的错误份额合计约 64% (MRFN) 与 68% (MRFN+)**——错误主体集中在弱带与中性带，强极性带 (Z2) 相对易判；MRFN+ 在 Z2 提升 3.2 个百分点的同时，Z0 略降 2.2 个百分点，呈现同一架构下“强带更准、弱带持平”的可重复观察——按 $|\hat{y}|$ 分区的准确率排序未变，错误归因结构未被推翻。其二，**标签的符号 oracle 准确率为 100%** (按 $\hat{y}$ 符号反推 cls 全中)，上限由特征侧弱情感分辨力决定，决策侧四种调整——阈值、类别权重、阈值兼权重、回归口径——对 Z0/Z1 准确率的改动均不超过 1 个百分点 (弱带主体未改变)，属系统性而非工程性瓶颈。诊断详情见 7.4 节错误归因层。数据按 $|\hat{y}|$ 分区列于表 5.9 (验证集 728 条，MRFN / MRFN+ 各三种子均值)：

表 5.9 按 $|\hat{y}|$ 分区的准确率 (MRFN / MRFN+)

带	定义	n	MRFN 准确率	MRFN+ 准确率
Z0: 中性	$ \hat{y} = 0$	184	0.480	0.458
Z1: 弱极性	$0 < \hat{y} \leq 0.5$	147	0.435	0.447
Z2: 强极性	$ \hat{y} > 0.5$	397	0.751	0.783

6 问题三：可解释情感预测模型的建立与求解

仅给出极性与强度的预测值无法独立复核判断依据。本章在冻结的 **MRFN+** 之上叠加反事实解释框架：**模态级贡献由精确 Shapley 值度量，位置级归因由积分梯度给出**，两套反事实参照使证据可回溯至原词与物理时间；解释可信性按运行前冻结的 **A-F 六项判据** 验证。

6.1 解释任务的形式化

问题三要求在预测结果之外给出判断依据——以可量化、可复核的方式说明本次判断主要依据了哪些模态、哪些时间位置的输入。每条样本的解释输出包含五要素：极性/强度、模态贡献 φ_m 、主要参考模态、关键证据与物理时间区间，对应完备性、保真性、一致性与可回溯性四项性质；本节同时明确两套反事实参照的分工：**Shapley 使用联盟级 $v(\emptyset)$ ($\text{avail} \equiv 0$)，IG 使用条件特征基线 ($\text{avail} \equiv 0$ ；缺失架构在全部模态未观测时梯度归零)**。

网络结构与输出规格。解释框架在冻结 **MRFN+** 之上叠加归因层，**不引入新预测网络、不重新训练、也不新增可训练参数**。归因层对 **MRFN+** 输出执行两次解释计算，即 **8 联盟全枚举 (Shapley)** 与 **50 位网格上中点 64 步积分 (IG)**，二者共享同一预测器与同一输入接口。解释对象为冻结 **MRFN+** 集成（三种子概率与回归平均），每条样本输出**五要素**：极性、强度、各模态带符号贡献 φ_m 、主要参考模态、关键证据及其物理时间区间 $[t_s, t_e)$ 。

模态级贡献由精确 Shapley 值度量 [8]，其联盟级 $v(\emptyset)$ 对应三模态全部未观测的状态；位置级归因由积分梯度度量 [9]，其条件特征基线保持自然观测、特征取缺失参照值。IG 不取联盟级参照的原因是结构性的：缺失感知架构在全部模态未观测时阻断一切特征梯度，位置归因恒为零。两套参照的构造规则与 5.4 节合成缺失算子保持一致，使干预输入的状态与训练所见状态可对应。

H7 验证状态。H7 判据要求归因保真度优于无缺失训练对照，但所需对照实验未执行，故如实报告：H7 的预注册判据未完成验证；现有证据仅支持分布覆盖性，即除空联盟外，Shapley 的 7 个联盟输入与 IG 的基线输入均落在问题二训练缺失生成机制的组合空间之内。

四项性质目标。**完备性** ($\sum_m \varphi_m = v(N) - v(\emptyset)$ 精确成立，6.2 节)、**保真性** (按归因序删除的预测偏移显著大于随机序，6.4 节)、**一致性** (门控信任与实际贡献趋势一致，6.4 节)、**可回溯性** (每个归因位可映射到证据与物理时间，6.3、6.5 节)。

6.2 模态级 Shapley 模型

模态作用程度以合作博弈的精确 Shapley 值度量——8 联盟全枚举，权重按精确分数 $\frac{|S|!(3-|S|-1)!}{3!}$ 计算。本节依次给出 Shapley 公式、联盟输入构造与三项公理校验：哑玩家公理由样本 #13 视觉整模态自然缺失的真实数据实证 ($\varphi_v^{\text{cls}} \equiv [0, 0, 0]$ 、 $\varphi_v^r = 0$)；附件 4 与附件 2 测试集 5 条重合样本的锚点自检 5/5 预测一致。

联盟值的构造。记模态全集 $N = \{\text{文本, 语音, 视觉}\}$ ，共 8 个联盟。对联盟 $S \subseteq N$ ，联盟值 $v(S)$ 通过对补集模态执行合成缺失得到： S 内模态保持自然观测， S 外模态的内容

位全部抹除——文本在编码前将相应子词替换为 [MASK] (3.1 节规则)，语音/视觉置零； $v(\emptyset)$ 为三模态全部未观测的状态，此时输入非全零——由 5.2 节机制一，位置嵌入与缺失嵌入仍构成输入。构造规则与 5.4 节合成缺失算子一致。分类与强度双输出分别取联盟值 $v^{cls}(S) \in \Delta^3$ ，预测概率向量与 $v^r(S) \in [-3, 3]$ ，均为三种子均值口径。

精确 Shapley 值。三模态的全部联盟仅 8 个，可精确枚举：

$$\varphi_m = \sum_{S \subseteq N \setminus \{m\}} \frac{|S|!(3 - |S| - 1)!}{3!} [v(S \cup \{m\}) - v(S)],$$

权重以精确分数 (1/3, 1/6, 1/3) 参与计算，避免浮点权重误差；分类输出逐类计算带符号 $\varphi_m^{cls} \in \mathbb{R}^3$ ，强度输出为标量 φ_m^r 。主要参考模态取

$$m^* = \arg \max_m |[\varphi_m^{cls}]_{\hat{y}}|,$$

其中 $[\cdot]_{\hat{y}}$ 为预测类 $\hat{y}$ 对应的分量。

公理校验 (表 6.3)。**效率公理精确成立** (残差见 §6.1)；**哑玩家公理由样本 #13 视觉整模态自然缺失给出真实数据实证**： $\phi_v \equiv 0$ 时该模态输入嵌入、证据可用性、覆盖率均逐位相同， $\varphi_v \equiv 0$ 严格成立。附件 4 与附件 2 测试集 5 条重合样本的锚点自检 5/5 一致 (仅作内部自检、不参与选择决策)。

贡献分布 (表 6.2、图 6.1)。**20 条样本的主导模态分布为文本 18、视觉 2、语音 0**，与问题二“文本主导”的实验结论一致；高置信样本 (校准置信度 > 0.97) 呈大 φ_{text} (预测类 0.55–0.68) 配微小的 φ_a, φ_v 。方向性信息同样可读：如样本 #04 (预测负类) 的 $\varphi_{\text{text}} = (+0.36, -0.08, -0.28)$ ，文本同时支持负类并抑制正类——带符号贡献在解释卡中直呈。图中左侧的带符号贡献堆叠显示文本占绝对主体、#13 的视觉贡献恒零 (哑玩家实证)；右侧 TOP-8 原词证据对应高贡献样本，词级证据回溯经问题一网格完成 (20 条样本全部建立位置——原词映射)。

6.3 位置级积分梯度模型

位置级重要性以积分梯度 (IG) 度量。本节将 IG 形式化为四个要点：可微层级、三基线对照 (missing/zero/mean)、词级质量守恒聚合与架构级零归因阻断。验证结论为：全 40 项 IG 检验通过、最大相对误差 0.62%；零泄漏性质在 3 基线 $\times$ 2 输出 $\times$ 3 模态 $\times$ 逐种子的全部组合下成立 (结构位与不可用位归因逐位精确为零)。

可微层级与基线。文本的积分梯度路径定义在编码器输出嵌入层 $E \in \mathbb{R}^{50 \times 768}$ 上 (各种子使用其微调编码器、冻结求值)，插值路径为

$$E(\tau) = E' + \tau(E - E'), \quad \tau \in [0, 1],$$

绝不对离散子词编号做数值插值；语音/视觉路径定义在标准化连续特征上。统一公式中的 x, x' 按模态取不同对象：文本取 $x = E, x' = E'$ (输出嵌入及其基线)，语音/视觉取 x 为标准化特征、 x' 为对应基线值。可用掩码固定为自然观测 (可用性判定含阈值切分、不可




图 6.1 模态贡献与词级证据回溯 (附件 4, 20 条)

三模态 Shapley 贡献分布 (附件4, 20 条样本, 预测类带符号)




图 6.2 三模态 Shapley 贡献密度 (附件 4, $n = 20$)

微, 故不做掩码插值)。基线取 6.1 节分名的条件特征基线: 文本为全部子词 [MASK] 重编码所得嵌入, 语音/视觉取缺失参照值; 敏感性检验另设零向量与训练均值两种基线。

积分梯度与数值求积。积分梯度作用于三种子集成的预测函数 F : 分类目标取集成预测类的 logit, 集成为三种子模型输出的均值函数, 故其梯度等于各种子梯度之均值——与逐种子计算后平均在数学上等价; 完备性检验的对象即该集成函数。与 6.1 节的“两套参照分名”相应, 此处区分两套目标函数: 模态级贡献与删除/插入检验作用于概率函数 (三种子 softmax 概率的均值), 位置级积分梯度作用于集成 logit 分数函数 (积分梯度的 Score 约定, 完备性对分数成立); 二者解释同一冻结预测器的不同侧面, 口径分列、不混用。位

表 6.1 三模态 Shapley 贡献分位数（附件 4， $n = 20$ ）

模态	度量	min	Q25	median	Q75	max	跨度
文本	$ \varphi_{\text{text}} $	0.050	0.185	0.401	0.531	0.682	0.632
语音	$ \varphi_{\text{audio}} $	0.008	0.020	0.029	0.045	0.157	0.149
视觉	$ \varphi_{\text{vision}} $	0.000	0.021	0.034	0.076	0.199	0.199
文本	$\varphi_{\text{text}}^{[\hat{y}]}$ （预测类）	-0.097	0.185	0.401	0.531	0.682	0.779
语音	$\varphi_{\text{audio}}^{[\hat{y}]}$	-0.157	-0.023	0.006	0.034	0.119	0.276
视觉	$\varphi_{\text{vision}}^{[\hat{y}]}$	-0.123	-0.001	0.023	0.036	0.199	0.322

注：与图 6.2 共同支撑“文本主导”结论—— $|\varphi_{\text{text}}|$ 中位数 0.401 约为音视中位数 0.029/0.034 的 12–14 倍；文本跨度 $[0.05, 0.68]$ 、音/视 $[\sim 0, 0.20]$ 。20 条样本主导模态分布：文本 18 / 视觉 2 / 语音 0（详见表 6.2 方向性计数）。样本 #13 视觉整模态自然缺失使 $|\varphi_v|_{\min} = 0$ 。

表 6.2 模态 Shapley 方向统计（预测类带符号 φ ）

模态	$\varphi > 0$	$\varphi < 0$	主导
text	19	1	18
audio	10	10	0
vision	13	7	2

置 j 的归因定义为

$$\text{IG}_j = (x_j - x'_j) \int_0^1 \frac{\partial F}{\partial x_j} \left(x' + \tau(x - x') \right) d\tau,$$

数值上采用 64 步中点 Riemann 求积（ $\tau_k = (k - 0.5)/64$ ）；强度目标取强度输出。

精度检验（表 6.4）。完备性残差按逐样本、逐输出检验： $|\sum_j \text{IG}_j - \Delta F|$ 不超过 $\max(0.05|\Delta F|, 10^{-3})$ ，在 20 条样本 $\times$ 2 类输出共 **40 项检验上全部通过**，最大相对误差 **0.62%**。求积规则经消融确定：32 步右端点在 6 个样本上超出阈值（最差 11.1%），64 步

表 6.3 Shapley 完备性检验（效率公理最大残差）

输出头	最大残差	门槛	通过
分类	3.0×10^{-8}	1×10^{-5}	20/20
强度	4.4×10^{-16}	1×10^{-5}	20/20

中点将其压至 0.62%。

基线敏感性。该项检验以三对基线在内容位上逐样本计算排序 Spearman：各对、各模态的均值均 ≥ 0.96 ，单样本最低 0.76（缺失参照与零向量的视觉通道）。语音/视觉的缺失参照与训练均值在标准化空间数值重合，不构成有效对照；实质性对比为文本通道三基线之间、以及缺失参照与零向量之间的对比，均值亦在 0.96 以上。

词级聚合。位置归因经问题一的映射聚合到原词：位置—原词映射在全部 20 条样本（含 2 条截断样本）上建立，词内均匀权 $\alpha_j = 1/n_w$ 提供归属与权重；词级归因取质量守恒求和

$$A_w = \sum_{j \in w} \text{IG}_j,$$

保证词级完备性 $\sum_w A_w = \sum_j \text{IG}_j$ ；被 50 位网格截断的整词标记为未覆盖（共 22 词），不生成证据。

零泄漏性质。结构位（CLS/SEP/填充位）与不可用位的归因，在全部“3 基线 $\times$ 2 输出 $\times$ 3 模态 $\times$ 逐种子”组合下恒为零（逐位精确为 0）。这由 5.2 节机制保证：选择运算使不可用位不进入计算图、值侧屏蔽使其不作为证据，梯度不经由这些位置。因此，**零归因是架构级性质而非数值巧合**：在本章的 IG 归因路径与 5.2 节架构下，缺失证据不进入位置归因。

图 6.3 中，三种基线下的归因排序高度一致（与敏感性数值相符），积分完备性残差集中于远低于阈值的区间；其中关于 IG-LOO 一致性的对比——音视局部干预强一致、文本未达门槛——属于保真度检验范畴，在 6.4 节展开。

表 6.4 IG 验证结果（条件特征基线）

验证项	实测	门槛/口径	判定
积分误差（64 步中点）	40/40	max rel 0.62%	通过
阻断位泄漏	$\max \text{IG} =0$ （逐位精确）	3 基线 $\times$ 2 输出 $\times$ 3 模态	通过
#13 哑玩家	$\max \text{IG}_v =0$ （逐位精确）	$\varphi_v \equiv 0$	通过
问题一网格映射	20/20	截断词 22 个未覆盖	通过
基线排序敏感性	$\bar{\rho}_{min}=0.961$	≥ 0.96	通过
稳定性 t/a/v	0.997/0.995/0.984	text ≥ 0.6	通过




图 6.3 IG 验证与 F 项诊断（三基线排序一致性）




图 6.4 TOP-20 关键词 IG 贡献（附件 4 词级聚合）

6.4 解释可信性验证

本节以运行前冻结的六项保真度检验核验解释可信性：**A** 删除优越性、**B** 插入优越性、**C** Comprehensiveness/Sufficiency、**D** 随机化坍塌、**E** 扰动稳定性、**F** IG-LOO 一致性。综合结果为前五项通过、F 项未通过并给出结构性诊断——**A 19/20 胜 (mean AOPC 0.166)**、**B 20/20 胜 (mean ΔAUC 0.129)**、**C compr = 0.306 > |suff| = 0.098**、**D 各模态中位 Spearman ≤ 0.267**、**E text 0.997/audio 0.995/vision 0.984**；F 项 text 单点 LOO 未达门槛 (**0.170 < 0.3**)，三步结构性诊断给出机制解释（BERT [MASK] 重编码属非局部干预，与 a/v 局部干预 $\rho_{\text{abs}} = 0.74/0.73$ 形成对照），H8 由此落定为**部分成立**。本节末段以 $g\text{-}\varphi$ 一致性分析（验证集全量 728 条，text Spearman **0.716**，argmax 一致率 **90.7%**）作为补充证据。

判据定义。删除/插入证据序为三模态可用位按 $|IG|$ 跨模态合并降序（零泄漏性质保

证不可用位不进入)；删除自自然观测起逐位执行问题二的抹除算子，插入自条件特征基线态起逐位恢复，对照为 5 组种子化随机序。A——删除优越性 (AOPC)；B——插入优越性 (ΔAUC)；C——compr/suff@0.2 (评价思想参考 ERASER[10])；D——权重随机化坍塌 (重置预测头后排序相关显著降低)；E——5% 噪声下 IG 排序 Spearman；F——IG-LOO 全秩 Spearman 及 TOP-20% 重合率。

检验结果 (表 6.5、图 6.5)。**A-E 通过**：A——AOPC 均值 0.166、19/20 胜 (唯一例外 #19, -0.08)；B—— ΔAUC 均值 0.129、20/20 胜；C——compr@0.2 均值 **0.306 对 |suff| 0.098**；D——各模态中位 ≤ 0.267 ；E——文本 mean ρ **0.997** (音/视 0.995/0.984)。

F 项未通过。文本通道全秩 Spearman **0.170**，低于专项门槛 0.3，如实报告、不移动门槛。诊断三步：其一，同输入重复计算差为零，排除计算误差；其二，音/视删除是局部干预，IG-LOO 一致性 $\rho = 0.739/0.732$ 、TOP-20% 重合 76%/71%——IG 在局部干预语义下忠实；其三，文本删除需 [MASK] 重编码、属非局部干预 (掩码推断即 BERT 预训练目标)，故 LOO 在文本通道近似度量“上下文可推断性”而非“嵌入敏感度” (与 IG 属不同反事实， $|\Delta p|$ 秩相关 0.213、TOP-20% 重合仅 29%)。

方法边界。IG 的参照 (条件特征基线) 与删除/插入的干预 (抹除算子) 分属两条路径：A/B/C 证明的是操作性保真度——按 IG 排序选出的证据在实际缺失干预下确为关键证据——而非同路径的积分验证；单点文本 LOO 则受非局部干预限制。二者在文中分开表述，不相互替代。

H8 部分成立。位置归因沿映射链回溯成立；局部干预下归因排序与删除响应秩一致成立 (音/视 $\rho \approx 0.73$)；文本 IG-LOO 未达专项门槛 (0.170 对 0.3)，语义边界已由上述诊断界定，未达标部分已给出机制解释。




图 6.5 删除/插入保真度曲线 (归因序与随机序对照)

门控一贡献一致性。门控 g_m 是融合层的信任权重， φ_m 是对预测输出的反事实贡献，二者含义不同，此处验证的是趋势一致性而非等同性。在附件 2 验证集全量 728 条样本上，对每条样本同时计算三种子均值口径的 g_m 与 φ_m (取预测类分量的绝对值)：文本通道 Pearson/Spearman 为 0.711/0.716，语音 0.186/0.106、视觉 0.228/0.213 呈弱正相关，argmax

表 6.5 解释保真度六项检验结果（判定与预注册门槛）

门槛	实测	预注册规则	判定
A 删除	0.166 (胜 19/20)	均值 >0 且 $\geq 15/20$	通过
B 插入	0.129 (胜 20/20)	均值 >0 且 $\geq 15/20$	通过
C 全面/充分	compr=0.306, suff =0.098	compr >0 , suff $<$ compr	通过
D 随机化坍缩	median ρ max 0.267	≤ 0.3	通过
E 稳定性 (text)	0.997	≥ 0.6	通过
F text IG-LOO	0.170	≥ 0.3	未通过

注：F 项结构性诊断——a/v 局部干预 $|\rho|=0.74/0.73$ 强一致；text [MASK] 重编码为非局部干预，与嵌入层 IG 属不同反事实，故 IG-LOO 一致性低（详见正文 6.4 节）。

一致率 **90.7%**，逐样本散点见图 6.6。音/视通道相关较弱（0.11–0.23）且贡献量级微小（6.2 节分布），本文不对二者建立解释性关联；该结果与 5.4 节门控响应检验互证——前者看”信任—贡献”的对应，后者看”信任—缺失”的响应。从图中可以看出，文本通道的点云随贡献增大整体上移，音视通道集中于低信任、低贡献区域——散点形态与分模态数值（0.72 对 0.11–0.21）一致。




图 6.6 门控—贡献一致性散点（附件 2 验证集，728 条，分模态）

门控—贡献一致性的逐模态 Pearson 与 Spearman 数值见表 6.6。

6.5 解释结果与分析

附件 4 的解释结果从预测分布、主导模态、证据覆盖与解释卡四个维度报告：**预测分布为正 10 / 负 7 / 中 3**，主导模态文本 18 / 视觉 2 / 语音 0。证据沿问题一的映射链回溯到原始素材的物理时间——全部产出不做精度声明（无标签测试）。

表 6.6 门控-贡献一致性 (valid, $n = 728$)

模态	cls Pearson	cls Spearman	reg Pearson	reg Spearman
文本	0.711	0.716	0.644	0.596
语音	0.186	0.106	0.166	0.134
视觉	0.228	0.213	0.253	0.246

证据回溯链。解释的证据链为：模型位置 $j \xrightarrow{\text{问题-网格}}$ 原词（词归属 κ ） $\xrightarrow{\text{CTC 强制对齐}}$ 物理时间 $[t_s, t_e]$ 。附件 4 与问题一的 100 条源样本无重合，故对 20 条视频现场重生成对齐资产（词—子词映射与 50 位网格构造的断言均已通过）；其中 9 条零失败，含失败词的样本其词时间按 4.4 节插值规则给出，对齐状态标记逐行透传于证据表；证据定位长表 60 条证据全部带物理时间区间，其中 57 条由直接对齐给出、3 条由插值给出，无不可验证条目。

置信度。按问题二验证集拟合的温度 $T = 1.2142$ 校准，校准保持 argmax 不变 (20/20)。

全量结果。按 $|\text{IG}|$ 排序的全局跨模态 TOP-3 证据在全部 20 条样本上均为文本证据——与 §6.2 贡献分布及问题二实验一一致。逐模态 TOP-1 证据表给出文本原词与时间区间、语音声学证据区间、视觉证据区间并渲染区间中点关键帧（19 张；样本 #13 视觉整模态自然缺失、无证据）。语音/视觉特征无官方维名字典，音视证据的语义描述止于时间区间级。带符号模态贡献总览见图 C.1。

解释卡（图 6.7）。三例样本：#09 强负文本主导、#14 视觉主导（20 条中仅 2 例）、#13 视觉整模态缺失（ $\varphi_v \equiv 0$ ，纯文本—语音解释）。所有证据带物理时间区间，左列预测与模态贡献、右列 TOP-5 原词证据一一对应。



图 6.7 解释卡三例（附件 4，MRFN+ 集成）

7 模型评价

各问指标一律引用回指，已在前文证明的结论不再重证。本章分四层汇总局限与改进方向。

7.1 模型优点

综合三部分实验，本文方法的核心特色可归纳为四个维度：表示基础、训练评测同源、解释公理化、过程可溯源。分述如下。

其一，表示基础可靠。三个问题共用问题一交付的统一时序坐标系：序列位置体系、观测状态定义、位置—物理时间映射，“特征零值不自动等于缺失”的前提贯穿全文（3.1 节）；该体系经受住四类验收指标检验（4.5 节），使训练、评测与解释作用于同一位置语义。

其二，缺失感知训练—评测同源。统一的缺失构造规则覆盖问题二的训练与评测，并为问题三的反事实干预提供状态可对应的构造（5.4、6.1 节）；缺失作为显式输入进入编码、注意力与门控三个环节，其代价—收益由迁移对照与消融验证（H4、H6 成立）。

其三，解释的公理化与可验证性。模态级贡献采用 8 联盟精确 Shapley、位置级归因采用积分梯度，效率公理、完备性与零泄漏等公理性质均通过检验（6.2、6.3 节）；解释可信性以运行前冻结的判据检验，未通过项如实呈现（6.4 节）。

其四，全过程的可溯源纪律。验收门槛实验前冻结、未通过项如实呈现（F 项、七轮改进回滚、H7 判据缺位），关键产物以清单与指纹登记（见第二章）；全部实测结果可溯源至冻结产物，具备可复现性。

7.2 三问联合验证

本节把三个问题各自给出的证据链放到同一坐标下作联合分析：融合层的信任分配（门控 g_m ）、输入的判别信息（删除干预下的性能变化与错误分区结构）与解释层的实际贡献（ φ_m ）是否指向一致的结构。三者度量对象不同，本节做关系分析而非相互证明。

三条证据链同向指向文本主导：其一，文本缺失造成的退化显著高于语音与视觉缺失，判别信息集中于文本（5.4 节实验一）；其二，模态贡献分布为文本 18/20 主导（6.2 节）；其三，主通道的门控—贡献 Spearman 为 0.716、argmax 一致率 90.7%（6.4 节），且门控对文本缺失率的响应方向成立（H5）。边界如实呈现：音/视通道的门控—贡献相关较弱（0.11–0.23）；文本单点删除与 IG 属不同反事实语义（6.4 节 F 项诊断），“贡献”的两种度量在文本上不重合，是最实质的边界；文本主导不等于文本充分——弱极性带承载错误主体（7.4 节），信息量一侧约束了三条证据链的共同上限。

7.3 灵敏度与稳定性分析

本节只汇总已有的实测结果，不新增实验。解释对基线选择不敏感（三对基线下归因排序 Spearman ≥ 0.96 ），对输入扰动稳定（5% 噪声后排序 Spearman 仍 0.997）；模型输出本身的种子间标准差低至万分之一个百分点量级，阶梯与终评均为三种子均值口径。边界：

未对冻结超参数 (λ_r 、 T) 作扫描式敏感性分析。

7.4 局限与错误归因

本节按表示、预测、解释、实验覆盖四层汇总局限并给出错误的结构性归因，均回指正文、不新增断言。

表示层。H1、H3 在机器证据层面成立、待人工签核落定 (4.5 节)；特征无维名字典，语义解释止于时间区间级；对齐输出质量依赖素材，低置信失败只能插值放行 (4.4 节)。

预测层与错误归因。干净性能与文本鲁棒性存在稳定权衡，MRFN+ 为八轮候选中唯一通过全部门槛的组合、未突破该权衡，且未做 31 场景评估 (5.5)。错误归因（按 $|\hat{y}|$ 分区的准确率、MRFN+ 重演一致、决策侧四种手段上限）的完整论述见 §5.6 节末段；此处补充两点延伸观察：其一，弱极性样本的 37% 被判为中性；其二，MRFN+ 集成的双输出误差结构见图 7.1（真中性仅 84/184 判对，强度预测向零收缩；集成口径 $MAE = 0.575$ 、 $Pearson = 0.680$ ）。两项观察共同表明：误差源于极性边界与弱情感区段，而非缺失处理。




图 7.1 MRFN+ 双输出性能与误差结构

注：(a) 三种子概率集成 argmax；(b) 三种子回归均值；(c) 三种子分区准确率均值，冻结口径。

解释层。五条边界：附件 4 无标签、结果不作精度声明；文本单点 LOO 与 IG 属不同反事实语义 (H8 部分成立)；H7 判据未完成验证、仅有分布覆盖性论证；音/视证据语义止于时间区间级；证据时间定位受“自动回放”签核边界约束 (6.4、6.1 节)。其中前两条对全文结论约束最强。

实验覆盖层。未做超参数扫描式敏感性分析 (7.3 节)；H7 对照实验缺位 (6.1 节)；三模态同时全缺失排除在评测网格之外 (5.4 节)。

改进方向与推广。基于上述局限，后续可在以下方向优化：完成人工签核与 H7 对照实验，在弱极性带上增强文本表示的判别信息，发展局部干预语义下的文本归因。推广方面，与本文结构对应性最强的是医学时序监测：多通道异构采样对应统一坐标与双域设计，传感器脱落与伪影对应“零值不等于缺失”的观测状态分离，临床决策可追溯对应证据回溯链。迁移时标签结构与判定门槛须依临床规范重建，解释的临床可用性须另行验证。

本文 MRFN vs 三消融基线性能分布




图 7.2 四项消融变体的性能分布

参考文献

- [1] Amir Zadeh, Paul Pu Liang, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of NAACL-HLT, 2019.
- [3] Florian Eyben, Klaus R. Scherer, Björn W. Schuller, Johan Sundberg, Elisabeth André, Carlos Busso, Mark W. Moore, and Shrikanth Narayanan. The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for voice research and affective computing. IEEE Transactions on Affective Computing, 7(2):190–202, 2016.
- [4] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations. In Advances in Neural Information Processing Systems, 2020.
- [5] Jin Hyun Cheong, Eshin Jolly, Tianmin Xie, et al. Py-Feat: Python facial expression analysis toolbox. Affective Science, 4:771–781, 2023.
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Advances in Neural Information Processing Systems, 2017.
- [7] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In Proceedings of the 34th International Conference on Machine Learning, 2017.
- [8] Lloyd S. Shapley. A value for n-person games. In Contributions to the Theory of Games II, pages 307–317. Princeton University Press, Princeton, 1953.
- [9] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. Axiomatic attribution for deep networks. In Proceedings of the 34th International Conference on Machine Learning, 2017.
- [10] Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher, and Byron C. Wallace. ERASER: A benchmark to evaluate rationalized NLP models. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020.

附录 A 环境与复现

A.1 运行环境

全部版本号取自问题一数据契约 (p1.v2) 的冻结记录, 为本文环境描述的唯一口径:

组件	版本: 冻结值
Python	3.10
PyTorch / torchaudio	2.11.0 / 2.11.0
transformers	5.17.0
openSMILE	2.6.0
Py-Feat	0.6.1
imageio-ffmpeg / ffmpeg	0.6.0 / 7.0.2 (static)

A.2 模型与权重指纹

BERT: bert-base-uncased, revision 86b5e09 (权重 SHA-256 前缀 68d45e234eb4); 对齐声学模型: torchaudio WAV2VEC2_ASR_BASE_960H; MRFN+ 三种子检查点 SHA-256 前 12 位: 54c56d1fd45d / 7553aa96090f / b491d4f1e5fd (第六章归因与附件 3、附件 4 推理使用同一权重族); 测试集终评冻结于 commit 03eece9 (唯一一次评估, 此后冻结)。

A.3 数据契约

问题一特征契约为 p1.v2: 100 条样本、schema 违例 0, 含结构掩码、逐样本映射表与三个核心 artifact 的 SHA-256; 评测掩码库使用独立种子 (2026), 每场景 8 个实例, 与训练种子分离; 改进轮次的缺失调度种子独立登记, 掩码库全量重生成经逐位一致性校验。

A.4 复现步骤

按下列入口脚本顺序即可复现全部结果 (参数与运行说明随交付包):

复现入口 (scripts/)

```
run_p1.py, check_p1_acceptance.py, generate_p1_replay.py #  
    问题一  
generate_p2_mask_library.py, train_p2_ladder.py,  
    train_p2_mrfn.py,  
train_p2_bft.py, eval_p2_test.py, eval_p2_test_second.py,  
    predict_fj3.py # 问题二  
check_p3_m1.py..check_p3_m5.py, gen_p3_m6_alignment.py,  
    predict_fj4.py # 问题三
```

附录 B 关键代码

B.1 合成缺失算子契约 (src/p2/missing.py, 头部节选)

```
# b_m 只允许落在 o_m=1 的位置; special/padding 永不抹除; a = o*(1-b)
# 机制: mcar=均匀随机位; block=单连续块(位置 head/mid/tail/random);
#      joint=a+v 同位联合(段长~附件3实测分布); full=整模态
# 附件3 实测段长分布: {1: 0.7474, 2: 0.1684, 3: 0.0421, 4: 0.0421}
# 可复现: rng = default_rng([mask_library_seed, combo_idx,
    k]), 逐位复现
MASK_LIBRARY_SEED = 2026; K_INSTANCES = 8
```

B.2 掩码原语与门控 (src/p2/modules.py、models.py, 节选)

```
def forward(self, x, a, mod_idx): # 缺失状态编码: 选择运算
    x_eff = torch.where(a_b[...], None, x, zeros) # a=0
    位不进计算图
    return self.pos + x_eff + (~a_b).to(x.dtype)[..., None] *
        self.miss[mod_idx]
scores = scores.masked_fill(~avail[:, None, None, :],
    float("-inf")) # K 侧屏蔽
v = torch.where(avail[:, None, :, None], v, zeros) # V 侧置零
empty = ~avail.any(dim=1) # 证据全不可用 -> 显式置零分支
g = softmax(self.gate(cat(list(h_tilde.values()) + [cov],
    dim=-1))) # 门控
```

B.3 归因计算 (src/p3/shapley.py、ig.py, 节选)

```
def exact_shapley(values): # 8 联盟精确枚举, 精确分数权重
    w = shapley_weights() # (1/3, 1/6, 1/3)
    for r in range(len(others) + 1):
        for c in combinations(others, r):
            term = (values[S | {m}] - values[S]) * float(w[r])
# IG: 64 步中点 Riemann (代码中路径变量名 alpha 对应正文 \tau)
for k in range(1, n_steps + 1):
    alpha = k / n_steps if rule == "right" else (k - 0.5) /
        n_steps
```

附录 C 结果文件样例

C.1 附件 3 (问题二)

附件 3 预测结果 CSV 含 30 行全量 (完整表头随交付包)。样例行:

附件 3_ 预测结果.csv (样例)

```
附件3_02, 1, -0.1721, 0.4488, 28, 0.0, 0.178571, 0.178571,
0.178571, 1.25, ...
```

行为分析摘要与困难样本清单 (前 5 条: 附件 3_30/29/27/17/21) 随交付包提供。推理模型为 MRFN+ 三种子集成。

C.2 附件 4 (问题三)

预测与模态贡献 CSV 列: sample_id, pred_polarity, confidence (校准), main_modality, $\varphi_{t/a/v}$, $\varphi_{t/a/v}^T$, $g_{t/a/v}$, vision_natural_missing (20 行全量); 证据定位长表列: sample_id, rank, modality, attribution, model_position, evidence_type, content, t_start, t_end, word_align_status (60 行)。样例行:

附件 4_ 证据定位长表.csv (样例)

```
01, 1, text, 0.0552, 9, word, belt, 1, 3.04, 3.22, 8, aligned
```

解释卡交付 4 例 (样本 #04/#09/#13/#17, 覆盖双向词证、强负文本主导、视觉整模态缺失哑玩家、高置信正类四类), 全文随交付包; 正文图 6.7 为另行选取的代表性三例 (含视觉主导样本 #14), 两处样本集不同。样例 (样本 #09):

解释卡 (样节)

```
极性 Negative (校准置信度 0.97) | 强度 -2.29 | 主要参考模态 text
转写: "(uhh) I did not like this movie at all, I would not
      recommend it"
text:  $\varphi$ =+0.682(预测类) / -2.454(强度) /  $g$ =0.765
证据 TOP3 (|IG| 序): "recommend" t [3.20, 3.62]s; "i"
      t [2.80, 2.82]s; "it" t [3.62, 4.96]s
对齐: 14 词 CTC 强制对齐 (失败 2, 插值放行), 视频时长 5.0s
```

20 条样本的带符号模态贡献全量总览见图 C.1, 与正文 6.5 节的解释卡互为整体与细节。

20 条样本的逐样本数值 (极性/置信度/强度/主模态/带符号 $\varphi_t/\varphi_a/\varphi_v$) 见表 C.1。

表 C.1 附件 4 全量解释汇总（极性/置信/强度/主模态）

样本	极性	置信度	强度	主模态	φ_t	φ_a	φ_v
#01	Neutral	0.47	+0.24	text	+0.106	-0.012	+0.024
#02	Positive	0.40	+0.25	text	+0.219	-0.085	-0.045
#03	Negative	0.46	-0.15	text	+0.185	-0.018	+0.011
#04	Negative	0.42	+0.50	text	+0.360	-0.157	-0.076
#05	Positive	0.75	+0.97	text	+0.314	+0.021	+0.140
#06	Positive	0.61	+0.49	text	+0.414	+0.034	-0.123
#07	Positive	0.79	+1.02	text	+0.468	+0.020	+0.026
#08	Positive	0.61	+0.49	text	+0.445	-0.027	-0.091
#09	Negative	0.97	-2.29	text	+0.682	-0.017	+0.021
#10	Negative	0.91	-1.81	text	+0.664	-0.027	+0.005
#11	Negative	0.92	-1.72	text	+0.548	+0.039	+0.068
#12	Negative	0.78	-0.93	text	+0.531	-0.031	+0.032
#13	Neutral	0.53	+0.20	text	+0.182	+0.020	+0.000
#14	Positive	0.48	+0.63	vision	-0.097	+0.059	+0.199
#15	Positive	0.77	+1.12	text	+0.389	+0.119	-0.001
#16	Negative	0.98	-2.40	text	+0.662	-0.008	+0.036
#17	Positive	0.96	+1.77	text	+0.609	+0.045	-0.001
#18	Neutral	0.45	-0.12	text	+0.107	-0.023	+0.030
#19	Positive	0.52	+0.77	vision	+0.050	+0.069	+0.101
#20	Positive	0.82	+1.17	text	+0.422	+0.032	+0.076




图 C.1 附件 4 全量解释总览：各样本带符号模态贡献（按预测极性分组）

附录 D 掩码库说明

31 个评测场景的固定键序（与 5.4 节网格一一对应）：

掩码库场景键序（31 条）

```
mcar/t/rate{10,20,40,60,80}/random # 单模态 × 5 率 (15 条)
mcar/{ta,tv,av}/rate40/random # 双模态 @40% (3 条)
block/{t,a,v}/rate40/{head,mid,tail,random} # 连续块 × 位置 (12 条)
joint/av/rate40/random # 联合缺失 (1 条)
```

每场景 8 个种子化实例（`default_rng([2026, combo_idx, k])`），场景值为 8 实例均值；掩码库种子与训练种子分离，训练期不可见；全库重生成经逐位一致性校验。

表 D.1 为固定覆盖率 40% 下不同连续缺失块长（ $\ell \in \{2, 5, 10\}$ 、独立种子 2027）的性能扫描结果，与 §5.4 节“文本主导脆弱性”结论互为补充——退化由覆盖率与模态身份驱动，而非缺失的连续形态。此外，31 场景按缺失类型分组的占比总览见图 D.1：MCAR 单模态占 48.4%（15 条），Block（连续块）占 38.7%（12 条），MCAR 双模态占 9.7%（3 条），联合缺失占 3.2%（1 条）——与上文键序定义一一对应。与正文图 5.4(b) 的 D_S 热力图互为补充：热力图按场景键序呈现每个场景的退化强度，本环形图按类型聚合呈现场景构成；前者用于读出退化分布，后者用于核验场景网格的类型均衡性。




图 D.1 31 缺失场景类型占比

表 D.1 固定覆盖率 40% 下连续缺失长度扫描 (D_S)

缺失形态	平均段长	文本	语音	视觉
散布 (mcar@40)	1.6	+0.048	-0.001	+0.004
短块 ($\ell \leq 2$)	2.4	+0.054	-0.000	+0.004
中块 ($\ell \leq 5$)	4.5	+0.050	-0.000	+0.004
长块 ($\ell \leq 10$)	7.2	+0.051	-0.002	+0.004
单块 ($\ell \approx 0.4w$)	9.3	+0.050	-0.002	+0.004

注：MRFN 3-seed、valid 728 条 $\times$ 8 实例均值；实际覆盖率 0.399（末块截断，各形态一致）；段长为模型索引空间（非物理秒）实测均值，三模态一致（差 ≤ 0.4 ）；散布与单块为冻结库锚点；clean $\mathcal{S} = 0.735$ 。

附录 E 自动回放图与签核单

以下 9 张回放图按 4.5 节协议自动渲染（签核完成前一律称“自动回放”），覆盖协议规定的全部六类边界；签核单如表 E.1，当前状态为“待签核”，签核结果将补录于本表。以发

表 E.1 回放签核单（当前状态：待签核）

样本	边界类型	人工结论
-3g5yACwYnA_13	多子词、标点挂靠、对齐失败	待签核
-3g5yACwYnA_2	多子词、标点挂靠、对齐失败	待签核
-3g5yACwYnA_9	标点挂靠、对齐失败	待签核
-3nNcZdcdvU_5	多子词、标点挂靠、正常	待签核
-571d8cVauQ_5	头部截断、多子词、对齐失败	待签核
-9y-fZ3swSY_4	rollback、多子词、对齐失败	待签核
-HwX2H8Z4hY_2	rollback、标点挂靠、无人脸、对齐失败	待签核
-HwX2H8Z4hY_5	标点挂靠、无人脸	待签核
-NFrJFQijFE_1	rollback、无人脸、混合帧率、对齐失败	待签核

生 rollback、多子词与对齐失败的样本 -9y-fZ3swSY_4 为例，图 E.1 给出其自动回放。其




图 E.1 自动回放示例

余八张回放图与备选图清单随交付包交付。